Rozumienie języka maszynowego

Dennis Yurichev

Rozumienie języka maszynowego

(Inżynieria wsteczna dla początkujących)

Dlaczego aż dwa tytuły? Przeczytaj tutaj: on page vi.

Dennis Yurichev my emails

@**(1)**

©2013-2022, Dennis Yurichev.

To dzieło jest na licencji Creative Commons Attribution-ShareAlike 4.0 International (CC BY-SA 4.0). Kopia licencji do wglądu znajduje się na https://creativecommons.org/licenses/by-sa/4.0/.

Wersja tekstu (23 października 2023).

Aktualna wersja (a także wersja rosyjska) tego tekstu znajduje się na https://beginners.re/.

Potrzebujemy tłumaczy!

Jeśli chcesz pomóc z tłumaczeniem tej książki na języki inne niż angielski i rosyjski, prześlij mailem fragment przetłumaczonego tekstu (obojętnie jakiej długości) a ja go dodam do kodu źródłowego.

Nie pytaj czy powinieneś tłumaczyć. Po prostu zrób coś. Przestałem odpowiadać na wiadomości "co powinienem zrobić".

Czytać tutaj.

Statystyka tłumaczeń na inne języki znajduje się tutaj: https://beginners.re/.

Prędkość nie gra roli, jako że jest to projekt open-source. Twoje imię pojawi się obok imion innych uczestników projektu. Koreański, chiński i perski są zarezerwowane przez wydawców. Wersją angielską i rosyjską zajmuję się sam, ale mój angielski nadal jest daleki od ideału, więc będę wdzięczny za korekty. Nawet mój rosyjski nie jest idealny, wiec będe wdzięczny również za korekty tekstu w jezyku rosyjskim!

Śmiało piszcie do mnie: my emails.

Skrócony spis treści

1 Przykłady kodu	1
2 Polish text placeholder	144
3	145
4 Java	146
5	147
6	148
7 Książki/blogi warte przeczytania	149
Użyte akronimy	154
Słownik terminów	157
Indeks	159
Spis treści	
1 Przykłady kodu 1.1 Metoda	

	iii
1.2.1 Krótkie wprowadzenie do CPU	. 2
1.2.2 Systemy liczbowe	. 4
1.3 Pusta funkcja	
1.3.1 x86	. 8
1.3.2 ARM	. 8
1.3.3 MIPS	. 8
1.3.4 Puste funkcje w praktyce	
1.4 Zwracanie wartości	
1.4.1 x86	
1.4.2 ARM	
1.4.3 MIPS	
1.5 Hello, world!	
1.5.1 x86	
1.5.2 x86-64	
1.5.3 ARM	
1.5.4 MIPS	
1.5.5 Wnioski	
1.5.6 Ćwiczenia	_
1.6 Prolog i epilog funkcji	
1.6.1 Rekurencja	
1.7 Pusta funkcja raz jeszcze	
1.8 Zwracanie wartości raz jeszcze	
1.9 Stos	
1.9.1 Dlaczego stos rośnie w dół?	
1.9.2 Do czego wykorzystywany jest stos?	
1.9.3 Struktura typowego stosu	
1.9.4 Śmieci na stosie	
1.9.5 Ćwiczenia	
1.10 Funkcja niemal pusta	
1.11 printf() z wieloma argumentami	
1.11.1 x86	
1.11.2 ARM	
1.11.3 MIPS	–
1.11.4 Wnioski	
1.11.5 Przy okazji	
1.12 scanf()	
1.12.1 Prosty przykład	
1.12.2 Popularny błąd	
1.12.3 Zmienne globalne	
1.12.3 Zimerine globalile	
1.12.5 Ćwiczenie	
1.13 Warto zauważyć: zmienne globalne vs zmienne lokalne	
1.14 Dostęp do przekazanych argumentów	
1.14.1 x86	
1.14.2 x64	
1.14.3 ARM	
1.15 switch()/case/default	
1.15.1	
1.15.2 Ćwiczenia	. 140

		iv
	1.16 Loops	141
	1.16.1 Ćwiczenia	141
	1.17 More about strings	141
	1.17.1 strlen()	
	1.18 Replacing arithmetic instructions to other ones	141
	1.18.1 Ćwiczenie	141
	1.19 Arrays	141
	1.19.1	141
	1.19.2	142
	1.19.3 Wnioski	142
	1.19.4 Ćwiczenia	142
	1.20 Structures	142
	1.20.1 UNIX: struct tm	142
	1.20.2	142
	1.20.3 Ćwiczenia	142
	1.21	143
	1.21.1	143
2	Polish text placeholder	144
3		145
4	Java	146
	4.1 Java	146
	4.1.1	146
	4.1.2	146
	4.1.3	146
5		147
	5.1 Linux	
	5.2 Windows NT	
	5.2.1 Windows SEH	
	5.3	
	5.4	147
6		148
0		140
7	Książki/blogi warte przeczytania	149
	7.1 Książki i inne materiały	149
	7.1.1 Inżynieria wsteczna	149
	7.1.2 Windows	149
	7.1.3 C/C++	150
	7.1.4 x86 / x86-64	150
	7.1.5 ARM	150
	7.1.6 Język maszynowy	151
	7.1.7 Java	
	7.1.8 UNIX	
	7.1.9 Programowanie	
	7.1.10	
	7.1.11 Coś jeszcze prostszego	

	V
Użyte akronimy	154
Słownik terminów	157
Indeks	159

Przedmowa

Skąd dwa tytuły?

W latach 2014-2018 książka nosiła tytuł "Inżynieria wsteczna dla początkujących" ale zawsze podejrzewałem, że zawęża to grono czytelników.

Ludzie zajmujący się bezpieczeństwem informacji (infosec) wiedzą o inżynierii wstecznej, jednak rzadko kiedy słyszałem, by używali słowa asembler.

Podobnie, termin "inżynieria wsteczna" jest nieco tajemniczy dla ogólnego grona programistów, jednak wiedzą oni o istnieniu asemblera.

W lipcu 2018 roku, w ramach eksperymentu, zmieniłem tytuł na "Język maszynowy dla początkujących" i umieściłem link na portalu Hacker News¹, i książka została ogólnie dobrze przyjęta.

Niech więc tak będzie, książka ma teraz dwa tytuły.

Zmieniłem jednak drugi tytuł na "Rozumienie kodu maszynowego", ponieważ ktoś już napisał książkę o tytule "Język maszynowy dla początkujących". Ludzie twierdzą, że "dla początkujących" brzmi odrobinę ironicznie jak na ~1000 stronicową książkę.

Dwie książki różnią się jedynie tytułem, nazwą pliku (UAL-XX.pdf versus RE4B-XX.pdf), URLem i kilkoma pierwszymi stronami.

O inżynierii wstecznej

Termin "inżynieria wsteczna" ma kilka popularnych definicji:

- 1) inżynieria wsteczna oprogramowania; analiza skompilowanych programów;
- 2) skanowanie modelu w 3D, żeby następnie go skopiować;
- 3) odzyskiwanie struktury DBMS².

Nasza książka będzie powiązana z tą pierwszą definicją.

Pożądana wiedza

Podstawowa znajomość C PL³. Polecane materiały: 7.1.3 on page 150.

Ćwiczenia i zadania

...wszystkie są na osobnej stronie: http://challenges.re.

Pochwały dla książki

https://beginners.re/#praise.

¹https://news.ycombinator.com/item?id=17549050

²Database Management Systems

³Język programowania (Programming Language)

Uczelnie

Ta książka jest polecana przynajmniej na poniższych uczelniach: https://beginners.re/#uni.

Podziękowania

Za cierpliwe odpowiadanie na wszystkie moje pytania: SkullC0DEr.

Za wskazanie błędów i nieścisłości: Alexander Lysenko, Federico Ramondino, Mark Wilson, Razikhova Meiramgul Kayratovna, Anatoly Prokofiev, Kostya Begunets, Valentin "netch" Nechayev, Aleksandr Plakhov, Artem Metla, Alexander Yastrebov, Vlad Golovkin⁴, Evgeny Proshin, Alexander Myasnikov, Alexey Tretiakov, Oleg Peskov, Pavel Shakhov, Zhu Ruijin, Changmin Heo, Vitor Vidal, Stijn Crevits, Jean-Gregoire Foulon⁵, Ben L., Etienne Khan, Norbert Szetei⁶, Marc Remy, Michael Hansen, Derk Barten, The Renaissance⁷, Hugo Chan, Emil Mursalimov, Tanner Hoke, Tan90909090@GitHub, Ole Petter Orhagen, Sourav Punoriyar, Vitor Oliveira, Alexis Ehret, Maxim Shlochiski, Greg Paton, Pierrick Lebourgeois, Abdullah Alomair, Bobby Battista, Ashod Nakashian.

Za inną pomoc: Andrew Zubinski, Arnaud Patard (rtp on #debian-arm IRC), noshadow on #gcc IRC, Aliaksandr Autayeu, Mohsen Mostafa Jokar, Peter Sovietov, Misha "tiphareth" Verbitsky.

Za przetłumaczenie tej książki na język chiński uproszczony: Antiy Labs (antiy.cn), Archer.

Za tłumaczenie na język koreański: Byungho Min.

Za tłumaczenie na język holenderski: Cedric Sambre (AKA Midas).

Za tłumaczenie na język hiszpański: Diego Boy, Luis Alberto Espinosa Calvo, Fernando Guida, Diogo Mussi, Patricio Galdames, Emiliano Estevarena.

Za tłumaczenie na język portugalski: Thales Stevan de A. Gois, Diogo Mussi, Luiz Filipe, Primo David Santini.

Za tłumaczenie na język włoski: Federico Ramondino⁸, Paolo Stivanin⁹, twyK, Fabrizio Bertone, Matteo Sticco, Marco Negro¹⁰, bluepulsar.

Za tłumaczenie na język francuski: Florent Besnard¹¹, Marc Remy¹², Baudouin Landais, Téo Dacquet¹³, BlueSkeye@GitHub¹⁴.

```
4goto-vlad@github
5https://github.com/pixjuan
6https://github.com/73696e65
7https://github.com/TheRenaissance
8https://github.com/pinkrab
9https://github.com/paolostivanin
10https://github.com/Internaut401
11https://github.com/besnardf
12https://github.com/mremy
13https://github.com/T30rix
14https://github.com/BlueSkeye
```

Za tłumaczenie na język niemiecki: Dennis Siekmeier¹⁵, Julius Angres¹⁶, Dirk Loser¹⁷, Clemens Tamme, Philipp Schweinzer, Tobias Deiminger.

Za tłumaczenie na język polski: Kateryna Rozanova, Aleksander Mistewicz, Wiktoria Lewicka, Marcin Sokołowski.

Za tłumaczenie na język japoński: shmz@github¹⁸,4ryuJP@github¹⁹.

Za korektę: Vladimir Botov, Andrei Brazhuk, Mark "Logxen" Cooper, Yuan Jochen Kang, Mal Malakov, Lewis Porter, Jarle Thorsen, Hong Xie.

Vasil Kolev²⁰ wprowadził wiele poprawek i wskazał sporo błędów.

Dziękuję również wszystkim użytkownikom z github.com za ich komentarze i poprawki.

Użyłem wielu pakietów 上下X. Chciałbym podziękować również ich autorom.

Darczyńcy

Tym wszystkim, którzy mnie wspierali w czasie pisania tej książki:

2 * Oleg Vygovsky (50+100 UAH), Daniel Bilar (\$50), James Truscott (\$4.5), Luis Rocha (\$63), Joris van de Vis (\$127), Richard S Shultz (\$20), Jang Minchang (\$20), Shade Atlas (5 AUD), Yao Xiao (\$10), Pawel Szczur (40 CHF), Justin Simms (\$20), Shawn the R0ck (\$27), Ki Chan Ahn (\$50), Triop AB (100 SEK), Ange Albertini (€10+50), Sergey Lukianov (300 RUR), Ludvig Gislason (200 SEK), Gérard Labadie (€40), Sergey Volchkov (10 AUD), Vankayala Vigneswararao (\$50), Philippe Teuwen (\$4), Martin Haeberli (\$10), Victor Cazacov (€5), Tobias Sturzenegger (10 CHF), Sonny Thai (\$15), Bayna AlZaabi (\$75), Redfive B.V. (€25), Joona Oskari Heikkilä (€5), Marshall Bishop (\$50), Nicolas Werner (€12), Jeremy Brown (\$100), Alexandre Borges (\$25), Vladimir Dikovski (€50), Jiarui Hong (100.00 SEK), Jim Di (500 RUR), Tan Vincent (\$30), Sri Harsha Kandrakota (10 AUD), Pillay Harish (10 SGD), Timur Valiev (230 RUR), Carlos Garcia Prado (€10), Salikov Alexander (500 RUR), Oliver Whitehouse (30 GBP), Katy Moe (\$14), Maxim Dyakonov (\$3), Sebastian Aguilera (€20), Hans-Martin Münch (€15), Jarle Thorsen (100 NOK), Vitaly Osipov (\$100), Yuri Romanov (1000 RUR), Aliaksandr Autayeu (€10), Tudor Azoitei (\$40), Z0vsky (€10), Yu Dai (\$10), Anonymous (\$15), Vladislav Chelnokov (\$25), Nenad Noveljic (\$50), Ryan Smith (\$25), Andreas Schommer (€5), Nikolay Gavrilov (\$300), Ernesto Bonev Reynoso (\$30).

bardzo dziękuję.

mini-FAQ

Q: Czy ta książka jest prostsza niż inne?

A: Nie, poziom trudności jest mniej więcej taki sam jak innych książek na ten temat.

```
15https://github.com/DSiekmeier
16https://github.com/JAngres
17https://github.com/PolymathMonkey
18https://github.com/shmz
19https://github.com/4ryuJP
20https://vasil.ludost.net/
```

Q: Obawiam się zacząć czytać tę książkę, ma ponad 1000 stron. "... dla początkujących" w nazwie brzmi nieco ironicznie.

A: Wszelkiego rodzaju kody źródłowe stanowią większość tej książki. Ta książka naprawdę jest dla początkujących, wiele w niej (jeszcze) brakuje.

Q: Co trzeba wiedzieć zanim się przystąpi do czytania książki?

A: Umiejętności C/C++ są pożądane, ale nie są niezbędne.

Q: Czy powinienem uczyć się jednocześnie x86/x64/ARM i MIPS? Czy to nie za dużo?

A: Myślę, że na początek wystarczy czytać tylko o x86/x64, części o ARM i MIPS można pominąć.

Q: Czy można zakupić książki w wersji papierowej w języku rosyjskim lub angielskim?

A: Niestety nie, żaden wydawca jeszcze się nie zainteresował wydaniem rosyjskiej lub angielskiej wersji. Natomiast można ją wydrukować i zbindować w każdym ksero. https://yurichev.com/news/20200222_printed_RE4B/.

Q: Czy istnieje wersja epub/mobi?

A: Nie. W wielu miejscach książka korzysta z hacków specyficznych dla TeXa/LaTeXa, dlatego przerobienie jej na HTML (epub/mobi to jest HTML) nie jest łatwe.

Q: Po co uczyć się asemblera w dzisiejszych czasach?

A: Jeśli nie jest się programistą OS²¹, to prawdopodobnie nie trzeba nic pisać w asemblerze: współczesne kompilatory optymalizują kod lepiej niż człowiek ²².

Do tego współczesne CPU²³ są bardzo skomplikowanymi urządzeniami i znajomość asemblera nie pomoże poznać ich mechanizmów wewnętrznych.

Jednak zostają dwa obszary, w których dobra znajomość asemblera może być pomocna: 1) badanie malware (złośliwego oprogramowania) w celu jego analizy ; 2) lepsze zrozumienie skompilowanego kodu w trakcie debuggowania.

Wobec tego ta książka jest napisana dla tych ludzi, którzy raczej chcą rozumieć assembler, a nie w nim pisać. Stąd jest w niej bardzo dużo przykładów - wyjść kompilatora.

Q: Kliknałem w odnośnik wewnątrz pliku PDF, jak teraz wrócić?

A: W Adobe Acrobat Reader trzeba wcisnąć Alt+LeftArrow. W Evince wcisnąć "<".

Q: Czy mogę wydrukować tę książkę? Korzystać z niej do nauczania?

A: Oczywiście, właśnie dlatego ta książka ma licencję Creative Commons (CC BY-SA 4.0).

Q: Dlaczego ta książka jest darmowa? Wykonałeś świetną robotę. To podejrzane, podobnie jak z innymi rzeczami za darmo.

²¹System operacyjny (Operating System)

²²Bardzo ciekawy artykuł na ten temat: [Agner Fog, *The microarchitecture of Intel, AMD and VIA CPUs*, (2016)]

²³Central Processing Unit

A: Moim zdaniem autorzy literatury technicznej robią to dla autoreklamy. Taka praca nie przynosi za dużo pieniędzy.

Q: Jak znaleźć pracę w zawodzie reverse engineeraa?

A: Na reddit (RE²⁴), od czasu od czasu pojawiają się wątki poszukiwania pracowników. Możesz spróbować tam poszukać.

Q: Mam pytanie...

A: Napisz do mnie maila (my emails).

O tłumaczeniu na język koreański

W styczniu 2015, wydawnictwo Acorn (www.acornpub.co.kr) z Korei Południowej wykonało ciężką pracę, żeby przetłumaczyć i wydać moją książkę (stanem na sierpień 2014) w języku koreańskim. Jest ona teraz dostępna na ich stronie.

Tłumaczył Byungho Min (twitter/tais9). Okładka namalował mój dobry przyjaciel, artysta, Andy Nechaevsky facebook/andydinka.

Acorn również ma prawa autorskie do tłumaczenia koreańskiego. Jakbyście chcieli mieć *prawdziwą* książkę w języku koreańskim i chcielibyście wesprzeć moją pracę, możecie ją kupić.

O tłumaczeniu na język perski (farsi)

W roku 2016 książkę przetłumaczył Mohsen Mostafa Jokar (znany w irańskiej społeczności z tłumaczenia instrukcji do Radare²⁵) Książka jest dostępna na stronie wydawnictwa ²⁶ (Pendare Pars).

Pierwsze 40 stron: https://beginners.re/farsi.pdf.

Pozycja książki w Narodowej Bibliotece Iranu: http://opac.nlai.ir/opac-prod/bibliographic/4473995.

O tłumaczeniu na język chiński

W kwietniu 2017, wydawnictwo PTPress skończyło tłumaczenie mojej książki na język chiński. Mają również prawo autorskie do tłumaczenia chińskiego.

Chińskie tłumaczenie można zamówić tutaj: http://www.epubit.com.cn/book/details/4174. Recenzje i historię tłumaczenia można znaleźć tutaj: http://www.cptoday.cn/news/detail/3155.

Głównym tłumaczem był Archer, u którego mam teraz dług wdzięczności. Był bardzo dociekliwy i znalazł w książce sporo bugów i błędów, co jest szczególnie ważne w literaturze, której dotyczy ta książka.

Bede polecał go również innym autorom!

²⁴reddit.com/r/ReverseEngineering/

²⁵http://rada.re/get/radare2book-persian.pdf

²⁶http://goo.gl/2Tzx0H

Chłopaki z Antiy Labs również pomogli z tłumaczeniem. Tutaj słowo wstępne napisane przez nich.

Rozdział 1

Przykłady kodu

1.1 Metoda

Kiedy autor tej książki uczył się C, a później C++, pisał niewielkie kawałki kodu, kompilował i patrzył jak wyglądają w asemblerze. Tak było o wiele łatwiej zrozumieć co się dzieje w programie.¹. Robił to wystarczająco dużo razy, żeby związek między kodem w C/C++ a tym co generuje kompilator wbił się w jego podświadomość bardzo głęboko. Dzięki temu łatwo mu określić zgrubną strukturę kodu w C, patrząc na kod asemblera. Możliwe, że ta metoda pomoże komuś jeszcze.

Czasami wykorzystam stare kompilatory, żeby otrzymać bardzo krótki lub prosty kawałek kodu.

Przy okazji, jest świetna strona, gdzie możesz zrobić to samo, używając różnych kompilatorów - bez konieczności instalowania ich u siebie: http://godbolt.org/.

Ćwiczenia

Kiedy autor tej książki uczył się asemblera, często kompilował krótkie funkcje w C i przepisywał je stopniowo na asemblera, starając się uzyskać jak najkrótszy kodu. Prawdopodobnie nie warto tego robić w praktycznych zastosowaniach, ponieważ trudno jest konkurować ze współczesnymi kompilatorami pod względem wydajności. Jest to jednak bardzo dobry sposób na zrozumienie asemblera. Możesz wziąć dowolny fragment kodu w asemblerze z tej książki i postarać się uczynić go krótszym. Ale nie zapomnij przetestować swojego rezultatu.

Poziomy optymalizacji i debuggowanie

Kod źródłowy można kompilować różnymi kompilatorami z różnym poziomami optymalizacji. W typowym kompilatorze jest tych poziomów około trzech, gdzie poziom

 $^{^1}$ Szczerze mówiąc, dalej tak robi, kiedy nie rozumie jak jakiś kod działa. Ostatni przykład, z 2019 roku: p += p+(i&1)+2; z "SATOW", SAT-solvera autorstwa D. Knutha.

zerowy oznacza wyłączoną optymalizację. Optymalizować można rozmiar programu lub jego szybkość. Kompilator, który nie dokonuje optymalizacji, działa szybciej i generuje bardziej przejrzysty kod (choć i większy objętościowo). Kompilator, który dokonuje optymalizacji, działa wolniej i stara się wygenerować jak najszybszy kod (co nie zawsze znaczy, że kod będzie krótszy). Obok poziomów i kierunków optymalizacji kompilator może załączać do pliku wynikowego dodatkowe informacje dla debuggera, tworząc w ten sposób kod, który jest prostszy w debuggowaniu. Bardzo ważną cechą kodu debuggowanego jest to, że może on zawierać powiązanie między każdą linią kodu źródłowego a adresem w kodzie maszynowym. Kompilatory, dokonując optymalizacji, zwykle generują kod, gdzie całe linie kodu źródłowego mogą zostać pominięte nie będą nawet widoczne w kodzie maszynowym. Praktykujący reverse engineer z reguły ma styczność z obiema wersjami, jako że niektórzy developerzy włączają optymalizację, a niektórzy - nie.

Dlatego będziemy pracować z przykładami kodu w obu wariantach.

1.2 Niektóre podstawowe pojęcia

1.2.1 Krótkie wprowadzenie do CPU

CPU (procesor) jest urządzeniem, które wykonuje bezpośrednio kod maszynowy programu.

Terminologia:

Instrukcja: prymitywny rozkaz CPU. Najprostsze przykłady: przenoszenie (kopiowanie) danych między rejestrami, korzystanie z pamięci (zapis/odczyt), proste operacje arytmetyczne.

Z reguły każdy CPU ma swój zestaw instrukcji (ISA²).

Kod maszynowy: kod wykonywany bezpośrednio przez CPU. Każda instrukcja kodu maszynowego zwykle jest kodowana za pomocą kilku bajtów.

Język asemblera : kod maszynowy plus niektóre rozszerzenia (np. makra), stworzone po to, żeby ułatwić pracę programiście.

Rejestr CPU: Każdy CPU ma swój zestaw rejestrów ogólnego przeznaczenia (GPR³). ≈ 8 w x86, ≈ 16 w x86-64 i ≈ 16 w ARM. Najłatwiej myśleć o rejestrze jak o zmiennej tymczasowej bez określonego typu. Wyobraź sobie, że pisząc w języku wyższego poziomu, masz dostępnych tylko 8 zmiennych o szerokości 32 (lub 64) bitów. Te 8 zmiennych to właśnie rejestry. Wbrew pozorom można z nimi naprawdę wiele zrobić!

Dlaczego występują języki niższego i wyższego poziomu? Odpowiedź jest prosta: ludzie i procesory różnią się między sobą - dla człowieka jest o wiele łatwiej pisać w wysokopoziomowym języku programowania typu C/C++, Java czy Python, a dla procesora łatwiej jest pracować na niższym poziomie abstrakcji. Zapewne można by zbudować procesor, który wykonywałby kod wysokiego poziomu, ale jego budowa byłaby dużo bardziej skomplikowana niż budowa procesorów jakie obecnie znamy. I

²Instruction Set Architecture (architektura listy rozkazów)

³General Purpose Registers (rejestry ogólnego przeznaczania)

odwrotnie, pisanie w języku asemblera jest dla ludzi bardzo niewygodne, z uwagi na jego niski poziom i trudność kodowania bez popełniania całej masy drobnych błędów. Program, który potrafi konwertować język wysokiego poziomu na kod asemblera, nazywamy kompilatorem.

Kilka słów o różnicy między ISA

x86 od zawsze zawierało instrukcje o różnej długości, więc kiedy nadeszła era 64-bitowej architektury, rozszerzenia x64 nie wpłynęły znacząco na ISA.

ARM to procesor RISC⁴ zaprojektowany tak, żeby zawierał wszystkie instrukcje tej samej długości, co miało sporo zalet w przeszłosci. Na samym początku wszystkie instrukcje ARM były kodowane na czterech bajtach (obecnie "tryb ARM")⁵.

Później się okazało, że nie jest to zbyt ekonomiczne, bo najczęściej używane przez procesor instrukcje⁶ mogą być zakodowane z wykorzystaniem mniejszej ilości informacji. Więc dodano inną ISA o nazwie "Thumb", gdzie każda instrukcja jest kodowana za pomocą tylko 2 bajtów. Jednak nie wszystkie instrukcje ARM mogą być zakodowane na 2 bajtach, więc zestaw instrukcji Thumb jest ograniczony. Kod skompilowany dla trybu ARM i Thumb może współdziałać w jednym programie.

Później twórcy ARM stwierdzili, że Thumb można rozszerzyć: tak pojawił się Thumb-2 (w ARMv7). Thumb-2 to wciąż dwubajtowe instrukcje, ale niektóre nowe instrukcje mają długość 4 bajtów. Szeroko rozpowszechnioną i błędną opinią jest to, że Thumb-2 to mieszanina ARM i Thumb. Tryb Thumb-2 został rozszerzony w celu wsparcia dla wszystkich możliwości procesora, by mógł konkurować z trybem ARM—co zostało w pełni osiągnięte, gdyż większość aplikacji na urządzenia iPod/iPhone/iPad są skompilowane dla zestawu instrukcji Thumb-2, (trzeba przyznać, że w dużej mierze jest to zasługa Xcode, który robi to domyślnie).

Później pojawił się 64-bitowy ARM. Jest to ISA znowu z 4-bajtowymi instrukcjami, bez dodatkowego trybu Thumb. Jednak nowe 64-bitowe wymagania wpłyneły na ISA tak, że obecnie mamy 3 zestawy instrukcji ARM: tryb ARM, tryb Thumb/Thumb-2 i ARM64. Te zestawy instrukcji częściowo się pokrywają, ale można powiedzieć, że są to różne zestawy a nie wariacje tego samego ISA. W tej książce postaramy się zaprezentować fragmenty kodu we wszystkich trzech trybach ISA. Istnieje jeszcze wiele innych RISC ISA z instrukcjami 32-bitowej długości — np. MIPS, PowerPC i Alpha AXP.

⁴Reduced Instruction Set Computing

⁵Instrukcje o stałym rozmiarze są wygodne, bo dzięki temu można łatwo znaleźć adres następnej (lub poprzedniej) instrukcji. Dokładniejsze wyjaśnienie znajduje się w sekcji o operatorze switch() (**??** on page ??).

⁶Są nimi MOV/PUSH/CALL/Jcc

1.2.2 Systemy liczbowe

Nowadays octal numbers seem to be used for exactly one purpose—file permissions on POSIX systems—but hexadecimal numbers are widely used to emphasize the bit pattern of a number over its numeric value.

Alan A. A. Donovan, Brian W. Kernighan — The Go Programming Language

Ludzie przyzwyczaili się do systemu dziesiętnego prawdopodobnie dlatego, że każdy ma 10 palców. Natomiast liczba 10 nie odgrywa szczególnej roli w nauce i matematyce. Binarny (dwójkowy) system liczbowy jest naturalny dla techniki cyfrowej i elektroniki: 0 oznacza brak prądu, a 1 — jego obecność. 10 w systemie binarnym to 2 w dziesiętnym; 100 w binarnym to 4 w dziesiętnym, itd.

Jeżeli w systemie liczbowym jest 10 znaków, jego *podstawa* (ang. *radix* lub *base*) to 10. System dwójkowy ma *podstawę* 2.

Ważne rzeczy, które warto sobie przypomnieć:

1) *liczba* jest liczbą, natomiast *cyfra* to umowny znak pisarski służący do zapisywania liczb; 2) sama w sobie liczba się nie zmienia przy przeliczaniu z jednego systemu na inny: zmienia się tylko sposób jej zapisu (lub reprezentacja w pamięci).

Jak skonwertować liczbę z jednego systemu na drugi?

Z notacji pozycyjnej korzysta się prawie wszędzie, to znaczy, że każda cyfra posiada swoją wagę w zależności od jej usytuowania wewnątrz liczby. Jeżeli 2 znajduje sie na ostatnim miejscu od prawej, jest to 2. Jeżeli jest ona usytuowana w miejscu przedostatnim, jest to 20.

Co oznacza zapis 1234?

```
10^3 \cdot 1 + 10^2 \cdot 2 + 10^1 \cdot 3 + 1 \cdot 4 = 1234 lub 1000 \cdot 1 + 100 \cdot 2 + 10 \cdot 3 + 4 = 1234
```

Tak samo to wygląda w przypadku liczb binarnych, tyle że podstawą jest 2, a nie 10. Co oznacza zapis 0b101011?

$$2^5 \cdot 1 + 2^4 \cdot 0 + 2^3 \cdot 1 + 2^2 \cdot 0 + 2^1 \cdot 1 + 2^0 \cdot 1 = 43 \text{ lub } 32 \cdot 1 + 16 \cdot 0 + 8 \cdot 1 + 4 \cdot 0 + 2 \cdot 1 + 1 = 43$$

Notację pozycyjną można przeciwstawić notacji niepozycyjnej, np. rzymskiej. ⁷. Prawdopodobnie ludzkość przeszła na notację pozycyjną, ponieważ w ten sposób łatwiej jest wykonywać proste operacje (dodawanie, mnożenie, itd.) na papierze, ręcznie.

Liczby binarne również można pisemnie dodawać, odejmować itd., dokładnie tak samo jak uczy się tego w szkole, tylko z użyciem dwóch cyfr.

Liczby w zapisie binarnym są nieporęczne, kiedy stosuje się je w kodzie źródłowym i zrzutach pamięci, dlatego w tych miejscach używa się systemu szesnastkowego (heksadecymalnego), o podstawie 16. System szesnastkowy używa szesnastu cyfr - znaków 0-9 oraz A-F. Każda cyfra zajmuje 4 bity lub 4 cyfry w systemie binarnym,

 $^{^7}$ O ewolucji systemów liczbowych przeczytasz w [Donald E. Knuth, *The Art of Computer Programming*, Volume 2, 3rd ed., (1997), 195–213.]

więc łatwo można konwertować z reprezentacji binarnej na szesnastkową i odwrotnie, nawet w pamięci.

szesnastkowy	binarny	dziesiętny
0	0000	0
1	0001	1
2	0010	2
3	0011	3
4	0100	4
5	0101	5
6	0110	6
7	0111	7
8	1000	8
9	1001	9
A	1010	10
В	1011	11
C	1100	12
D	1101	13
E	1110	14
F	1111	15

Jak rozpoznać w jakim systemie zapisana jest konkretna liczba?

Liczby dziesiętne z reguły są zapisywane tradycyjnie, czyli 1234. Ale niektóre asemblery pozwalaja podkreślić to przez sufiks "d": 1234d.

Do liczb binarnych czasami dodaje się prefiks "0b": 0b100110111 (W GCC⁸ istnieje do tego niestandardowe rozszerzenie ⁹). Jest jeszcze inny sposób: sufiks "b", np: 100110111b. W tej książce będę się trzymał konwencji prefiksowej "0b" dla liczb binarnych.

Liczby szesnastkowe mają prefiks "0x" w C/C++ i niektórych innych PL: 0x1234ABCD. Lub mają sufiks "h": 1234ABCDh — zwykle są w ten sposób reprezentowane w asemblerach lub debuggerach. W tej konwencji, jeśli liczba zaczyna się od A..F, przed nimi dopisuje się 0: 0ABCDEFh. Za czasów 8-bitowych komputerów domowych był również sposób zapisu liczb za pomocą prefiksu \$, np., \$ABCD. W tej książce będę się trzymał prefiksu "0x" dla liczb szesnastkowych.

Czy trzeba umieć konwertować liczby w głowie? Tablicę liczb szesnastkowych składających się z jednej cyfry łatwo zapamiętać, ale raczej nie warto zapamiętywać większych liczb.

Prawdopodobnie najczęściej liczby szesnastkowe są spotykane w URL¹⁰-ach. W ten sposób są kodowane litery spoza alfabetu łacińskiego. Np.: https://en.wiktionary.org/wiki/na%C3%AFvet%C3%A9 to URL strony w Wiktionary o słowie "naïveté".

⁸GNU Compiler Collection

⁹https://gcc.gnu.org/onlinedocs/gcc/Binary-constants.html

¹⁰Uniform Resource Locator

System ósemkowy

Jeszcze jeden system, z którego często korzystało się w informatyce w przeszłości to system oktalny. System oktalny ma 8 cyfr (0-7), każda opisująca 3 bity, więc łatwo przeliczać liczbę na inne systemu, w obie strony. Ten system prawie wszędzie został zastąpiony przez szesnastkowy, ale, o dziwo, w systemach *NIX nadal jest program korzystający z systemu ósemkowego: chmod.

Jak wiedzą użytkownicy systemów *NIX, argumentem chmod jest liczba składająca się z 3 cyfr. Pierwsza cyfra określa uprawnienia właściciela pliku, druga - to uprawnienia grupy (do której plik należy), trzecia dla reszty użytkowników. Każda cyfra może być przedstawiona binarnie:

dziesiętny	binarny	znaczenie
7	111	rwx
6	110	rw-
5	101	r-x
4	100	r
3	011	-wx
2	010	-w-
1	001	x
0	000	

Więc każdy bit jest powiązany z flagą: read/write/execute (prawo do odczytu/zapisu-/wykonania).

Właśnie dlatego wspomniałem o chmod — liczba, będąca argumentem, może być reprezentowana w systemie ósemkowym. Na przykład weźmy 644. Kiedy uruchamiasz chmod 644 file, ustawiasz uprawnienia read/write (odczyt zapis) dla właściciela, uprawnienia read (zapis) dla grupy i read dla wszystkich innych użytkowników. Jeśli skonwertujemy liczbę 644 z systemu ósemkowego na binarny, to otrzymamy 110100100, lub (w grupach po 3 bity) 110 100 100.

Teraz widzimy, że każda 'trójka' opisuje uprawnienia dla właściciela/grupy/reszty: pierwsza rw-, druga to r-- i trzecia to r--.

System ósemkowy był również popularny na starych komputerach, jak PDP-8, dlatego że słowo (podstawowa porcja informacji) mogło składać się 12, 24 lub 36 bitów, a wszystkie te liczby są podzielne przez 3, więc wybór systemu ósemkowego był całkiem logiczny. Obecnie wszystkie popularne komputery mają słowa/adresy 16-, 32-lub 64-bitowe i wszystkie te liczby są podzielne przez 4, więc system szesnastkowy jest wygodniejszy.

System ósemkowy jest wspierany przez wszystkie standardowe kompilatory C/C++. Czasami jest to źródłem nieporozumień, dlatego że liczby ósemkowe są kodowane z zerem z przodu, na przykład: 0377 to 255. Gdy pomylisz się i napiszesz "09" zamiast 9, to kompilator zgłosi błąd. GCC może zwrócić podobny komunikat: error: invalid digit "9" in octal constant.

System ósemkowy jest również popularny w Javie. Gdy IDA¹¹ wyświetla string ze znakami niedrukowalnymi, są one zakodowane w systemie ósemkowym (a nie szesnastkowym). Dekompilator JAD zachowuje się w taki sam sposób.

Podzielność

Kiedy widzisz liczbę 120, to można szybko się zorientować, że jest ona podzielna przez 10, dlatego że ostatnią cyfrą jest 0. Podobnie, 123400 jest podzielne przez 100, bo ostatnie dwie cyfry są zerami.

Analogicznie liczba szesnastkowa 0x1230 jest podzielna przez 0x10 (16 w systemie dziesiętnym), 0x123000 jest podzielne przez 0x1000 (4096 w systemie dziesiętnym), itd.

Liczba binarna 0b1000101000 jest podzielna przez 0b1000 (8), itd.

Tę właściwość można wykorzystać, żeby szybko sprawdzić czy jakiś adres lub rozmiar bloku jest wyrównany do pewnej granicy (czy rozmiar bloku jest całkowitą krotnością długości słowa, np. krotnością 32 bitów). Na przykład sekcje w plikach PE¹² prawie zawsze zaczynają się od adresów kończących się trzema szesnastkowymi zerami: 0x41000, 0x10001000, itd., gdyż prawie wszystkie sekcje w plikach PE są wyrównane do granicy 0x1000 (4096) bajtów.

Arytmetyka wielokrotnej precyzji a podstawa

Arytmetyka wielokrotnej precyzji (multi-precision arithmetic) może operować na dowolnie dużych liczbach, które mogą być przechowywane w kilku bajtach. Na przykład klucze RSA, zarówno prywatne jak i publiczne, mogą zajmować 4096 bitów a nawet więcej.

W [Donald E. Knuth, *The Art of Computer Programming*, Volume 2, 3rd ed., (1997), 265] przedstawiono ideę: kiedy przechowuje się liczbę wielokrotnej precyzji w kilku bajtach, cała liczba może być reprezentowana jako zapisana w systemie liczbowym o podstawie $2^8 = 256$, i każda cyfra reprezentuje jeden bajt. Podobnie, gdybyś liczbę wielokrotnej precyzji przechowywał w kilku 32-bitowych całkowitoliczbowych wartościach, każda cyfra byłaby reprezentowana przez 32-bitowy slot (4 bajty), i można by uważać te liczbe za zapisaną w systemie o podstawie 2^{32} .

Wymowa liczb w systemach niedziesiętnych

Liczby zapisane w systemie o podstawie innej niż 10, zwykle wymawia się cyfra po cyfrze: "jeden-zero-zero-jeden-jeden-...". Nie używa się słów jak "dziesięć" czy "tysiąc" by przez pomyłkę nie potraktowano liczby jak zapisanej w systemie dziesiętnym.

Liczby zmiennoprzecinkowe

Żeby odróżniać liczby zmiennoprzecinkowe od całkowitoliczbowych, często na końcu dodaje się ".0", np. 0.0, 123.0, itd.

¹¹ Interaktywny deasembler i debugger rozwijany przez Hex-Rays

¹²Portable Executable (format plików wykonywalnych w systemach Windows)

1.3 Pusta funkcja

Najprostszą istniejącą funkcją jest funkcja, która nic nie robi:

Listing 1.1: Kod w C/C++

```
void f()
{
         return;
};
```

Skompilujmy ją!

1.3.1 x86

Dla x86 i MSVC, i GCC generują ten sam kod:

Listing 1.2: Optymalizujący GCC/MSVC (wyjście w asemblerze)

```
f: ret
```

Mamy tu tylko jedną instrukcję: RET, która jest instrukcją powrotu do funkcji wywołującej.

1.3.2 ARM

Listing 1.3: Optymalizujący Keil 6/2013 (tryb ARM) (wyjście w asemblerze)

```
f PROC
BX lr
ENDP
```

Adres powrotu (RA¹³) w ARM zapisywany jest nie na stosie, a w rejestrze LR¹⁴. Instrukcja BX LR, wykonując skok pod ten adres, zwraca sterowanie do funkcji wywołującej.

1.3.3 MIPS

Są dwie konwencje nazewnictwa rejestrów w architekturze MIPS: używająca numeru rejestru (od \$0 do \$31) lub nazwy umownej (\$V0, \$A0, itd.).

Wyjście asemblera w GCC pokazuje numery rejestrów

Listing 1.4: Optymalizujący GCC 4.4.5 (wyjście w asemblerze)

```
j $31
nop
```

...a IDA— nazwy umowne:

¹³adres powrotu

¹⁴Link Register

Listing 1.5: Optymalizujący GCC 4.4.5 (IDA)

```
j $ra
nop
```

Pierwsza instrukcja jest instrukcją skoku (J lub JR), która zwraca sterowanie do funkcji wywołującej, skacząc pod adres w rejestrze \$31 (\$RA).

Jest to rejestr odpowiadający LR w ARM.

Druga instrukcja to NOP¹⁵, która nic nie robi. Na razie możemy ją zignorować.

Jeszcze małe co nieco o konwencji nazewnictwa w MIPS

Nazwy rejestrów i instrukcji w MIPS tradycyjnie są zapisywane małymi literami, lecz my będziemy je zapisywać dużymi, dlatego że nazwy instrukcji i rejestrów innych ISA w tej książce są zapisywane dużymi.

1.3.4 Puste funkcje w praktyce

Mimo, że puste funkcje są bezużyteczne, są one dość często spotykane w niskopoziomowym kodzie.

Po pierwsze, często spotykamy funkcje zapisujące szczegółowe informacje do logów, na przykład:

Listing 1.6: Kod w C/C++

Przy kompilacji wersji programu przeznaczonej do wdrożenia, _DEBUG jest niezdefiniowane, więc funkcja dbg_print(), mimo, że jest wywoływana, będzie pusta.

Po drugie, popularnym sposobem na ochronę oprogramowania jest kompilacja kilku wersji: pierwsza dla legalnych konsumentów, druga - demonstracyjna. Demonstracyjna wersja może nie zawierać jakiejś ważnej funkcjonalności, na przykład:

¹⁵No Operation

Listing 1.7: Kod w C/C++

Funkcja save_file() może być wywołana, kiedy użytkownik klika w menu File->Save. Wersja demo może zawierać wyłączony przycisk menu, ale nawet jeśli cracker go włączy, to zostanie wywoływana jedynie pusta funkcja, w której nie ma użytecznego kodu.

IDA oznacza takie funkcje jako nullsub_00, nullsub_01, itd.

1.4 Zwracanie wartości

Inną prostą funkcją jest taka, która zwraca stałą wartość.

Listing 1.8: Kod w C/C++

```
int f()
{
     return 123;
};
```

Skompilujmy ją.

1.4.1 x86

Poniżej efekt kompilacji z optymalizacją kompilatorami GCC i MSVC na x86:

Listing 1.9: Optymalizujący GCC/MSVC (wyjście w asemblerze)

```
f:
mov eax, 123
ret
```

Są tu tylko dwie instrukcje: pierwsza zapisuje wartość 123 do rejestru EAX, który umownie jest używany do przechowywania wartości zwracanej, a drugą jest RET, która zwraca sterowanie do funkcji wywołującej.

Funkcja wywołująca pobierze wynik z rejestru EAX.

1.4.2 ARM

W kodzie maszynowym na ARM widać kilka różnic:

Listing 1.10: Optymalizujący Keil 6/2013 (tryb ARM) (wyjście w asemblerze)

```
f PROC
```

MOV BX ENDP	r0,#0x7b ; 123 lr
ENDP	

ARM używa rejestru R0 do zwracania wartości z funkcji, więc 123 kopiowane jest do R0.

Warto zaznaczyć, że nazwa instrukcji MOV jest myląca, zarówno na x86 jak i na ARM. Dane nie są *przenoszone*, tylko *kopiowane*.

1.4.3 MIPS

Wyjście asemblera GCC oznacza rejestry numerami:

Listing 1.11: Optymalizujący GCC 4.4.5 (wyjście w asemblerze)

j	\$31	
li	\$2,123	# 0×7b

...a IDA używa nazw umownych:

Listing 1.12: Optymalizujący GCC 4.4.5 (IDA)

			, , ,	, ,	
jr li	\$ra \$v0,	0x7B			
li	\$v0,	0x7B			

Rejestr \$2 (nazwa umowna - \$V0) używany jest do przechowywanie wartości zwracanej z funkcji. LI to skrót od "Load Immediate" i w architekturze MIPS jest odpowiednikiem instrukcji MOV z x86.

Drugą instrukcją jest instrukcja skoku (J lub JR), która zwraca sterowanie do funkcji wywołującej.

Możesz się zastanawiać, dlaczego instrukcje LI i J/JR są w odwrotnej kolejności. Jest to efekt optymalizacji przetwarzania potokowego w architekturze RISC, zwanej "branch delay slot".

Przyczyną wprowadzanie takiego rozwiązania jest dziwactwo w niektórych architekturach typu RISC i nie jest to dla nas istotne - po prostu przyjmijmy, że w asemblerze MIPS instrukcja następująca po instrukcji skoku jump/branch jest wykonywana przed samym skokiem.

W rezultacie instrukcje typu branch są zawsze zamienione z instrukcją, która jest wykonywana przed nimi.

W praktyce często występują funkcje, które jedynie zwracają 1 (*true - prawdę*) lub 0 (*false - fałsz*).

Najmniejsze UNIXowe narzędzia, /bin/true i /bin/false zwracają odpowiednio 0 i 1, jako kod wyjścia. (Zero, jako kod wyjścia, oznacza zwykle sukces, natomiast kod niezerowy oznacza błąd.)

1.5 Hello, world!

Przejdźmy do słynnego przykładu z książki [Brian W. Kernighan, Dennis M. Ritchie, *The C Programming Language*, 2ed, (1988)]:

Listing 1.13: Kod w C/C++

```
#include <stdio.h>
int main()
{
    printf("hello, world\n");
    return 0;
}
```

1.5.1 x86

MSVC

Skompilujmy kod w MSVC 2010:

```
cl 1.cpp /Fal.asm
```

(Opcja /Fa oznacza wygenerowanie listingu w asemblerze)

Listing 1.14: MSVC 2010

```
CONST
         SEGMENT
                  'hello, world', OAH, OOH
$SG3830 DB
CONST
        ENDS
        _main
PUBLIC
        _printf:PROC
EXTRN
; Function compile flags: /Odtp
_TEXT
        SEGMENT
_main
        PR<sub>0</sub>C
        push
                 ebp
                 ebp, esp
        mov
                 OFFSET $SG3830
        push
        call
                 _printf
        add
                 esp, 4
                 eax, eax
        xor
         pop
                 ebp
                 0
         ret
main
         ENDP
TEXT
        ENDS
```

MSVC generuje listingi w składni Intela. Różnica między składnią Intela a AT&T będzie omówiona w in 1.5.1 on page 15.

Kompilator wygenerował plik 1.obj, który następnie będzie połączony konsolidatorem (ang. linker) w 1.exe. W naszym przypadku ten plik składa się z dwóch segmentów: CONST (dane-stałe) i _TEXT (kod).

Łańcuch znaków hello, world w C/C++ ma typ const char[][Bjarne Stroustrup, The C++ Programming Language, 4th Edition, (2013)p176, 7.3.2], jednak nie posiada nazwy. Kompilator potrzebuje nazwy, żeby z tym łańcuchem znaków pracować, dlatego nadaje mu własną nazwę - \$SG3830.

Dlatego ten przykład można by zapisać w ten sposób:

```
#include <stdio.h>
const char $SG3830[]="hello, world\n";
int main()
{
    printf($SG3830);
    return 0;
}
```

Wróćmy do kodu w asemblerze. Jak widać, łańcuch znaków kończy się bajtem zerowym — jest to element standardu C/C++ o łańcuchach znaków. Więcej o łańcuchach znaków w C/C++: ?? on page ??.

W segmencie kodu _TEXT znajduje się na razie tylko jedna funkcja: main() i, jak prawie każda funkcja, zaczyna się od prologu a kończy się epilogiem ¹⁶.

Po prologu następuje wywołanie funkcji printf():

CALL _printf. Przed tym wywołaniem adres łańcucha znaków (lub wskaźnik na niego) z naszym pozdrowieniem ("Hello, world!") odkładany jest na stos, za pomocą instrukcji PUSH.

Po tym jak funkcja printf() zwraca sterowanie do funkcji main(), adres łańcucha znaków (lub wskaźnik na niego) wciąż jest na stosie. Nie jest on dalej potrzebny, więc wskaźnik wierzchołka stosu (rejestr ESP) musi zostać poprawiony.

ADD ESP, 4 oznacza: dodaj wartość 4 do rejestru ESP.

Dlaczego 4? Z racji tego, że jest to kod 32-bitowy, do przekazania adresu za pomocą stosu potrzebowaliśmy 4 bajtów. W x64 potrzebowalibyśmy 8 bajtów.

ADD ESP, 4 jest równoważne instrukcji POP register, ale nie wykorzystuje dodatkowego rejestru¹⁷. W pierwszym przypadku jedynie bezpośrednio manipulujemy na rejestrze ESP (wskaźniku wierzchołka stosu), a w drugim przypadku zdejmujemy ze stosu jeden element i odkładamy go do rejestru *register* a rejestr ESP zmienia się automatycznie.

Niektóre kompilatory, jak Intel C++ Compiler, w tej samej sytuacji mogą wygenerować POP ECX zamiast ADD (można to zaobserwować w kodzie Oracle RDBMS, gdyż jest on kompilowany właśnie tym kompilatorem). POP ECX oznacza zdjęcie elementu ze stosu i umieszczenie go w rejestrze ECX. Osiągnęliśmy taki sam efekt jak w przypadku instrukcji ADD (zmiana wskaźnika stosu), ale skutkiem ubocznym jest nadpisanie ECX.

Możliwe, że kompilator stosuje tu POP ECX dlatego, że ta instrukcja jest krótsza (1 bajt w przypadku POP kontra 3 bajty w przypadku ADD).

¹⁶Więcej o prologu i epilogu przeczytasz w sekcji (1.6 on page 40).

¹⁷Ale za to modyfikowany jest rejestr stanu

Poniżej przykład wykorzystania POP zamiast ADD z Oracle RDBMS:

Listing 1.15: Oracle RDBMS 10.2 Linux (plik app.o)

.text:0800029A	push	ebx
.text:0800029B	call	qksfroChild
.text:080002A0	pop	ecx

MSVC czasami zachowuje się tak samo.

Listing 1.16: Saper na systemie Windows 7 32-bit

.text:0102106F	push	0
.text:01021071	call	ds:time
.text:01021077	pop	ecx

Po wywołaniu printf() kod w C/C++ zawiera instrukcję return 0- zwróć 0 jako wynik funcji main().

W kodzie wygenerowanym robi to instrukcja XOR EAX, EAX.

X0R, jak można się domyśleć, to — "alternatywa wykluczająca" 18 , ale kompilatory często korzystają z niej zamiast z M0V EAX, 0 — znów dlatego, że kod operacji (opcode) jest krótszy (2 bajty w X0R kontra 5 w M0V).

Niektóre kompilatory generują SUB EAX, EAX, co oznacza *odejmij wartość w* EAX *od wartości w* EAX, co w każdym przypadku da 0.

Ostatnia instrukcja RET zwraca sterowanie do funkcji wywołującej. Zwykle jest to kod C/C++ CRT¹⁹, który z kolei zwróci sterowanie do systemu operacyjnego.

GCC

Skompilujmy teraz ten sam kod za pomocą kompilatora GCC 4.4.1 na systemie Linux: gcc 1.c -o 1. Następnie za pomocą deasemblera IDA podejrzymy wynik kompilacji funkcji main(). IDA, jak i MSVC, pokazują kod w składni Intela²⁰.

Listing 1.17: Kod w programie IDA

```
main
                proc near
var_10
                = dword ptr -10h
                         ebp
                push
                mov
                         ebp, esp
                         esp, 0FFFFFF0h
                and
                sub
                         esp, 10h
                         eax, offset aHelloWorld ; "hello, world\n"
                moν
                         [esp+10h+var_10], eax
                mov
                         _printf
                call
                mov
                         eax, 0
```

¹⁸Wikipedia

¹⁹C Runtime library

²⁰ Można zmusić również GCC do generowania listingów w tym formacie, za pomocą opcji -S-masm=intel.

[leave	•
	retn	
main	endp	

Wynik jest prawie taki sam. Adres łańcucha znaków hello, world, leżącego w segmencie danych, najpierw zapisywany jest do EAX, a później odkładany na stos. Dodatkowo w prologu funkcji widzimy AND ESP, 0FFFFFF0h — ta instrukcja wyrównuje ESP do granicy 16 bajtów. Dzięki temu wszystkie wartości na stosie będą również wyrównane w taki sam sposób (procesor pracuje efektywniej z adresami wyrównanymi do granicy 4 lub 16 bajtów.).

SUB ESP, 10h alokuje na stosie 16 bajtów. Choć tutaj wystarczyłyby 4 bajty, co będzie widoczne dalej.

Dzieje się tak dlatego, że ilość przydzielanego miejsca na stosie jest również wyrównywana do granicy 16 bajtów.

Adres łańcucha znaków (lub wskaźnik na niego) jest zatem odkładany prosto na stos, bez wykorzystywania instrukcji PUSH. var_10 jest jednocześnie zmienną lokalną i argumentem dla funkcji printf(). Więcej na ten temat dowiesz się później.

Następnie jest wywoływana funkcja printf().

W odróżnieniu od MSVC, GCC przy kompilacji z wyłączoną optymalizacją generuje MOV EAX, 0 zamiast krótszego kod operacji (opcode).

Ostatnia instrukcja LEAVE — jest analogiczna do pary instrukcji MOV ESP, EBP i POP EBP — jest to powrót wskaźnika stosu i rejestru EBP do stanu początkowego. Jest to niezbędne, ponieważ na początku funkcji modyfikowaliśmy rejestry ESP i EBP (za pomocą MOV EBP, ESP / AND ESP, ...).

GCC: składnia AT&T

Sprawdźmy, jak będzie wyglądał listing w składni AT&T, która jest bardziej popularna w świecie UNIXa.

Listing 1.18: Kompilujemy za pomocą GCC 4.7.3

```
gcc -S 1_1.c
```

Otrzymamy taki plik:

Listing 1.19: GCC 4.7.3

```
.file "1_1.c"
    .section .rodata
.LC0:
    .string "hello, world\n"
    .text
    .globl main
    .type main, @function
main:
.LFB0:
    .cfi_startproc
    pushl %ebp
```

```
.cfi def cfa offset 8
        .cfi_offset 5, -8
        movl
                %esp, %ebp
        .cfi_def_cfa_register 5
        andl
                $-16, %esp
        subl
                $16, %esp
                $.LCO, (%esp)
        movl
        call
                printf
        movl
                $0, %eax
        leave
        .cfi_restore 5
        .cfi_def_cfa 4, 4
        .cfi endproc
.LFE0:
                main, .-main
        .size
        .ident "GCC: (Ubuntu/Linaro 4.7.3-lubuntu1) 4.7.3"
        .section
                         .note.GNU-stack, "", @progbits
```

Listing zawiera wiele makr (rozpoczynających się od kropki). Na razie nie są one dla nas istotne.

Zignorujmy je wszystkie, (za wyjątkiem .string, które koduje sekwencję znaków zakończonych znakiem null — tak jak łańcuchy znaków w C++). Otrzymamy wtedy: 21.

Listing 1.20: GCC 4.7.3

```
.LC0:
        .string "hello, world\n"
main:
        pushl
                 %ebp
        movl
                 %esp, %ebp
        andl
                 $-16, %esp
        subl
                 $16, %esp
        movl
                 $.LC0, (%esp)
        call
                 printf
                 $0, %eax
        movl
        leave
        ret
```

Główne różnice między składnią Intela a AT&T:

Operandy są zapisywane w odwotnej kolejności

```
W składni Intela:
<instrukcja> <operand docelowy> <operand źródłowy>.
W składni AT&T:
<instrukcja> <operand źródłowy> <operand docelowy>.
```

Istnieje łatwy sposób na zapamiętanie tej różnicy: kiedy pracujecie ze składnią Intela — możecie w głowie postawić znak równości (=) między operandami, a

²¹Eliminację zbędnych makr można uzyskać za pomocą opcji GCC: *-fno-asynchronous-unwind-tables*

- z AT&T strzałkę w prawo $(\rightarrow)^{22}$.
- AT&T: Przed nazwami rejestrów stawia się symbol (%), a przed liczbami (\$). Zamiast nawiasów kwadratowych używa się okrągłych.
- AT&T: Do każdej instrukcji dodaje się przyrostek określający typ danych:
 - q quad (64 bity)
 - I long (32 bity)
 - w word (16 bitów)
 - b byte (8 bitów)

Wracając do wyniku kompilacji: jest on niemal identyczny do tego, który prezentuje IDA. Jedna drobnostka: 0FFFFFFF0h jest zapisywane jako \$-16. Oba zapisy oznaczją dokładnie to samo: 16 w sytemie dziesiętnym to 0x10 w szesnastkowym. -0x10 to 0xFFFFFFF0 (dla liczb całkowitych 32-bitowych) 23 .

Zwracana wartość jest ustawiany na 0 za pomocą zwykłej instrukcji MOV, a nie XOR. MOV zapisuje wartość do rejestru. Nazwa tej instrukcji nie jest do końca poprawna (wartości nie są przemieszczane, tylko kopiowane). W innych architekturach instrukcja ta nosi nazwę "LOAD", "STORE" lub podobną.

Korekcja (patching) łańcuchów znaków (Win32)

Możemy w łatwy sposób znaleźć łańcuch znaków "hello, world" w pliku wykonywalnym za pomocą Hiew:

```
Hiew: hw_spanish.exe
                             PE+.00000001`40003000 Hiew 8.02
  C:\tmp\hw spanish.exe
      .400025F0:
       .40003000:
       68 65 6C 6C-6F 2C 20 77-6F 72 6C 64-0A 00 00 00
                                     hello, world⊡
.40003010:
      01 00 00 00-FE FF FF FF-FF FF FF-00 00 00 00
.40003020:
       32 A2 DF 2D-99 2B 00 00-CD 5D 20 D2-66 D4 FF FF
                                     2ó■-Ö+
       40003030:
40003040:
```

Rysunek 1.1: Hiew

Możemy przetłumaczyć naszą wiadomość na język hiszpański:

²²W niektórych standardowych funkcjach biblioteki C (memcpy(), strcpy(), ...) również korzysta się z kolejności argumentów jak w składni Intela: najpierw wskaźnik na miejsce docelowe w pamięci, następnie wskaźnik na miejsce źródłowe.

²³W kodowaniu U2 - https://pl.wikipedia.org/wiki/Kod_uzupe%C5%82nie%C5%84_do_dw%C3%B3ch i kolejności bajtów big endian - https://pl.wikipedia.org/wiki/Kolejno%C5%9B%C4%87_bajt%C3%B3w

```
Hiew: hw_spanish.exe

☑FWO EDITMODE

                              PE+ 00000000 0000120D Hiew 8.02
  C:\tmp\hw_spanish.exe
       000011F0:
       00001200:
       68 6F 6C 61-2C 20 6D 75-6E 64 6F 0A-00 00 00 00
                                       hola, mundo⊡
00001210:
       01 00 00 00-FE FF FF FF-FF FF FF-00 00 00 00
                                       26^{-0} - 0 + = 1 \pi f^{\perp}
00001220:
       32 A2 DF 2D-99 2B 00 00-CD 5D 20 D2-66 D4 FF FF
       00001230:
```

Rysunek 1.2: Hiew

Tekst w języku hiszpańskim jest o 1 bajt krótszy od tekstu w języku angielskim, dlatego dodajemy na koniec bajt 0x0A (\n) i bajt zerowy.

Działa.

A co jeśli chcielibyśmy wstawić dłuższy tekst? Po oryginalnym tekście w języku angielskim widzimy kilka bajtów zerowych. Trudno powiedzieć czy można je nadpisać: mogą (ale nie muszą!) one być wykorzystywane gdzieś w kodzie CRT. Tak czy inaczej, możemy je nadpisywać tylko jeśli naprawdę wiemy co robimy.

Korekcja łańcuchów znaków (Linux x64)

Spróbujmy edytować plik wykonywalny systemu Linux x64, korzystając z rada.re:

Listing 1.21: Sesja w rada.re

```
dennis@bigbox ~/tmp % gcc hw.c
dennis@bigbox ~/tmp % radare2 a.out
-- SHALL WE PLAY A GAME?
[0x00400430] > / hello
Searching 5 bytes from 0x00400000 to 0x00601040: 68 65 6c 6c 6f
Searching 5 bytes in [0x400000-0x601040]
0x004005c4 hit0 0 .HHhello, world;0.
[0x00400430] > s 0x004005c4
[0x004005c4] > px
- offset -
           0 1
                23 45 67 89 AB CD EF
                                                   0123456789ABCDEF
0x004005c4
           6865 6c6c 6f2c 2077 6f72 6c64 0000 0000
                                                   hello, world....
                                                   ...;0........
0x004005d4
           011b 033b 3000 0000 0500 0000 1cfe ffff
0x004005e4
           7c00 0000 5cfe ffff 4c00 0000 52ff ffff
                                                   |...\...L...R...
0x004005f4
           a400 0000 6cff ffff c400 0000 dcff ffff
                                                   ....l...........
0x00400604
           0c01 0000 1400 0000 0000 0000 017a 5200
                                                   ....zR.
           0178 1001 1b0c 0708 9001 0710 1400 0000
0x00400614
                                                   .x..........
           1c00 0000 08fe ffff 2a00 0000 0000 0000
0x00400624
                                                   *.....
           0000 0000 1400 0000 0000 0000 017a 5200
0x00400634
           0178 1001 1b0c 0708 9001 0000 2400 0000
0x00400644
                                                   .x....$...
```

```
1c00 0000 98fd ffff 3000 0000 000e 1046
0x00400654
                                                    ........0....F
0x00400664
           0e18 4a0f 0b77 0880 003f 1a3b 2a33 2422
                                                    ..J..w...?.;*3$"
0x00400674
           0000 0000 1c00 0000 4400 0000 a6fe ffff
                                                    .......D......
0x00400684 1500 0000 0041 0e10 8602 430d 0650 0c07
                                                    ....A....C..P...
0x00400694 0800 0000 4400 0000 6400 0000 a0fe ffff
                                                    ....D...d.....
0x004006a4 6500 0000 0042 0e10 8f02 420e 188e 0345
                                                    e....B....E
0x004006b4 0e20 8d04 420e 288c 0548 0e30 8606 480e . ..B.(..H.0..H.
[0x004005c4] > oo+
File a.out reopened in read-write mode
[0x004005c4] > w hola, mundo\x00
[0x004005c4] > q
dennis@bigbox ~/tmp % ./a.out
hola, mundo
```

Co tu się dzieje: szukam łańcucha znaków "hello", korzystając z komendy /, następnie ustawiam kursor (seek w terminologii rada.re) pod ten adres. Następnie chcę się upewnić, że jest to rzeczywiście poszukiwane miejsce: px wyświetla bajty pod tym adresem. oo+ przełącza rada.re w tryb odczytu/zapis. w zapisuje łańuch znaków ASCII w miejscu kursora (seek). Warto zauważyć \00 na końcu, jest to bajt zerowy. q wyłącza rada.re.

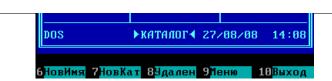
Prawdziwa historia crackowania oprogramowania

Program do przetwarzania obrazów, niezarejestrowany, dodawał do pliku znak wodny, na przykład napis "This image was processed by evaluation version of [nazwa oprogramowania]" Spróbowaliśmy najprostszego rozwiązania: znaleźliśmy ten tekst w pliku wykonywalnym i zastąpiliśmy go spacjami. Znak wodny zniknął. Ogólnie rzecz biorąc, wciąż był nakładany przez program. Za pomocą funkcji Qt, znak wodny wciąż był dodawany do obrazu. Ale dodawanie spacji nie zmieniało go w żaden sposób...

Tłumaczenie oprogramowania za czasów MS-DOS

Sposób przedstawiony wyżej był powszechnie wykorzystywany w latach 80. i 90. przy tłumaczeniu oprogramowania pod MS-DOS na język rosyjski. Ta technika może być wykorzystywana przy braku wiedzy na temat kodu maszynowego i formatów plików wykonywalnych. Nowy łańcuch znaków nie powinien być dłuższy niż stary, ponieważ istnieje ryzyko nadpisania innej wartości albo fragmentu kodu wykonywalnego

Rosyjskie słowa i zdania zwykle są trochę dłuższe od angielskich odpowiedników, dlatego *przetłumaczone* oprogramowanie zawierało sporo dziwnych akronimów (skrótowców) i trudnych do zrozumienia skrótów.



Rysunek 1.3: Norton Commander 5.51 przetłumaczony na język rosyjski

Prawdopodobnie sytuacja wyglądała podobnie z tłumaczeniem na inne języki.

W przypadku łańcuch znaków w Delphi, rozmiar również musi być poprawiony, jeśli zachodzi taka potrzeba.

1.5.2 x86-64

MSVC: x86-64

Przyjrzyjmy się wynikom kompilacji 64-bitowego MSVC:

Listing 1.22: MSVC 2012 x64

```
$SG2989 DB
                 'hello, world', OAH, OOH
main
        PR0C
                 rsp, 40
        sub
                 rcx, OFFSET FLAT: $SG2989
        lea
        call
                 printf
        xor
                 eax, eax
        add
                 rsp, 40
        ret
main
        ENDP
```

W x86-64 wszystkie rejestry zostały rozszerzone do 64 bitów i ich nazwy zyskały prefiks R-. Żeby jak najrzadziej korzystać ze stosu (inaczej mówiąc, jak najmniej korzystać z pamięci cache i pamięci zewnętrznej), istnieje popularna metoda przekazywania argumentów funkcji przez rejestry (fastcall) ?? on page ??. Tzn. część argumentów funkcji jest przekazywana przez rejestry a część — przez stos. W Win64 pierwsze 4 argumenty funkcji są przekazywane przez rejestry RCX, RDX, R8 i R9. Widać to w powyższym przykładzie: wskaźnik na argument funkcji printf() (łańcuch znaków) teraz jest przekazywany nie przez stos, a przez rejestr RCX. Wskaźniki są teraz 64-bitowe, więc są przekazywane przez przez 64-bitowe rejestry (mające prefiks R-). Ale dla wstecznej kompatybilności można adresować również młodsze 32 bity rejestrów poprzez prefiks E-. W ten oto sposób wygląda rejestr RAX/EAX/AX/AL w x86-64:

Number bajtu:							
7	6	5	4	3	2	1	0
RAX ^{×64}							
EAX							
	AX					X	
						AH	AL

Funkcja main() zwraca wartość typu *int*, który w C/C++, dla większej kompatybilności, pozostał 32-bitowy. Właśnie dlatego na końcu funkcji main() zeruje się nie RAX, a EAX, czyli 32-bitową część rejestru. Dodatkowo na stosie lokalnym jest zarezerwowanych 40 bajtów. Jest to tzw. "shadow space", który będzie omawiany później: 1.14.2 on page 134.

GCC: x86-64

Przyjrzyjmy się wynikom kompilacji GCC na 64-bitowym systemie Linux:

Listing 1.23: GCC 4.4.6 x64

```
.string "hello, world\n"
main:

sub    rsp, 8
    mov    edi, OFFSET FLAT:.LCO; "hello, world\n"
    xor    eax, eax; liczba użytych rejestrów wektorowych XMMO-XMM7
    call    printf
    xor    eax, eax
    add    rsp, 8
    ret
```

Na Linuksie, *BSD i Mac OS X w architekturze x86-64 argumenty funkcji także przekazuje się przez rejestry [Michael Matz, Jan Hubicka, Andreas Jaeger, Mark Mitchell, System V Application Binary Interface. AMD64 Architecture Processor Supplement, (2013)] ²⁴.

6 pierwszych argumentów jest przekazywanych przez rejestry RDI, RSI, RDX, RCX, R8 i R9, a reszta — przez stos.

Wskaźnik na łańcuch znaków jest przekazywany przez EDI (32-bitową część rejestru). Dlaczego nie użyto 64-bitowego RDI?

Warto pamiętać, że w 64-bitowym trybie wszystkie instrukcje M0V, zapisujące cokolwiek do młodszej 32-bitowej części rejestru, zerują starsze 32 bity (jest to opisane w dokumentacji Intela: 7.1.4 on page 150). Z tego powodu instrukcja M0V EAX, 011223344h poprawnie zapisze tę wartość do RAX, a starsze bity się wyzerują.

Jeślibyśmy podejrzeli w deasemblerze IDA skompilowany plik (.o), to zobaczylibyśmy kody operacji (opcode) wszystkich instrukcji ²⁵:

Listing 1.24: GCC 4.4.6 x64

```
.text:0000000004004D0
                                        main proc near
.text:00000000004004D0 48 83 EC 08
                                        sub
                                                rsp, 8
.text:00000000004004D4 BF E8 05 40 00
                                                edi, offset format; "hello,
                                        mov
.text:00000000004004D9 31 C0
                                        xor
                                                eax, eax
.text:00000000004004DB E8 D8 FE FF FF
                                        call
                                                printf
.text:00000000004004E0 31 C0
                                        xor
                                                eax, eax
.text:00000000004004E2 48 83 C4 08
                                        add
                                                rsp, 8
```

²⁴Dostep także przez https://software.intel.com/sites/default/files/article/402129/ mpx-linux64-abi.pdf

²⁵Trzeba włączyć tę opcję w **Options** → **Disassembly** → **Number of opcode bytes**

.text:0000000004004E6 C3	retn	1
.text:0000000004004E6	main endp	

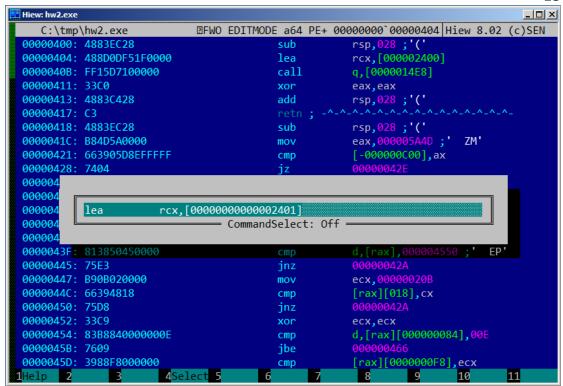
Jak widać, instrukcja MOV pod adresem 0x4004D4, która zapisuje do EDI, zajmuje 5 bajtów. Ta sama instrukcja, zapisująca 64-bitową wartość do RDI, zajmuje 7 bajtów. Najwyraźniej GCC stara się zaoszczędzić trochę miejsca. GCC jest również pewne, że segment danych, w którym przechowywany jest łańcuch znaków, nigdy nie będzie zaalokowany pod adresem powyżej 4GiB.

Widać również, że rejestr EAX został wyzerowany przed wywołaniem funkcji printf(). Zgodnie ze standardem ABI²⁶ opisanym wyżej, w *NIX dla x86-64 w EAX jest ustawiana liczba użytych rejestrów wektorowych do przekazania argumentów zmiennoprzecinkowych, jeśli funkcja może przyjmować zmienną liczbę argumentów. Nie został wykorzystany żaden taki rejestr, a printf() jest funkcją o zmiennej liczbie argumentów, więc należy ustawić EAX na 0.

Łatanie (patching) adresów (Win64)

Jeśli nasz przykład skompilujemy za pomocą MSVC 2013 z opcją /MD (dynamiczne linkowanie, mniejszy plik wykonywalny dzięki zewnętrznym odwoływaniom do bibliotek MSVCR*.DLL), funkcja main() będzie łatwa do znalezienia, gdyż wystąpi jako pierwsza:

²⁶Interfejs binarny aplikacji (Application Binary Interface)



Rysunek 1.4: Hiew

Możemy spróbować inkrementować adres:

```
Hiew: hw2.exe
    C:\tmp\hw2.exe
                                □FUO ----- a64 PE+.000000001 4000100B Hiew 8.02 (c)SEN
.40001000: 4883EC28
                                                            rsp,028;'('
                                                             rcx,[00000001 40003001]; 'ello, w
.40001004: 488D0DF61F0000
                                               lea.
.4000100B: FF15D7100000
                                               call
                                                            printf
.40001011: 33C0
.40001013: 4883C428
                                                            eax, eax
                                                            rsp,028 ;'('
                                               add
.40001017: C3
.40001018: 4883EC28
                                                             rsp,028;'('
                                               sub
.4000101C: B84D5A0000
                                                             eax,0000005A4D ;' ZM'
                                               mov
.40001021: 663905D8EFFFFF
                                                             [00000001`40000000],ax
                                               cmp
.40001028: 7404
.4000102A: 33C9
                                                            ecx,ecx
.4000102C: EB38
                                               jmps
.4000102E: 48630507F0FFFF
                                              2movsxd
                                                            rax,d,[00000001~4000003C] --24
.40001035: 488D0DC4EFFFFF
                                               lea
                                                            rcx,[00000001`40000000]
                                               add
.4000103C: 4803C1
                                                            rax,rcx
                                                            d,[rax],000004550; EP'
.00000001`4000102A --E5
ecx,00000020B
[rax][018],cx
.4000103F: 813850450000
                                               cmp
.40001045: 75E3
                                               jnz
.40001047: B90B020000
                                               mov
.4000104C: 66394818
                                               CMD
.40001050: 75D8
                                                            .00000001~4000102A --25
                                               jnz
.40001052: 33C9
                                                            ecx,ecx
.40001054: 83B8840000000E
                                                            d,[rax][000000084],00E
                                               CMD
                                                            .00000001`40001066 --<u>B</u>3
[rax][0000000F8],ecx
.4000105B: 7609
                                               jbe
 4000105D: 3988F8000000
                                               cmp
       2PutBlk 3Edit
                                                              8Header 9Files 10Ouit
```

Rysunek 1.5: Hiew

Hiew wyświetla teraz "ello, world" (obok instrukcji 'LEA RCX...', która ładuje adres łańucha znaków, przekazywany jako argument do funkcji printf()). Kiedy uruchomimy plik wykonywalny, właśnie ten ciąg znaków zostnie wypisany na ekran.

Wyświetlanie różnych ciągów znaków z pliku wykonywalnego (Linux x64)

Plik wykonywalny po skompilowaniu za pomocą GCC 5.4.0 na systemie Linux x64, ma wiele innych łańcuchów znaków: głównie są to nazwy importowanych funkcjii oraz nazwy bibliotek.

Uruchamiamy objdump, żeby podejrzeć zawartość wszystkich sekcji skompilowanego pliku:

Łatwo przekazać adres łańcucha znaków "/lib64/ld-linux-x86-64.so.2" do funkcji printf():

```
#include <stdio.h>
int main()
{
    printf(0x400238);
    return 0;
}
```

Trudno uwierzyć, ale program wyświetli ten łańcuch znaków na ekran.

Jeśli zmienimy adres na 0x400260, to wyświetli się napis "GNU". Adres jest prawidłowy dla konkretnej wersji GCC, GNU toolset, etc. W waszym systemie plik wykonywalny może wyglądać trochę inaczej i wszystkie adresy także będą inne. Podobnie, usuwanie lub dodawanie kodu do kodu źródłowego może przesunąć wszystkie adresy w programie wykonywalnym do przodu lub do tyłu.

1.5.3 ARM

Do eksperymentów z ARM skorzystamy z kilku kompilatorów:

- popularnego w systemach wbudowanych Keil Release 6/2013,
- Apple Xcode 4.6.3 IDE z kompilatorem LLVM-GCC 4.2 ²⁷
- GCC 4.9 (Linaro) (dla ARM64), jest dostępny w postaci pliku wykonywalnego dla win32 na http://www.linaro.org/projects/armv8/.

Wszędzie w tej książce, jeżeli zaznaczono inaczej, mówimy o 32-bitowym ARM (włączając tryb Thumb i Thumb-2). 64-bitowym ARM będzie oznaczony explicite jako ARM64.

Nieoptymalizujący Keil 6/2013 (tryb ARM)

Na początek skompilujmy nasz przykład za pomocą Keil:

```
armcc.exe --arm --c90 -00 1.c
```

Kompilator *armcc* generuje listing w asemblerze w składni Intela. Listing zawiera niektóre wysokopoziomowe makra, związane z ARM ²⁸. Nas interesują prawdziwe instrukcje, dlatego zobaczmy jak wygląda skompilowany kod w programie IDA.

²⁷W rzeczywistości Apple Xcode 4.6.3 korzysta z GCC jako front-endu i z LLVM jako generatora kodu binarnego

²⁸Na przykład listing zawiera instrukcję PUSH/P0P, których nie ma w trybie ARM

Listing 1.25: Nieoptymalizujący Keil 6/2013 (tryb ARM) IDA

```
.text:00000000
                           main
.text:00000000 10 40 2D E9
                              STMFD
                                      SP!, {R4,LR}
.text:00000004 1E 0E 8F E2
                              ADR
                                      RO, aHelloWorld; "hello, world"
.text:00000008 15 19 00 EB
                              BL
                                       2printf
.text:0000000C 00 00 A0 E3
                              MOV
                                      R0, #0
                              LDMFD
.text:00000010 10 80 BD E8
                                      SP!, {R4, PC}
.text:000001EC 68 65 6C 6C+aHelloWorld DCB "hello, world",0
                                                                 ; DATA XREF:
   main+4
```

Widać, że każda instrukcja ma rozmiar 4 bajtów — zgodnie z oczekiwaniami, ponieważ kompilowaliśmy nasz kod dla trybu ARM, a nie Thumb.

Pierwsza instrukcja, STMFD SP!, {R4,LR}²⁹, działa podobnie jak instrukcja PUSH w x86: odkłada wartości dwóch rejestrów (R4 i LR) na stos.

W rzeczy samej, kompilator *armcc*, generując listing, wstawił tam dla uproszczenia instrukcję PUSH {r4,lr}. Nie jest to do końca precyzyjne, ponieważ instrukcja PUSH dostępna jest w trybie Thumb. By uniknąć dezorientacji, wygenerowany kod maszynowy podglądamy w programie IDA.

Instrukcja najpierw zmniejsza SP³¹, by wskazywał na miejsce na stosie dostępne do zapisu nowych wartości, następnie zapisuje wartości rejestrów R4 i LR pod adres w pamięci, na który wskazuje zmodyfikowany rejestr SP.

Podobnie jak PUSH w trybie Thumb, ta instrukcja pozwala na odkładanie na stos wartości kilku rejestrów na raz, co może być bardzo wygodne.

Przy okazji, takie zachowanie nie ma swojego odpowiednika w x86.

Można zauważyć, że STMFD jest generalizacją instrukcji PUSH (czyli rozszerza jej możliwości), dlatego że może operować na różnych rejestrach, a nie tylko na SP. Inaczej mówiąc, z STMFD można korzystać przy zapisie wartości kilku rejestrów we wskazane miejsce w pamięci.

Instrukcja ADR R0, aHelloWorld dodaje/odejmuje wartość w rejestrze PC³² (R0) do-/od przesunięcia, w którym jest przechowywany łańcuch znaków hello, world. Dlaczego użyto tutaj rejestru PC? Jest to tzw. "position-independent code" ³³.

Taki kod można uruchomić z dowolnego miejsca w pamięci. Inaczej mówiąc, jest to adresowanie względne, względem rejestru PC. W kodzie operacji (opcode) instrukcji ADR jest zapisane przesunięcie (offset) między adresem tej instrukcji a adresem łańcucha znaków. Przesunięcie zawsze jest stałe, niezależnie od tego, w które miejsce OS załadował nasz kod. Dlatego wszystko czego potrzebujemy — to dodanie adresu bieżącej instrukcji (z PC), żeby otrzymać adres bezwględny łańcucha znaków.

Instrukcja BL __2printf³⁴ wywołuje funkcję printf(). Działanie tej instrukcji przebiega w 2 krokach:

²⁹STMFD³⁰

³¹wskaźnik stosu. SP/ESP/RSP w x86/x64. SP w ARM.

³²Program Counter. IP/EIP/RIP w x86/64. PC w ARM.

³³Jest to szerzej omówione w kolejnym rozdziale (?? on page ??)

³⁴Branch with Link

- zapisz adres występujący po instrukcji BL (0xC) do rejestru LR,
- przekaż sterowanie do funkcji printf(), zapisując jej adres do rejestru PC.

Kiedy funkcja printf() zakończy działanie, musi wiedzieć gdzie zwrócić sterowanie. Dlatego każda funkcja, kończąc pracę, zwraca sterowanie pod adres zapisany w rejestrze LR.

Na tym polega główna różnica między "czystymi" procesorami RISC, jak ARM, a procesorami CISC³⁵ w rodzaju x86, gdzie adres powrotu zwykle jest odkładany na stos. Przeczytasz o tym więcej w kolejnym rozdziale (1.9 on page 42).

Dodatkowo nie jest możliwe zakodowanie 32-bitowego adresu bezwzględnego (lub przesunięcia) w 32-bitowej instrukcji BL, ponieważ ma ona miejsce tylko dla 24 bitów. Jak zapewne pamiętasz, wszystkie instrukcje w trybie ARM mają długość 4 bajtów (32 bitów) i mogą się znajdować tylko pod adresem wyrównanym do krotności 4 bajtów. Oznacza to, że ostatnich 2 bitów (które są zawsze zerowe) można nie kodować. Ostatecznie zostaje nam 26 bitów na zakodowanie przesunięcia. Odpowiada to zakresowi $current\ PC \pm \approx 32M$.

Następna instrukcja MOV R0, #0³⁶ po prostu zapisuje 0 do rejestru R0. To dlatego, że nasza funkcja zwraca 0, a wartości zwracane z funkcji zapisywane są do R0.

Ostatnia instrukcja to LDMFD SP!, R4,PC³⁷. Pobiera ona wartość ze stosu (lub z pamięci), zapisuje do R4 i PC oraz zwiększa wskaźnik stosu SP. Działa podobnie jak instrukcja P0P.

Notabene, pierwsza instrukcja STMFD odłożyła na stos wartości z rejestrów R4 i LR, ale teraz zostały one przywrócone do R4 i PC, dzięki instrukcji LDMFD.

Jak już wiemy, rejestr LR zawiera adres w pamięci, pod który funkcja zwróci sterowanie po zakończeniu swojej pracy. Pierwsza instrukcja odkłada tę wartość na stos, ponieważ ten sam rejestr zostanie wykorzystany przez naszą funkcję main(), gdy wywoła ona funkcję printf().

Na końcu funkcji ta wartość zapisywana jest do rejestru PC, w ten sposób przekazując sterowanie tam, skąd została wywołana.

Z reguły funkcja main() jest funkcją główną w C/C++, więc zarządzanie zostanie zwrócone do loadera w OS, lub gdzieś do CRT, lub w jeszcze inne, podobne, miejsce.

Wszystko to pozwala pozbyć się ręcznego wywoływania BX LR (skok pod adres z rejestru LR) na samym końcu funcji.

DCB — dyrektywa asemblera, opisująca tablicę bajtów bądź ciąg znaków ASCII, podobna do dyrektywy DB w x86

Nieoptymalizujący Keil 6/2013 (tryb Thumb)

Skompilujmy ten sam przykład za pomocą Keil w trybie Thumb:

```
armcc.exe --thumb --c90 -00 1.c
```

³⁵Complex Instruction Set Computing

³⁶Oznacza MOV

³⁷LDMFD³⁸ jest instrukcją odwrotną do STMFD

Otrzymamy (listing z programu IDA):

Listing 1.26: Nieoptymalizujący Keil 6/2013 (tryb Thumb) + IDA

```
.text:00000000
                           main
.text:00000000 10 B5
                              PUSH
                                       {R4,LR}
.text:00000002 C0 A0
                                       RO, aHelloWorld; "hello, world"
                              ADR
.text:00000004 06 F0 2E F9
                              BI
                                        _2printf
.text:00000008 00 20
                              MOVS
                                       R0, #0
                                       {R4,PC}
.text:0000000A 10 BD
                              P0P
.text:00000304 68 65 6C 6C+aHelloWorld DCB "hello, world",0
                                                                  ; DATA XREF:
   main+2
```

Od razu można zauważyć 2 bajtowe (16-bitowe) kody operacji (opcode) — jest to już wcześniej wspomniany tryb Thumb.

Wyjątkiem jest instrukcja BL, która składa się z dwóch 16-bitowych instrukcji. W jednym 16-bitowym kodzie operacji (opcode) jest za mało miejsca na przesunięcie, po którym znajduje się funkcja printf(). Dlatego pierwsza 16-bitowa instrukcja ładuje starsze 10 bitów przesunięcia, a druga — młodsze 11 bitów przesunięcia.

Skoro wszystkie instrukcje w trybie Thumb są 2-bajtowe (16-bitowe), to sytuacja, w której instrukcja zaczyna się pod adresem nieparzystym, jest niemożliwa.

Wniosek z tego jest taki, że ostatniego bitu adresu można nie kodować. Dzięki temu instrukcja BL w trybie Thumb może zakodować adres z przedziału $current\ PC \pm \approx 2M$.

Co do pozostałych instrukcji: PUSH i POP działają jak opisane wyżej STMFD/LDMFD, tyle że rejestr SP nie jest tu jawnie wskazany. ADR działa dokładnie tak samo jak w poprzednim przykładzie. MOVS zapisuje wartość 0 do rejestru R0, by funkcja zwróciła zero.

Optymalizujący Xcode 4.6.3 (LLVM) (tryb ARM)

Xcode 4.6.3 bez włączonego trybu optymalizacji generuje za dużo zbędnego kodu, dlatego włączymy optymalizację (flaga -03), dzięki czemu liczba instrukcji będzie tak mała, jak to możliwe.

Listing 1.27: Optymalizujący Xcode 4.6.3 (LLVM) (tryb ARM)

```
_hello_world
 text:000028C4
text:000028C4 80 40 2D E9
                              STMFD
                                               SP!, {R7,LR}
                                               R0, #0x1686
 text:000028C8 86 06 01 E3
                              MOV
                                               R7, SP
R0, #0
 text:000028CC 0D 70 A0 E1
                              MOV
 text:000028D0 00 00 40 E3
                              MOVT
                                               R0, PC, R0
 text:000028D4 00 00 8F E0
                              ADD
 text:000028D8 C3 05 00 EB
                              BL
                                                puts
                                               R0, #0
 text:000028DC 00 00 A0 E3
                              MOV
text:000028E0 80 80 BD E8
                              LDMFD
                                               SP!, {R7, PC}
 cstring:00003F62 48 65 6C 6C+aHelloWorld_0 DCB "Hello world!",0
```

Instrukcje STMFD i LDMFD są już nam znane.

Instrukcja MOV zapisuje liczbę 0x1686 do rejestru RO — jest to przesunięcie, wskazujące na łańcuch znaków "Hello world!".

Rejestr R7 (wg standardu [iOS ABI Function Call Guide, (2010)]³⁹) przechowuje wskaźnik ramki stosu (frame pointer). Będzie to omówione później.

Instrukcja MOVT R0, #0 (MOVe Top) zapisuje 0 do starszych 16 bitów rejestru. Zwykła instrukcja MOV w trybie ARM może zapisywać tylko do młodszych 16 bitów rejestru, z uwagi na długość instrukcji.

Warto pamiętać, że w trybie ARM kody operacji (opcode) instrukcji są ograniczone do 32 bitów. Nie ma to oczywiście wpływu na przenoszenie wartości między rejestrami. Z tego powodu do zapisywania do starszych bitów (od 16 do 31, włącznie) istnieje dodatkowa instrukcja MOVT. Tutaj jej użycie jest zbędne, gdyż MOV R0, #0x1686 i tak by wyzerowała starszą część rejestru. Możliwe, że jest to niedociągnięcie kompilatora.

Instrukcja ADD R0, PC, R0 dodaje PC do R0 żeby wyliczyć adres bezwzględny łańcucha znaków "Hello world!". Jak już wiemy, jest to "position-independent code", dlatego taka korekta jest niezbędna.

Instrukcja BL wywołuje puts() zamiast printf().

LLVM zamienił wywołanie printf() na puts(). Działanie printf() z jednym argumentem jest prawie równoznaczna puts().

Prawie, gdyż obie funkcje zadziałają identycznie, jeśli łańcuch znaków nie będzie zawierał sekwencji opisujących format, zaczynających się od znaku %. Jeśli będzie, wtedy wyniki ich pracy będą różne. ⁴⁰.

Dlaczego kompilator zamienił wywoływaną funkcję? Prawdopodobnie dlatego, że funkcja puts() jest szybsza ⁴¹. Najwidoczniej dlatego, że puts() przekazuje znaki na stdout, nie porównując ich ze znakiem %.

Dalej jest już znana instrukcja MOV RO, #0, ustawiająca O jako wartość zwracaną.

Optymalizujący Xcode 4.6.3 (LLVM) (tryb Thumb-2)

Domyślnie Xcode 4.6.3 wygeneruje trybie Thumb-2 podobny kod:

Listing 1.28: Optymalizujący Xcode 4.6.3 (LLVM) (tryb Thumb-2)

text:00002B6C		_hello_world	1
text:00002B6C	80 B5	PUSH	{R7,LR}
text:00002B6E	41 F2 D8 30	MOVW	R0, #0x13D8
text:00002B72	6F 46	MOV	R7, SP
text:00002B74	C0 F2 00 00	MOVT.W	R0, #0
text:00002B78	78 44	ADD	RO, PC
text:00002B7A	01 F0 38 EA	BLX	_puts
text:00002B7E	00 20	MOVS	R0, #0
text:00002B80	80 BD	P0P	{R7,PC}

³⁹Dostep także przez http://developer.apple.com/library/ios/documentation/Xcode/ Conceptual/iPhoneOSABIReference/iPhoneOSABIReference.pdf

⁴⁰Należy również zauważyć, że puts () nie potrzebuje znaku nowej linii '\n' na końcu łańcucha, dlatego został on pominięty.

⁴¹ciselant.de/projects/gcc_printf/gcc_printf.html

```
...
__cstring:00003E70 48 65 6C 6C 6F 20+aHelloWorld DCB "Hello world!",0xA,0
```

Instrukcje BL i BLX w trybie Thumb są kodowane jako para 16-bitowych instrukcji. W Thumb-2 te zastępcze kody operacji (opcode) rozszerzono tak, by instrukcje mogły być zakodowane jako 32-bitowe.

Można to łatwo zauważyc, gdyż w w trybie Thumb-2 wszystkie 32-bitowe instrukcje zaczynają się od 0xFx lub 0xEx.

Jednak na listingu w programie IDA bajty kodu operacji (opcode) są zamienione miejscami. W procesorze ARM instrukcje są kodowane w następujący sposób: najpierw podaje się ostatni bajt, potem pierwszy (dla trybów Thumb i Thumb-2), lub, dla trybu ARM, najpierw czwarty bajt, następnie trzeci, drugi i pierwszy (z uwagi na różną kolejność bajtów).

Bajty są wypisywane w listingach IDA w następującej kolejności:

- dla trybów ARM i ARM64: 4-3-2-1;
- dla trybu Thumb: 2-1;
- dla pary 16-bitowych instrukcji w trybie Thumb-2: 2-1-4-3.

Widzimy, że instrukcje MOVW, MOVT.W i BLX rzeczywiście zaczynają się od 0xFx.

Jedną z tych instrukcji jest MOVW R0, #0x13D8 — zapisuje ona 16-bitową liczbę do młodszych bitów rejestru R0, zerując starsze.

Inną instrukcją jest MOVT.W RO, #0 — działa tak jak MOVT z poprzedniego przykładu, ale przeznaczona jest dla trybu Thumb-2

W tym przykładzie wykorzystana została instrukcja BLX zamiast BL. Różnica polega na tym, że oprócz zapisania adresu powrotu (RA) do rejestru LR i przekazania sterowania do funkcji puts (), odbywa się zmiana trybu procesora z Thumb/Thumb-2 na tryb ARM (lub odwrotnie).

Jest to niezbędne dlatego, że instrukcja, do której zostanie przekazane sterowanie jest zakodowana w trybie ARM i wygląda następująco:

```
__symbolstub1:00003FEC _puts ; CODE XREF: _hello_world+E __symbolstub1:00003FEC 44 F0 9F E5 LDR PC, =__imp__puts
```

Jest to skok do miejsca, w którym, w sekcji importów, zapisany jest adres funkcji puts(). Można zadać pytanie: dlaczego nie można wywołać puts() bezpośrednio, tam gdzie jest to potrzebne?

Nie jest to efektywne z punktu widzenia oszczędności miejsca.

Praktycznie każdy program korzysta z zewnętrznych bibliotek łączonych dynamicznie (jak DLL w Windows, .so w *NIX czy .dylib w Mac OS X). W bibliotekach dynamicznych znajdują się często wykorzystywane funkcje biblioteczne, w tym funkcja puts () ze standardu C.

W wykonywalnym pliku binarnym (Windows PE .exe, ELF lub Mach-O) istnieje sekcja importów. Jest to lista symboli (funkcji lub zmiennych globalnych) importowanych z modułów zewnętrznych wraz z nazwami tych modułów. Program ładujący OS, iterując po symbolach zaimportowanych w module głównym, ładuje niezbędne moduły i ustawia rzeczywiste adresy każdego z symboli.

W naszym przypadku, __imp__puts jest 32-bitową zmienną, w której program ładujący OS umieści rzeczywisty adres funkcji z biblioteki zewnętrznej.

Następnie LDR odczytuje 32-bitową wartość z tej zmiennej, i zapisując ją do rejestru PC, przekazuje tam sterowanie.

Żeby skrócic czas tej procedury programu ładującego, trzeba sprawić aby adres każdego symbolu zapisywał się tylko raz, do specjalnie przydzielonego miejsca.

Do tego, jak się już upewniliśmy, zapisywanie 32-bitowej liczby do rejestru jest niemożliwe bez odwoływania się do pamięci.

Optymalnym rozwiązaniem jest wydzielenie osobnej funkcji, pracującej w trybie ARM, której jedynym celem jest przekazywanie sterowania dalej, do biblioteki dynamicznie łączonej. Nastepnie można wywoływać tę jednoinstrukcyjną funkcję z kodu w trybie Thumb.

Nawiasem mówiąc, w poprzednim przykładzie (skompilowanym dla trybu ARM), instrukcja BL przekazuje sterowanie do takiej samej thunk-funkcji, lecz procesor nie przestawia się w inny tryb (stąd brak "X" w mnemoniku instrukcji).

Jeszcze o thunk-funkcjach

Thunk-funkcje są trudne do zrozumienia przede wszystkim przez brak spójności w terminologii. Najprościej jest myśleć o nich jak o adapterach-przejściówkach z jednego typu gniazdek na drugi. Na przykład, adapter pozwalający włożyć do gniazdka amerykańskiego wtyczkę brytyjską lub na odwrót. Thunk-funkcje również są czasami nazywane wrapper-ami. Wrap w języku angielskim to owinąć, zawinąć, opakować. Oto jeszcze kilka definicji tych funkcji:

"Kawałek kodu, który dostarcza adres:", według P. Z. Ingerman, który wymyślił thunk w 1961 roku, jako sposób na powiązanie parametrów rzeczywistych z ich formalnymi definicjami w wywołaniach procedur, w języku Algol-60. Jeśli procedura jest wywołana z wyrażeniem w miejscu parametru formalnego, kompilator generuje thunk, który oblicza wartość wyrażenia i pozostawia adres tego wyniku w pewnej standardowej lokalizacji.

• • •

Microsoft i IBM zdefiniowali w ich systemach, opartych na Intelu, "środowisko 16-bitowe" (z odrażającymi rejestrami segmentowymi i 64k limitem adresów) i "środowisko 32-bitowe" (z płaskim adresowaniem i półrzeczywistym trybem zarządzania pamięcią). Te dwa środowiska mogą działać równocześnie na tym samym komputerze i systemie operacyjnym (dzięki temu, co w świecie Microsoftu znane jest jako

WOW, co jest skrótowcem od Windows On Windows). MS i IBM zdecydowali, że proces przechodzenia z trybu 16-bitowego do 32-bitowego (i odwrotnie), nazwany zostanie "thunk"; istnieje nawet narzędzie na system Windows 95, "THUNK.EXE", nazwane "thunk kompilatorem".

(The Jargon File)

Jeszcze jeden przykład możemy znaleźć w bibliotece LAPACK — ("Linear Algebra PAC-Kage") napisanej w języku FORTRAN. Deweloperzy C/C++ również chcą korzystać z LAPACK, ale przepisywanie jej na C/C++, a następnie utrzymywanie kilku wersji byłoby szaleństwem. Istnieją wobec tego krótkie funkcje w C, które są wywoływane ze środowiska C/C++, które z kolei wywołują funkcje FORTRAN i prawie nic oprócz tego nie robią:

```
double Blas_Dot_Prod(const LaVectorDouble &dx, const LaVectorDouble &dy)
{
    assert(dx.size()==dy.size());
    integer n = dx.size();
    integer incx = dx.inc(), incy = dy.inc();

    return F77NAME(ddot)(&n, &dx(0), &incx, &dy(0), &incy);
}
```

Takie funkcje również są nazywane "wrapperami".

ARM64

GCC

Skompilujmy przykład w GCC 4.8.1 dla ARM64:

Listing 1.29: Nieoptymalizujący GCC 4.8.1 + objdump

```
0000000000400590 <main>:
 1
      400590:
 2
                     a9bf7bfd
                                               x29, x30, [sp,#-16]!
                                       stp
                                               x29, sp
 3
      400594:
                     910003fd
                                       mov
 4
      400598:
                     90000000
                                               x0, 400000 <_init-0x3b8>
                                       adrp
 5
      40059c:
                     91192000
                                       add
                                               x0, x0, #0x648
 6
      4005a0:
                     97ffffa0
                                       bl
                                               400420 <puts@plt>
                                               w0, #0x0 // #0
x29, x30, [sp],#16
 7
      4005a4:
                     52800000
                                       mov
 8
      4005a8:
                     a8c17bfd
                                       ldp
 9
      4005ac:
                     d65f03c0
                                       ret
10
11
12
13
    Contents of section .rodata:
     400640 01000200 00000000 48656c6c 6f210a00
                                                    .......Hello!..
14
```

W ARM64 nie ma trybów Thumb i Thumb-2, jest tylko ARM, więc wszystkie instrukcje są 32-bitowe.

Dysponujemy dwukrotnie większą liczbą rejestrów: **??** on page ??. 64-bitowe rejestry mają prefiks X-, a ich 32-bitowe części — W-.

Instrukcja STP (*Store Pair*) odkłada na stos jednocześnie 2 rejestry: X29 i X30. Oczywiście może ona zapisać tę parę gdziekolwiek w pamięci, ale w tym przypadku miejscem docelowym jest rejestr SP, a więc jest ona odkładana na stos.

Rejestry w ARM64 są 64-bitowe (8 bajtowe), dlatego do przechowywania 2 rejestrów potrzeba 16 bajtów.

Wykrzyknik ("!") po operandzie oznacza, że najpierw od SP będzie odjęte 16 i dopiero po tej czynności wartości z obu rejestrów będą odłożone na stos.

Jest to tak zwany *pre-index*. Więcej o różnicy między *post-index* a *pre-index*: **??** on page ??.

Posługując się terminologią x86 — pierwsza instrukcja jest analogiczna do pary instrukcji PUSH X29 i PUSH X30. X29 w ARM64 jest wykorzystywane jako FP⁴², a X30 jako LR, dlatego są one odkładane na stos w prologu funkcji.

Druga instrukcja kopiuje SP do X29 (FP). Jest to niezbędne do ustawienia ramki stosu (stack frame) funkcji.

Instrukcje ADRP i ADD ustawiają adres łańcucha znaków "Hello!" w rejestrze X0, ponieważ pierwszy argument funkcji jest przekazywany przez ten rejestr. Jednakże w ARM nie ma instrukcji, za pomocą których można zapisać do rejestru dużą liczbę (dlatego że długość instrukcji wynosi maksymalnie 4 bajty. Więcej informacji o tym można znaleźć tutaj: ?? on page ??). Dlatego trzeba skorzystać z kilku instrukcji. Pierwsza instrukcja (ADRP) zapisuje do X0 adres strony o rozmiarze 4KiB, która zawiera łańcuch znaków, a druga (ADD) dodaje do tego adresu resztę (przesunięcie względem początku strony pamięci). Więcej o tym: ?? on page ??.

0x400000 + 0x648 = 0x400648, i możemy zobaczyć, że w segmencie danych . rodata pod tym adresem znajduje się nasz łańcuch znaków "Hello!".

Następnie za pomocą instrukcji BL jest wywoływana funkcja puts (). Zostało to omówione wcześniej: 1.5.3 on page 29.

Instrukcja MOV zapisuje 0 do W0. W0 to młodsze 32 bity 64-bitowego rejestru X0:

Starsze 32 bity	Młodsze 32 bity	
X0		
	W0	

Wynik funkcji jest zwracany przez X0 i main() zwraca 0.

Dlaczego 32-bitowa część? W ARM64, jak i w x86-64, typ *int* ma rozmiar 32 bitów, dla kompatybilności.

Skoro funkcja zwraca 32-bitowy *int*, to trzeba wypełnić tylko młodsze 32 bity 64-bitowego rejestru X0.

Żeby mieć pewność, zmieńmy przykład i skompilujmy go ponownie. Teraz main() zwraca 64-bitowa wartość:

⁴²Frame Pointer

Listing 1.30: funkcja main() zwracająca wartość typu uint64_t

```
#include <stdio.h>
#include <stdint.h>

uint64_t main()
{
    printf ("Hello!\n");
    return 0;
}
```

Wynik jest taki sam, tylko MOV w tej linii wygląda teraz:

Listing 1.31: Nieoptymalizujący GCC 4.8.1 + objdump

```
4005a4: d2800000 mov x0, #0x0 // #0
```

Następnie za pomocą instrukcji LDP (Load Pair) przywracane są rejestry X29 i X30.

Nie ma wykrzyknika po instrukcji: oznacza to, że najpierw wartości są zdejmowane ze stosu a dopiero po tej czynności SP jest zwiększany o 16.

Jest to tzw. post-index.

W ARM64 pojawia się nowa instrukcja: RET. Działa tak samo jak BX LR, ale zawiera specjalny bit (ang. hint bit), który podpowiada procesorowi, że jest to wyjście z funkcji, a nie kolejna instrukcja skoku - by procesor mógł zoptymalizować jej wykonanie.

Funkcja jest bardzo prosta, GCC z włączoną optymalizacją generuje dokładnie taki sam kod.

1.5.4 MIPS

O "wskaźniku globalnym" ("global pointer")

"Wskaźnik globalny" ("global pointer") jest bardzo ważną koncepcją MIPS. Jak już wiemy, każda instrukcja w MIPS ma długość 32 bitów, dlatego niemożliwe jest zakodowanie 32-bitowego adresu w jednej instrukcji. Zamiast tego trzeba wykorzystać parę instrukcji (jak to robiło GCC dla załadowania adresu łańcucha znaków).

Można załadować dane z dowolnego adresu w przedziale register-32768...register+32767, za pomocą jednej instrukcji, dlatego że można w niej zakodować 16-bitowe przesunięcie (przesunięcie może być ujemne, stąd mówimy o zakresie liczby 16-bitowej ze znakiem). Możemy więc przydzielić do tego celu jakiś rejestr i zaalokować bufor 64KiB na najczęściej wykorzystywane dane.

Rejestr ten nazywamy "wskaźnikiem globalnym" ("global pointer") i wskazuje on na środek bufora 64KiB. Bufor zwykle zawiera zmienne globalne oraz adresy funkcji importowanych, jak printf(), ponieważ deweloperzy GCC stwierdzili, że pobranie adresu pewnych funkcji musi być tak szybkie, jak to możliwe, i powinno zająć jedną instrukcję, a nie dwie.

W plikach ELF ten 64KiB bufor znajduje się częściowo w sekcji .sbss ("small BSS⁴³")

⁴³Block Started by Symbol

dla danych niezainicjalizowanych i .sdata ("small data") dla danych zainicjalizowanych. To oznacza, że programista może wybrać do czego potrzebuje szybszego dostępu i umieścić to w segmentach .sdata/.sbss. Niektórzy programiści starej daty mogą pamiętać model pamięci w MS-DOS ?? on page ?? lub w managery pamięci typu XMS/EMS, gdzie cała pamięć była podzielona na bloki o długości 64KiB.

Ten pomysł jest wykorzystywany również w innych architekturach, np. PowerPC.

Optymalizujący GCC

Popatrzmy na poniższy przykład, pokazujący wykorzystanie "wskaźnika globalnego".

Listing 1.32: Optymalizujący GCC 4.4.5 (wyjście w asemblerze)

```
$LC0:
 2
    ; \000 to bajt zero w systemie ósemkowym:
 3
            .ascii "Hello, world!\012\000"
   main:
    ; prolog funkcji
 5
 6
    ; ustaw GP:
 7
            lui
                    $28,%hi(__gnu_local_gp)
 8
            addiu
                    $sp,$sp,-32
 9
            addiu
                    $28,$28,%lo(__gnu_local_gp)
10
    ; odłóż RA na stos lokalny:
11
                    $31,28($sp)
            SW
12
    ; załaduj adres funkcji puts() z GP do $25:
13
            lw
                    $25,%call16(puts)($28)
14
    ; załaduj adres łańcucha znaków do $4 ($a0):
15
            lui
                    $4,%hi($LC0)
16
    ; skocz do puts(), zapisując adres powrotu do rejestru powrotu:
                    $25
17
            jalr
            addiu
                    $4,$4,%lo($LCO); branch delay slot
18
    ; przywróć RA:
19
20
            lw
                    $31,28($sp)
21
    ; skopiuj 0 z $zero do $v0:
22
            move
                    $2,$0
23
    ; zwróć sterowanie, skacząc pod adres w RA:
24
                    $31
            j
    ; epilog funkcji:
25
26
            addiu
                    $sp,$sp,32 ; branch delay slot + posprzątaj stos lokalny
```

Rejestr \$GP w prologu funkcji ustawiany jest na środek tego obszaru. Na stos lokalny odkładany jest rejestr RA. W tym przykładzie kompilator również zamienił wywołanie printf() na puts(). Adres funkcji puts() jest ładowany do \$25 za pomocą instrukcji LW ("Load Word"). Następnie adres łańucha znaków jest ładowany do \$4 za pomocą pary instrukcji LUI ("Load Upper Immediate") i ADDIU ("Add Immediate Unsigned Word"). LUI ustawia starsze 16 bitów rejestru (stąd "upper" w nazwie instrukcji) i ADDIU dodaje młodsze 16 bitów do adresu.

ADDIU znajduje się po JALR (pamiętaj jednak o *branch delay slot*). Rejestr \$4 (\$A0) jest wykorzystywany do przekazywania pierwszego argumentu funkcji ⁴⁴.

⁴⁴Tabela rejestrów MIPS znajduje się w dodatku ?? on page ??

JALR ("Jump and Link Register") skacze pod adres z rejestru \$25 (znajduje się w nim adres puts ()), jednocześnie zapisując adres instrukcji, która zostanie wywołana jako następna (LW) w RA. Widać podobieństwo do ARM. I jeszcze jedna bardzo ważna rzecz: adres zapisywany do RA nie jest adresem kolejnej (ADDIU) instrukcji z listingu (dlatego, że jest to *delay slot* i wykonuje się przed instrukcją skoku), a instrukcji następującej po *delay slot*. W ten sposób, podczas wykonywania JALR, do RA jest zapisywane PC+8. W naszym wypadku jest to adres instrukcji LW, kolejnej po ADDIU.

LW ("Load Word") w linii 20 przywraca RA ze stosu lokalnego (ta instrukcja jest właściwie częścią epilogu funkcji).

MOVE w linii 22 kopiuje wartość z \$0 (\$ZERO) do \$2 (\$V0).

MIPS ma specjalny rejestr, który zawsze zawiera stałą zero. Najwyraźniej deweloperzy MIPS stwierdzili, że 0 jest najpowszechniejszą stałą w programowaniu, więc niech rejestr \$0 będzie wykorzystywany za każdym razem, kiedy będzie potrzebne 0.

Inna ciekawostka: w MIPS nie ma instrukcji kopiującej wartość z rejestru do rejestru. M0VE DST, SRC to w rzeczywistości ADD DST, SRC, \$ZER0 (gdzie DST = SRC + 0). Najwidoczniej twórcy MIPS chcieli stworzyć jak najbardziej zwięzłą tablicę kodów operacji (opcode). To wcale nie znaczy, że dodawanie jest wykonywane podczas każdej instrukcji M0VE. Prawdopodobnie te pseudoinstrukcje są optymalizowane w CPU i ALU 45 nigdy nie jest wykorzystywane.

J w linii 24 skacze pod adres w RA, co powoduje wyjście z funkcji. ADDIU poniżej J jest wykonywane przed J (pamiętasz o *branch delay slot*?) i należy do epilogu funkcji.

Poniżej listing z programu IDA. Każdy rejestr posiada swoją pseudonazwę:

Listing 1.33: Optymalizujący GCC 4.4.5 (IDA)

```
.text:00000000 main:
 2
    .text:00000000
 3
    .text:00000000 var_10
                                    = -0 \times 10
    .text:00000000 var 4
                                    = -4
 5
    .text:00000000
 6
    ; prolog funkcji
 7
    ; ustaw GP:
   .text:00000000
                                    lui
                                            $gp, (__gnu_local_gp >> 16)
    .text:00000004
                                            sp, -0x20
                                    addiu
10
   .text:00000008
                                    la
                                            $gp, (__gnu_local_gp & 0xFFFF)
11
    ; odłóż RA na stos lokalny:
    .text:0000000C
                                            $ra, 0x20+var 4($sp)
                                    SW
13
   ; odłóż GP na stos lokalny:
14
    ; z jakiegoś powodu tej instrukcji nie było na listingu z GCC:
    .text:00000010
15
                                            $gp, 0x20+var 10($sp)
                                    SW
    ; załaduj adres funkcji puts() z GP do $t9:
16
17
    .text:00000014
                                            $t9, (puts & 0xFFFF)($gp)
                                    lw
18
    ; wylicz adres łańcucha znaków i zapisz w $a0:
19
    .text:00000018
                                    lui
                                            $a0, ($LCO >> 16) # "Hello, world!"
20
    ; skocz do puts(), zapisując adres powrotu do rejestru powrotu
                                    jalr
    .text:0000001C
                                            $t9
   .text:00000020
                                            $a0, ($LC0 & 0xFFFF) # "Hello,
                                    la
       world!
```

⁴⁵Jednostka arytmetyczno-logiczna (Arithmetic Logic Unit)

```
23
    ; przywróć RA:
24
    .text:00000024
                                    lw
                                            $ra, 0x20+var_4($sp)
25
    ; skopiuj 0 z $zero do $v0:
26
   .text:00000028
                                    move
                                            $v0, $zero
    ; zwróć sterowanie, skacząc pod adres z RA:
27
28
   .text:0000002C
                                    jr
                                            $ra
29
    ; epilog funkcji:
   .text:00000030
                                    addiu
                                            $sp, 0x20
```

Instrukcja w linii 15 odkłada GP na stos lokalny. Co ciekawe, brakuje jej na listingu z GCC — możliwe, że jest to spowodowane błędem w samym GCC⁴⁶. Wartość GP musi zostać odłożona, ponieważ każda funkcja może używać swojego własnego 64KiB bufora. Rejestr zawierający adres puts () nazwany został \$T9, dlatego że rejestry z prefiksem T określane są jako "tymczasowe" i ich zawartości nie musi być zachowywana - nie jest więc odkładana na stos.

Nieoptymalizujący GCC

Nieoptymalizujący GCC generuje nieco rozwlekły kod.

Listing 1.34: Nieoptymalizujący GCC 4.4.5 (wyjście w asemblerze)

```
$LC0:
 1
 2
            .ascii "Hello, world!\012\000"
 3
    main:
 4
    ; prolog funkcji
 5
    ; odłóż RA ($31) i FP na stos:
 6
                     $sp,$sp,-32
            addiu
                     $31,28($sp)
 7
            SW
 8
                     $fp,24($sp)
            SW
    ; ustaw FP (stack frame pointer):
 9
10
            move
                     $fp,$sp
11
    ; ustaw GP:
12
                     $28,%hi(__gnu_local_gp)
13
            addiu
                     $28,$28,%lo( gnu local gp)
14
    ; załaduj adres łańcucha znaków
15
            lui
                     $2,%hi($LC0)
            addiu
                     $4,$2,%lo($LC0)
16
17
    ; załaduj adres funkcji puts() z GP:
                     $2,%call16(puts)($28)
18
            lw
19
            nop
20
    ; wywołaj puts():
                     $25,$2
21
            move
22
            jalr
                     $25
23
            nop ; branch delay slot
24
25
    ; przywróć GP ze stosu lokalnego:
26
            lw
                     $28,16($fp)
27
    ; ustaw rejestr $2 ($V0) na zero:
28
            move
                     $2,$0
```

⁴⁶Najwidoczniej funkcje generujące listingi nie są krytyczne dla użytkowników GCC, dlatego pewne kosmetyczne błędy wciąż mogą być niepoprawione.

```
29
    ; epilog funkcji.
30
    ; przywróć SP:
31
                     $sp,$fp
            move
32
    ; przywróć RA:
                     $31,28($sp)
33
            lw
    ; przywróć FP:
34
35
            lw
                     $fp,24($sp)
36
            addiu
                     $sp,$sp,32
    ; skok pod adres z RA:
37
38
                     $31
             j
39
            nop
                 ; branch delay slot
```

FP jest wykorzystywany jako wskaźnik ramki stosu (stack frame pointer). Widać również 3 instrukcje NOP. Drugi i trzeci NOP występują po instrukcjach skoku. Prawdopodobnie kompilator GCC zawsze dodaje NOP-y (przez *branch delay slot*) po instrukcjach skoku a następnie, jeśli optymalizacja jest włączona, może je wyeliminować. W tym przypadku instrukcje pozostały na swoim miejscu.

Poniżej ten sam plik wykonywalny w programie IDA:

Listing 1.35: Nieoptymalizujący GCC 4.4.5 (IDA)

```
.text:00000000 main:
 2
    .text:00000000
 3
    .text:00000000 var 10
                                    = -0 \times 10
 4
    .text:00000000 var 8
                                    = -8
 5
    .text:00000000 var 4
                                    = -4
 6
    .text:00000000
 7
    ; prolog funkcji
 8
    ; odłóż RA i FP na stos:
                                             sp, -0x20
 9
    .text:00000000
                                    addiu
                                             $ra, 0x20+var_4($sp)
10
    .text:00000004
                                    SW
11
    .text:00000008
                                    SW
                                             $fp, 0x20+var 8($sp)
12
    ; ustaw FP (stack frame pointer):
13
    .text:0000000C
                                    move
                                             $fp, $sp
14
    ; ustaw GP:
15
    .text:00000010
                                    la
                                             $qp,
                                                   __gnu_local_gp
                                             p, 0x20+var_10(sp)
16
    .text:00000018
                                    SW
    ; załaduj adres łańcucha znaków:
17
   .text:0000001C
                                             $v0, (aHelloWorld >> 16) # "Hello,
18
                                    lui
        worl
                                             $a0, $v0, (aHelloWorld & 0xFFFF) #
19
    .text:00000020
                                    addiu
        "Hello, world!"
20
    ; załaduj adres funkcji puts() z GP:
21
    .text:00000024
                                             $v0, (puts & 0xFFFF)($gp)
                                    1 w
22
    .text:00000028
                                             $at, $zero ; NOP
                                    or
23
    ; wywołaj puts():
    .text:0000002C
24
                                             $t9, $v0
                                    move
    .text:00000030
25
                                    jalr
                                             $t9
26
    .text:00000034
                                             $at, $zero ; NOP
27
    ; przywróć GP ze stosu lokalnego:
28
    .text:00000038
                                             $gp, 0x20+var 10($fp)
29
    ; ustaw rejestr $2 ($V0) na zero:
    .text:0000003C
                                             $v0, $zero
30
                                    move
31 |; epilog funkcji.
```

```
32 |; przywróć SP:
33
   .text:00000040
                                    move
                                            $sp, $fp
34
   ; przywróć RA:
35
                                            $ra, 0x20+var_4($sp)
   .text:00000044
                                    lw
36
   ; przywróć FP:
   .text:00000048
37
                                    lw
                                            $fp, 0x20+var 8($sp)
   .text:0000004C
38
                                    addiu
                                            $sp, 0x20
39
    ; skocz pod adres z RA:
40
   .text:00000050
                                    jr
                                            $ra
   .text:00000054
41
                                            $at, $zero ; NOP
                                    or
```

Co ciekawe, IDA rozpoznała parę LUI/ADDIU i zebrała ją w jedną pseudoinstrukcję LA ("Load Address") w linii 15. Można zauważyć, że jej długość to 8 bajtów! Nazywamy to pseudoinstrukcją (lub *makrem*), ponieważ nie jest to prawdziwa instrukcja MIPS, tylko wygodna nazwa dla pary dwóch powiązanych instrukcji.

Widać również, że IDA nie rozpoznała instrukcji NOP w liniach 22, 26 i 41.

W rzeczywistości NOP jest realizowany przez 0R \$AT, \$ZERO. Jest to instrukcja przeprowadzająca operację *LUB* na rejestrze \$AT i \$ZERO (rejestr zawsze przechowujący stałą 0), co jest pustą instrukcją. MIPS, jak i niektóre inne ISA, nie posiada oddzielnej instrukcji NOP.

Rola ramki stosu (stack frame) w tym przykładzie

Adres łańcucha znaków jest przekazywany przez rejestr. Po co w takim razie ustawiać stos lokalny? Wartości rejestrów RA i GP muszą być gdzieś zapisane (ponieważ wywołujemy funkcję - printf()) i w tym celu korzysta się ze stosu lokalnego.

Gdyby to była funkcja liść (ang. leaf function), to można by pozbyć się prologu i epilogu funkcji, zobacz przykład: 1.4.3 on page 11.

Optymalizujący GCC: sesja w debuggerze GDB

Listing 1.36: Przykład sesji w GDB

```
root@debian-mips:~# gcc hw.c -03 -o hw
root@debian-mips:~# gdb hw
GNU gdb (GDB) 7.0.1-debian
Reading symbols from /root/hw...(no debugging symbols found)...done.
(qdb) b main
Breakpoint 1 at 0x400654
(gdb) run
Starting program: /root/hw
Breakpoint 1, 0 \times 00400654 in main ()
(gdb) set step-mode on
(gdb) disas
Dump of assembler code for function main:
0x00400640 <main+0>: lui
                                 gp,0x42
0x00400644 <main+4>:
                        addiu
                                 sp, sp, -32
```

```
0x00400648 <main+8>:
                         addiu
                                  gp, gp, -30624
0x0040064c <main+12>:
                                  ra,28(sp)
                         SW
0x00400650 <main+16>:
                         SW
                                  gp, 16(sp)
0x00400654 <main+20>:
                                  t9,-32716(gp)
                         lw
0x00400658 <main+24>:
                         lui
                                  a0,0x40
0x0040065c <main+28>:
                                  t9
                         jalr
0x00400660 <main+32>:
                         addiu
                                  a0,a0,2080
0x00400664 <main+36>:
                                  ra,28(sp)
                         1w
0x00400668 <main+40>:
                                  v0,zero
                         move
0x0040066c <main+44>:
                         jr
                                  ra
0x00400670 <main+48>:
                         addiu
                                  sp, sp, 32
End of assembler dump.
(gdb) s
0 \times 00400658 in main ()
(qdb) s
0x0040065c in main ()
(gdb) s
0x2ab2de60 in printf () from /lib/libc.so.6
(gdb) x/s $a0
                  "hello, world"
0x400820:
(gdb)
```

1.5.5 Wnioski

Główną różnicą między kodem w x86/ARM a x64/ARM64 jest to, że wskaźnik na łańcuch znaków stał się 64-bitowy. W rzeczy samej, współczesne CPU stały się 64-bitowe przez niższy koszt pamięci oraz większe zapotrzebowania na nią przez współczesne aplikacje. Komputery mogą mieć więcej pamięci, niż można zaadresować za pomocą 32 bitów. W związku z tym, wszystkie wskaźniki są teraz 64-bitowe.

1.5.6 Ćwiczenia

```
http://challenges.re/48http://challenges.re/49
```

1.6 Prolog i epilog funkcji

Prolog funkcji to sekwencja instrukcji rozpoczynająca funkcję. Zwykle przypomina poniższy fragment kodu:

```
push ebp
mov ebp, esp
sub esp, X
```

Co te instrukcje robią: zapisują wartość rejestru EBP na stosie, ustawiają wartość w rejestrze EBP na wartość z ESP a następnie alokuję miejsce na stosie na zmienne lokalne

Wartość w EBP pozostaje niezmieniona przez całą funkcję i używana jest przy dostępie do zmiennych lokalnych i argumentów. Do tego samego celu można by użyć ESP, ale byłoby to niewygodne, gdyż wartość ESP zmienia się w czasie wykonywania funkcji.

Epilog funkcji zwalnia zaalokowane miejsce na stosie, przywraca wartość rejestru EBP do jego pierwotnego stanu i zwraca sterowanie do funkcji wywołującej:

```
mov esp, ebp
pop ebp
ret 0
```

Prolog i epilog zwykle jest wykrywany przez deasemblery i używany do wyodrębnienia pojedynczych funkcji.

1.6.1 Rekurencja

Prolog i epilog funkcji mają negatywny wpływ na wywołania rekurencyjne.

Wiecej o rekurencji: ?? on page ??.

1.7 Pusta funkcja raz jeszcze

Wróćmy do przykładu z pustą funkcją 1.3 on page 8. Uzbrojeni w wiedzę o prologu i epilogu funkcji, spójrzmy na wynik kompilacji GCC bez optymalizacji:

Listing 1.37: Nieoptymalizujący GCC 8.2 x64 (wyjście w asemblerze)

```
f:

push rbp
mov rbp, rsp
nop
pop rbp
ret
```

Poza instrukcją RET jest tam jedynie prolog i epilog, które nie zostały zoptymalizowane.

NOP wygląda jak kolejna osobliwość kompilatora. Jedyną instrukcją, która realizuje działanie programu, jest tutaj RET. Wszystkie pozostałe można by usunąć (zoptymalizować).

1.8 Zwracanie wartości raz jeszcze

Znając pojęcie prologu i epilogu, skompilujmy raz jeszcze przykład z wartością zwracaną (1.4 on page 10, 1.8 on page 10) za pomocą GCC z wyłączoną optymalizacją:

Listing 1.38: Nieoptymalizujący GCC 8.2 x64 (wyjście w asemblerze)

```
f:
push rbp
```

Instrukcje realizujące działanie programu to MOV i RET – pozostałe to prolog i epilog.

1.9 Stos

Stos w informatyce jest jedną z najbardziej fundamentalnych struktur danych 47 . AKA 48 LIFO 49 .

Technicznie rzecz biorąc, jest to blok pamięci w pamięci procesu + rejestr ESP w x86, RSP w x64, lub SP w ARM, który przechowuje wskaźnik na miejsce w granicach tego bloku.

Najczęściej używanymi instrukcjami do operowania na stosie są PUSH i POP (w x86 i trybie Thumb w ARM). PUSH zmniejsza ESP/RSP/SP o 4 w trybie 32-bitowym (lub o 8 w 64-bitowym), następnie zapisuje zawartość swojego operandu pod adres, na który wskazuje ESP/RSP/SP, .

POP jest odwrotną operacją: najpierw pobiera dane z miejsca, na które wskazuje wskaźnik stos i umieszcza ją w miejscu wskazywanym przez operand docelowy (często jest to rejestr), a następnie zwiększa wskaźnik stosu o 4 (lub 8).

Po zaalokowaniu stosu wskaźnik stosu pokazuje na koniec tego obszaru pamięci. PUSH zmniejsza wskaźnik stosu, a POP — zwiększa. Koniec stosu znajduje się na początku zaalokowanego bloku pamięci. Może zabrzmieć to dziwnie, ale tak to działa.

ARM wspiera zarówno stosy rosnący w dół, jak i w górę.

Na przykład instrukcje STMFD/LDMFD, STMED⁵⁰/LDMED⁵¹ są przeznaczone dla stosu malejącego (rosnącego w dół od adresów wysokich do adresów niskich). Natomiast instrukcje STMFA⁵²/LDMFA⁵³, STMEA⁵⁴/LDMEA⁵⁵ są przeznaczone dla stosu rosnącego (rosnącego w górę od niskich adresów do adresów wysokich).

1.9.1 Dlaczego stos rośnie w dół?

Intuicyjnie moglibyśmy pomyśleć, że jak każda inna struktura danych, stos mógłby rosnać w góre, w kierunku adresów wysokich.

Prawdopodobnie stos rośnie w dół ze względów historycznych. Kiedy komputery były duże i zajmowały cały pokój, można było bardzo łatwo podzielić pamięć na dwa

⁴⁷wikipedia.org/wiki/Call_stack

⁴⁸ Also Known As — znany również jako

⁴⁹Ostatni na wejściu, pierwszy na wyjściu (Last In First Out)

⁵⁰Store Multiple Empty Descending ()

⁵¹Load Multiple Empty Descending ()

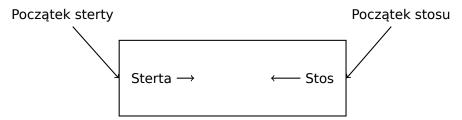
⁵² Store Multiple Full Ascending ()

⁵³Load Multiple Full Ascending ()

⁵⁴Store Multiple Empty Ascending ()

⁵⁵Load Multiple Empty Ascending ()

obszary: na stertę i na stos. Nie było wiadomo z góry, jak duża może być sterta lub stos, dlatego takie rozwiązanie było najprostsze.



W [D. M. Ritchie and K. Thompson, *The UNIX Time Sharing System*, (1974)]⁵⁶można przeczytać:

Dane użytkownika (część obrazu procesu) podzielone są na trzy logiczne segmenty. Segment kodu programu zaczyna się od adresu 0 w wirtualnej przestrzeni adresowej. W trakcie wykonania jest on zabezpieczony przed zapisem i tylko jedna jego kopia jest współdzielona przez wszystkie procesy, wykonujące ten sam program. Po pierwszej granicy 8KB ponad segmentem kodu programy, w wirtualnej przestrzeni adresowej, rozpoczyna się prywatny, zapisywalny segment danych, którego rozmiar może być zwiększany przez wywołanie systemowe. Od najwyższego adresu w wirtualnej przestrzeni adresowej zaczyna się segment stosu, który automatycznie rośnie w dół stosownie do zmian wskaźnika stosu.

To trochę przypomina sytuację, gdy uczeń prowadzi notatki z dwóch wykładów w jednym zeszycie. Pierwsze notatki zaczynają się konwencjonalnie, od początku zeszytu, ale drugie zapisywane są na końcu, po obróceniu zeszytu. Gdy zabraknie miejsca, notatki spotkają się gdzieś w środku.

1.9.2 Do czego wykorzystywany jest stos?

Zapisywanie adresu powrotu

x86

Przed wywołaniem funkcji za pomocą instrukcji CALL, na stos odkładany jest adres kolejnej instrukcji (tej bezpośrednio za CALL). Następnie następuje skok bezwarunkowy pod adres z operandu instrukcji CALL.

Instrukcja CALL jest równoważna parze instrukcji PUSH adres docelowy / JMP.

RET zdejmuje adres ze stosu i przekazuje tam sterowanie — jest to równoważne parze instrukcji POP tmp / JMP tmp.

Bardzo łatwo przepełnić stos, poprzez nieskończoną rekurencję:

void f()

⁵⁶Dostęp także przez URL

```
{
    f();
};
```

MSVC 2008 wyświetli ostrzeżenie:

...ale wygeneruje plik wykonywalny:

```
?f@@YAXXZ PROC
                                   ; f
; Line 2
        push
                 ebp
        mov
                 ebp, esp
; Line 3
        call
                 ?f@@YAXXZ
; Line 4
        pop
                 ebp
        ret
                 0
?f@@YAXXZ ENDP
                                   ; f
```

...jeśli włączymy optymalizację (opcja /0x), to zoptymalizowany kod nie będzie powodował przepełnienia stosu i działał *poprawnie*⁵⁷

GCC 4.4.1 wygeneruje taki sam kod w obu przypadkach i nie wyświetli żadnego ostrzeżenia.

ARM

Programy na ARM również korzystają ze stosu do zapisywania adresu powrotu, ale w trochę inny sposób. Jak już było wspomniane w rozdziale "Hello, world!" (1.5.3 on page 25), adres powrotu (RA) jest zapisywany do rejestru LR (rejestr powrotu). Jeśli zajdzie potrzeba wywołania kolejnej funkcji i ponownego użycia LR, to jego zawartość będzie musiała być gdzieś zapisana.

⁵⁷o ironio!

Zwykle odbywa się to w prologu funkcji, często widzimy tam instrukcję jak PUSH {R4-R7,LR}, a w epilogu POP {R4-R7,PC} — rejestry, z których będzie korzystała bieżąca funkcja, w tym rejestr LR, odkładane są na stos.

Jeśli jakaś funkcja nie wywołuje żadnych innych funkcji w trakcie swojej pracy, w terminologii RISC nazywana jest *funkcją-liściem*⁵⁸. Z tego powodu funkcja-liść nie odkłada rejestru LR na stos, ponieważ go nie zmienia. Jeśli funkcja jest niewielkich rozmiarów i korzysta z małej liczby rejestrów, to może w ogóle nie korzystać ze stosu. Stąd w ARM możliwe jest wywoływanie małych funkcji-liści bez używania stosu. Jest to szybsze niż w starych x86, gdyż nie korzysta się z pamięci zewnętrznej RAM do korzystania ze stosu. ⁵⁹. Ten mechanizm przydaje się również, gdy pamięć pod stos nie została jeszcze zaalokowana albo jest niedostępna.

kilka przykładów takich funkcji: 1.14.3 on page 137, 1.14.3 on page 138, ?? on page ??, ?? on page ??, ?? on page ??, ?? on page ??, ?? on page ??.

Przekazywanie argumentów funkcji

Najpopularniejszy sposób na przekazywanie parametrów funkcji w x86 to "cdecl":

```
push arg3
push arg2
push arg1
call f
add esp, 12; 4*3=12
```

Wywoływana funkcja pobiera swoje argumentu za pomocą wskaźnik stosu.

Stos, przed wykonaniem pierwszej instrukcji z f(), wygląda następująco:

ESP	adres powrotu
ESP+4	argument#1, oznaczony w programie IDA jako arg_0
ESP+8	argument#2, oznaczony w programie IDA jako arg_4
ESP+0xC	argument#3, oznaczony w programie IDA jako arg_8

Opis innych konwencji wywoływania funkcji znajduje się tutaj: (?? on page ??).

Nawiasem mówiąc, funkcja wywoływana nie posiada informacji o liczbie przekazywanych do niej argumentów. Funkcja printf(), która może mieć zmienną liczbę argumentów, ustala ich liczbę za pomocą specyfikatorów formatu (rozpoczynających się od znaku %).

Jeśli napiszemy:

```
printf("%d %d %d", 1234);
```

printf() wypisze 1234, a następnie jeszcze dwie losowe⁶⁰ liczby, który przypadkowo znalazły się na stosie obok.

⁵⁸infocenter.arm.com/help/index.jsp?topic=/com.arm.doc.faqs/ka13785.html

⁵⁹Kiedyś, na PDP-11 i VAX, instrukcja CALL (wywołanie innych funkcji) była kosztowna; procesor spędzał na CALL nawet do 50% czasu wykonania programu. Z tego powodu posiadanie dużej liczby małych funkcji uchodziło za antywzorzec [Eric S. Raymond, *The Art of UNIX Programming*, (2003)Chapter 4, Part II].

⁶⁰Tak na prawdę nie są one losowe, patrz: 1.9.4 on page 52

```
Dlatego nie ma znaczenia jak zapiszemy funkcję main():
jak main(), main(int argc, char *argv[])
lub main(int argc, char *argv[], char *envp[]).
```

W rzeczywistości kod z CRT wywołuje main() mniej więcej tak:

```
push envp
push argv
push argc
call main
...
```

Jeśli zadeklarujesz main() bez argumentów, one i tak będą na stosie, lecz nie zostaną wykorzystane. Jeśli zadeklarujesz main() jako main(int argc, char *argv[]), to będziesz mógł skorzystać z pierwszych dwóch argumentów, a trzeci będzie dla funkcji "niewidoczny". Co więcej, można nawet zadeklarować main(int argc) i to również zadziała.

Inny, podobny, przykład: ??.

Alternatywne sposoby na przekazywanie argumentów

Warto zauważyć, że nic nie zmusza programisty do przekazywanie argumentów przez stos. Nie ma takiego wymagania, można to robić to zupełnie inaczej, nie korzystając ze stosu.

Dość popularnym sposobem wśród początkujących jest przekazywanie argumentów przez zmienne globalne, na przykład:

Listing 1.39: Kod w asemblerze

```
. . .
                 X, 123
        mov
                 Y, 456
        mov
         call
                 do something
         . . .
        dd
                 ?
                 ?
        hh
do_something proc near
         : take X
         : take Y
         ; do something
         retn
do something endp
```

Ta metoda posiada oczywistą wadę: funkcja do_something() nie może wywołać sama siebie przez rekurencję (lub za pomocą innej funkcji), gdyż musiałaby nadpisać własne argumenty. To samo dotyczy zmiennych lokalnych, gdyby przechowywać je w

zmiennych globalnych, to funkcja nie będzie mogła wywołać sama siebie. Co więcej, nie jest to bezpieczne w środowisku wielowątkowym⁶¹. Przechowywania danych na stosie wszystko upraszcza — stos może przechować tyle argumentów funkcji/zmiennych, na ile pozwoli jego rozmiar.

W [Donald E. Knuth, *The Art of Computer Programming*, Volume 1, 3rd ed., (1997), 189] można przeczytać o jeszcze dziwniejszych metodach przekazywania argumentów, szczególnie wygodnych na IBM System/360.

W MS-DOS istniała metoda przekazywania argumentów przez rejestry, na przykład ten fragment kodu na wiekowym 16-bitowym MS-DOS wypisze "Hello, world!":

Jest to całkiem podobne do metody ?? on page ??. Przypomina to również sposoby korzystania z wywołań systemowych (ang. syscall) na systemach Linuks (?? on page ??) i Windows.

Jeżeli funkcja w MS-DOS zwraca wartość typu boolean (jeden bit, zwykle oznaczający wystąpienie błędu), to często wykorzystywana jest flaga CF.

Na przykład:

W razie wystąpienia błędu flaga CF zostaje ustawiona i instrukcja JC skacze do miejsca oznaczonego etykietą error. W przeciwnym razie uchwyt (ang. *file handle*) stworzonego pliku zwracany jest przez rejestr AX.

Ta metoda wciąż jest wykorzystywana przez programistów asemblera. W kodach źródłowych Windows Research Kernel (który jest bardzo podobny do Windows 2003) możemy znaleźć coś takiego (plik base/ntos/ke/i386/cpu.asm):

```
public Get386Stepping
Get386Stepping proc
```

 $^{^{61}}$ W poprawnej implementacji każdy wątek miałby własny stos lokalny, ze swoimi argumentami/zmiennymi.

```
call
                MultiplyTest
                                         ; Perform multiplication test
        jnc
                short G3s00
                                         ; if nc, muttest is ok
        mov
                ax, 0
        ret
G3s00:
        call
                Check386B0
                                        ; Check for BO stepping
                                        ; if nc, it's B1/later
                short G3s05
        jnc
                ax, 100h
                                        ; It is B0/earlier stepping
        mov
        ret
G3s05:
                Check386D1
        call
                                        ; Check for D1 stepping
                short G3s10
        jс
                                        ; if c, it is NOT D1
                ax, 301h
        mov
                                        ; It is D1/later stepping
        ret
G3s10:
                ax, 101h
                                        ; assume it is B1 stepping
        mov
        ret
        . . .
MultiplyTest
                proc
                                        ; 64K times is a nice round number
        xor
                CX,CX
mlt00:
        push
                CX
                                        ; does this chip's multiply work?
        call
                Multiply
        pop
                CX
                short mltx
                                        ; if c, No, exit
        jс
        loop
                mlt00
                                         ; if nc, YEs, loop to try again
        clc
mltx:
        ret
MultiplyTest
                endp
```

Przechowywanie zmiennych lokalnych

Funkcja może zaalokować miejsce na stosie dla własnych zmiennych lokalnych przez zmniejszenie wskaźnika stosu, w kierunku końca stosu (pamiętaj, że stos rośnie w dół, w kierunku niskich adresów!).

Jest to bardzo szybkie, niezależnie od liczby zmiennych lokalnych. Wiedz, że nie ma przymusu trzymania zmiennych lokalnych na stosie. Możesz je trzymać gdziekolwiek, ale tradycyjnie wykorzystuje się do tego stos.

x86: Funkcja alloca()

Ciekawym przypadkiem jest funkcja alloca() ⁶². Działa ona jak malloc(), ale przydziela pamięć bezpośrednio na stosie. Nie ma potrzeby zwalniania tak zaalokowanego obszaru pamięci za pomocą free(), gdyż epilog funkcji (1.6 on page 40) przywróci ESP do stanu początkowego i zaalokowana pamięć zostanie *porzucona*. Ciekawa jest również implementacja tej funkcji. Krótko mówiąc, przesuwa ESP w dół stosu o wymaganą liczbę bajtów, przez co ESP wskazuje na przydzielony obszar pamięci.

Sprawdźmy:

```
#ifdef __GNUC__
#include <alloca.h> // GCC
#else
#include <malloc.h> // MSVC
#endif
#include <stdio.h>

void f()
{
    char *buf=(char*)alloca (600);
#ifdef __GNUC__
    snprintf (buf, 600, "hi! %d, %d, %d\n", 1, 2, 3); // GCC
#else
    __snprintf (buf, 600, "hi! %d, %d, %d\n", 1, 2, 3); // MSVC
#endif

puts (buf);
};
```

Funkcja _snprintf() działa tak samo jak printf(), tylko zamiast wypisywać tekst na standardowe wyjście (stdout), zapisuje do bufora buf. Z kolei funkcja puts() kopiuje zawartość bufora buf na standardowe wyjście. Oczywiście zamiast korzystać z tych dwóch funkcji, można by użyć printf(), ale chcemy zobaczyć wykorzystanie niewielkiego bufora.

MSVC

Skompilujmy (MSVC 2010):

Listing 1.40: MSVC 2010

```
mov eax, 600 ; 00000258H
call __alloca_probe_16
mov esi, esp

push 3
push 2
```

⁶²W MSVC implementację funkcji można podejrzeć w plikach alloca16.asm i chkstk.asm w C:\Program Files (x86)\Microsoft Visual Studio 10.0\VC\crt\src\intel

```
push
    push
           OFFSET $SG2672
    push
           600
                      ; 00000258H
    push
           esi
    call
            __snprintf
    push
           esi
    call
           _puts
    add
           esp, 28
. . .
```

Jedyny parametr alloca() jest przekazywany przez EAX (zamiast przez stos) 63

GCC + składnia Intela

GCC 4.4.1 generuje podobne wyjście, ale bez wywoływania zewnętrznych funkcji:

Listing 1.41: GCC 4.7.3

```
.LC0:
        .string "hi! %d, %d, %d\n"
f:
        push
                 ebp
                 ebp, esp
        mov
        push
                 ebx
        sub
                 esp, 660
        lea
                 ebx, [esp+39]
        and
                 ebx, -16
                                              ; wyrównaj wskaźnik do granicy 16
    bajtów
                 DWORD PTR [esp], ebx
        mov
                                             ; S
                 DWORD PTR [esp+20], 3
        mov
        mov
                 DWORD PTR [esp+16], 2
        mov
                 DWORD PTR [esp+12], 1
                 DWORD PTR [esp+8], OFFSET FLAT:.LC0 ; "hi! %d, %d, %d\n" \label{eq:def}
        mov
        mov
                 DWORD PTR [esp+4], 600
                                             ; maxlen
        call
                  snprintf
                 DWORD PTR [esp], ebx
        mov
                                             ; S
        call
                 puts
                 ebx, DWORD PTR [ebp-4]
        mov
        leave
        ret
```

GCC + składnia AT&T

Spójrzmy na ten sam kod, ale w składni AT&T:

⁶³Dlatego, że alloca() to nie tyle funkcja, co raczej *compiler intrinsic* (?? on page ??). Jedną z przyczyn, dla której potrzebujemy osobnej funkcji a nie kilku instrukcji w samym kodzie, jest to, że implementacja alloca() z MSVC⁶⁴ zawiera kod, który czyta z właśnie zaalokowanej pamięci. W konsekwencji OS mapuje pamięć fizyczną na ten region pamięci wirtualnej. Po wywołaniu funkcji alloca() ESP pokazuje na blok o długości 600 bajtów, który można użyć na tablicę buf.

Listing 1.42: GCC 4.7.3

```
.LC0:
        .string "hi! %d, %d, %d\n"
f:
        pushl
                %ebp
        movl
                %esp, %ebp
        pushl
                %ebx
        subl
                 $660, %esp
                39(%esp), %ebx
        leal
                $-16, %ebx
        andl
                %ebx, (%esp)
        movl
                $3, 20(%esp)
        movl
                $2, 16(%esp)
        movl
                $1, 12(%esp)
        movl
        movl
                $.LCO, 8(%esp)
                $600, 4(%esp)
        movl
        call
                 snprintf
        movl
                %ebx, (%esp)
        call
                puts
        movl
                 -4(%ebp), %ebx
        leave
        ret
```

Kod jest taki sam jak na poprzednim listingu.

Nawiasem mówiąc, movl \$3, 20(%esp) odpowiada mov DWORD PTR [esp+20], 3 w składni Intela. W składni AT&T, sposób adresowania pamięci *rejestr+przesunięcie* zapisywany jest jako przesunięcie(%rejestr).

(Windows) SEH

Na stosie są przechowywane wpisy SEH⁶⁵ dla funkcji (jeśli są one obecne). Więcej o tym tutaj: (5.2.1 on page 147).

Ochrona przed przepełnieniem bufora

Więcej o tym tutaj (1.19.2 on page 142).

Automatyczne zwalnianie miejsca na stosie

Zmienne lokalne i wpisy SEH są trzymane na stosie prawdopodobnie dlatego, że kiedy funkcja kończy działanie są one zwalniane automatycznie. Odbywa się to za pomocą tylko jednej instrukcji, zmieniającej wartość wskaźnika stosu — często jest to instrukcja ADD. Argumenty funkcji, można tak powiedzieć, również są automatycznie zwalniane na końcu funkcji. Z kolei wszystko, co jest przechowywane na stercie (heap), trzeba zwalniać jawnie.

⁶⁵Structured Exception Handling

1.9.3 Struktura typowego stosu

Struktura typowego stosu w środowisku 32-bitowym, przed wykonaniem pierwszej instrukcji w funkcji, wygląda następująco:

ESP-0xC	zmienna lokalna#2, oznaczona w programie IDA jako var_8
ESP-8	zmienna lokalna#1, oznaczona w programie IDA jako var_4
ESP-4	odłożona wartość EBP
ESP	adres powrotu
ESP+4	argument#1, oznaczony w programie IDA jako arg_0
ESP+8	argument#2, oznaczony w programie IDA jako arg_4
ESP+0xC	argument#3, oznaczony w programie IDA jako arg_8

1.9.4 Śmieci na stosie

When one says that something seems random, what one usually means in practice is that one cannot see any regularities in it.

Stephen Wolfram, A New Kind of Science.

Często w tej książce mówimy o "szumie" lub "śmieciach" na stosie czy w pamięci. Skąd one się biorą? Są to pozostałości po poprzednich wywołaniach funkcji.

Krótki przykład:

```
#include <stdio.h>

void f1()
{
        int a=1, b=2, c=3;
};

void f2()
{
        int a, b, c;
        printf ("%d, %d, %d\n", a, b, c);
};

int main()
{
        f1();
        f2();
};
```

Kompilujemy...

Listing 1.43: Nieoptymalizujący MSVC 2010

```
$SG2752 DB '%d, %d', 0aH, 00H
```

```
_{c} = -12
                   ; size = 4
_{b} = -8
                   ; size = 4
_{a} = -4
                   ; size = 4
_f1
         PR<sub>0</sub>C
         push
                   ebp
         mov
                   ebp, esp
         sub
                   esp, 12
                   DWORD PTR _a$[ebp], 1
         mov
                   DWORD PTR _b$[ebp], 2
         mov
         mov
                   DWORD PTR _c$[ebp], 3
         mov
                   esp, ebp
                   ebp
         pop
         ret
                   0
_f1
         ENDP
_{b$} = -12
_{b$} = -8
                   ; size = 4
                   ; size = 4
_a$ = -4
_f2 F
                   ; size = 4
         PR<sub>0</sub>C
         push
                   ebp
                   ebp, esp
         mov
                   esp, 12
         sub
                   eax, DWORD PTR _c$[ebp]
         mov
         push
                   ecx, DWORD PTR _b$[ebp]
         \text{mov}
         push
                   ecx
                   edx, DWORD PTR _a$[ebp]
         mov
         push
                   edx
                   OFFSET $SG2752; '%d, %d, %d'
         push
         call
                   DWORD PTR __imp__printf
         add
                   esp, 16
         mov
                   esp, ebp
         pop
                   ebp
         ret
_f2
         ENDP
         PR<sub>0</sub>C
_main
         push
                   ebp
         mov
                   ebp, esp
                  _f1
         call
         call
                   _f2
         xor
                   eax, eax
         pop
                   ebp
                   0
         ret
_main
         ENDP
```

Kompilator się trochę oburzy...

```
c:\polygon\c\st.c(11) : warning C4700: uninitialized local variable 'c' \( \sqrt{used} \)
c:\polygon\c\st.c(11) : warning C4700: uninitialized local variable 'b' \( \sqrt{used} \)
c:\polygon\c\st.c(11) : warning C4700: uninitialized local variable 'a' \( \sqrt{used} \)
Microsoft (R) Incremental Linker Version 10.00.40219.01
Copyright (C) Microsoft Corporation. All rights reserved.

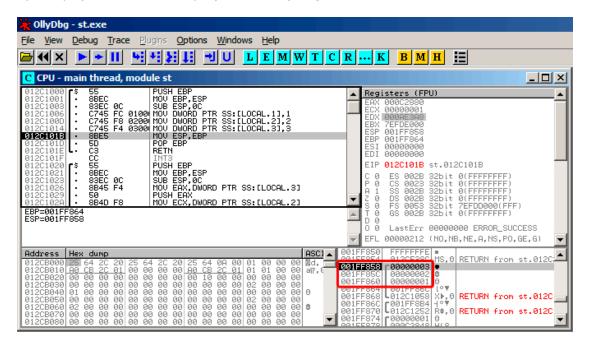
/out:st.exe
st.obj
```

Ale kiedy uruchomimy skompilowany program...

```
c:\Polygon\c>st
1, 2, 3
```

Dziwne, przecież nie ustawialiśmy żadnych zmiennych w f2(). Te wartości to "duchy", które wciąż znajdują się na stosie.

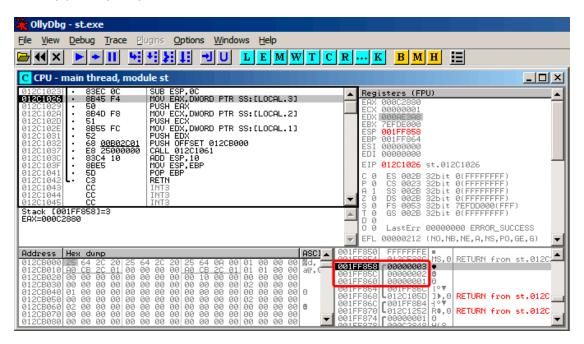
Spróbujmy uruchomić ten przykład w OllyDbg:



Rysunek 1.6: OllyDbg: f1()

Kiedy f1() ustawia zmienne a, b i c są one zapisywane pod adresem 0x1FF860, itd.

A kiedy jest wykonywana f2():



Rysunek 1.7: OllyDbg: f2()

... a, b i c w funkcji f2() znajdują się pod tymi samymi adresami! Nikt jeszcze nie nadpisał tych wartości, więc na razie pozostają one nietknięte. Taka dziwna sytuacja ma miejsce, kiedy kilka funkcji jest wykonywanych jedna po drugiej, a SP jest taki sam (funkcje mają taką samą liczbę argumentów). Wtedy zmienne lokalne będą przechowywane w tych samych adresach na stosie. Podsumowując, wszystkie wartości na stosie (i ogólnie w pamięci) to wartości pozostałe po poprzednich funkcjach. Nie są one losowe, w ścisłym tego słowa znaczeniu, lecz nieprzewidywalne. Czy można coś z tym zrobić? Można by czyścić fragmenty stosu przed wykonywaniem funkcji, ale to za dużo zbędnej (i nieporzebnej) pracy.

MSVC 2013

Przykład był skompilowany w MSVC 2010. Jeden czytelnik tej książki spróbował skompilować to w MSVC 2013, uruchomił i zobaczył 3 liczby w odwrotnej kolejności:

```
c:\Polygon\c>st
3, 2, 1
```

Dlaczego? Również spróbowałem skompilować ten przykład w MSVC 2013 i otrzymałem:

Listing 1.44: MSVC 2013

```
_a$ = -12 ; size = 4
```

```
b$ = -8
                  ; size = 4
_{c} = -4
                  ; size = 4
         PR<sub>0</sub>C
_f2
_f2
         FNDP
_c$ = -12
                  ; size = 4
_b$ = -8
                  ; size = 4
_a$ = -4
                  ; size = 4
       PR0C
_f1
. . .
_f1
         ENDP
```

W odróżnieniu od MSVC 2010, MSVC 2013 rozmieścił zmienne a/b/c w funkcji f2() w odwrotnej kolejności. Jest to całkowicie poprawne, ponieważ w C/C++ nie ma zdefiniowanego standardu, który by wyznaczał kolejność zmiennych lokalnych na stosie. Przyczyną różnicy są zapewne zmiany w kodzie kompilatora, a więc nowsze MSVC zachowuje się nieco inaczej.

1.9.5 Ćwiczenia

```
http://challenges.re/51http://challenges.re/52
```

1.10 Funkcja niemal pusta

Poniższy fragment kodu znalazłem w projekcie Boolector⁶⁶:

```
// forward declaration. the function is residing in some other module:
int boolector_main (int argc, char **argv);

// executable
int main (int argc, char **argv)
{
        return boolector_main (argc, argv);
}
```

Dlaczego ktoś miałby tak robić? Prawdopodobnie boolector_main() może być kompilowane do biblioteki dynamicznej (jak np. DLL) i wywoływane w testach. Kod testowy również może przygotować argumenty argc/argv, tak jak to robi CRT.

Ciekawy jest wynik kompilacji:

⁶⁶https://boolector.github.io/

Listing 1.45: Nieoptymalizujący GCC 8.2 x64 (wyjście w asemblerze)

```
main:
        push
                rbp
        mov
                rbp, rsp
        sub
                rsp, 16
        mov
                DWORD PTR -4[rbp], edi
        mov
                QWORD PTR -16[rbp], rsi
                rdx, QWORD PTR -16[rbp]
        mov
                eax, DWORD PTR -4[rbp]
        mov
                rsi, rdx
        mov
                edi, eax
        mov
                boolector_main
        call
        leave
```

Mamy tutaj: prolog, niepotrzebne (niezoptymalizowane) przetasowanie dwóch argumentów, CALL, epilog i RET.

Zobaczmy na efekt kompilacji GCC z włączoną optymalizacją:

Listing 1.46: Optymalizujący GCC 8.2 x64 (wyjście w asemblerze)

```
main:

jmp boolector_main
```

Bardzo prosty kod — rejestr i stos zostały nienaruszone, gdyż boolector_main() ma taki sam zestaw argumentów. Jedyne co należało zrobić, to przekazać sterowanie pod inny adres.

Przypomina to thunk funkcje.

Później zobaczymy nieco bardziej zaawansowane przykłady: 1.11.2 on page 73, ?? on page ??.

1.11 printf() z wieloma argumentami

Spróbujmy rozszerzyć przykład Hello, world! (1.5 on page 12):

```
#include <stdio.h>
int main()
{
     printf("a=%d; b=%d; c=%d", 1, 2, 3);
     return 0;
};
```

1.11.1 x86

x86: 4 argumenty

MSVC

Gdy skompilujemy kod za pomocą MSVC 2010 Express, otrzymamy:

```
$SG3830 DB 'a=%d; b=%d; c=%d', 00H
...

push 3
push 2
push 1
push 0FFSET $SG3830
call _printf
add esp, 16 ; 00000010H
```

Kod jest niemal identyczny z tym, który widzieliśmy w *Hello, world!* (1.5 on page 12), lecz teraz argumenty funkcji printf() zostały odłożone na stos w odwrotnej kolejności. Pierwszy argument jest zapisywany jako ostatni.

Przy okazji, zmienna typu *int* w środowisku 32-bitowym ma długość 32 bitów, czyli 4 bajtów.

Mamy więc 4 argumenty. 4*4=16 —zajmują dokładnie 16 bajtów na stosie: 32-bitowy wskaźnik na łańcuch znaków i trzy liczby typu *int*.

Gdy wskaźnik stosu (rejestr ESP) jest przywracany za pomocą ADD ESP, X za wywołaniem funkcji, to często można określić liczbę argumentów, dzieląc X przez 4.

Oczywiście dotyczy to tylko konwencji wywołań cdecl i środowiska 32-bitowego!

O konwencjach wywołań przeczytasz tutaj (?? on page ??).

Kompilator, gdy kilka funkcji jest wywoływanych jedna za drugą, może połączyć kilka instrukcji "ADD ESP, X" w jedną i umieścić ją po ostatnim wywołaniu:

```
push a1
push a2
call ...
...
push a1
call ...
push a1
push a2
push a2
push a3
call ...
add esp, 24
```

Przykład prawdziwego kodu:

Listing 1.47: x86

```
.text:100113E7
                  push
.text:100113E9
                  call
                          sub 100018B0 ; wykorzystuje jeden argument (3)
                          sub 100019D0 ; funkcja bez argumentów
.text:100113EE
                  call
                          sub_10006A90 ; funkcja bez argumentów
.text:100113F3
                  call
.text:100113F8
                  push
.text:100113FA
                          sub_100018B0 ; wykorzystuje jeden argument (1)
                  call
```

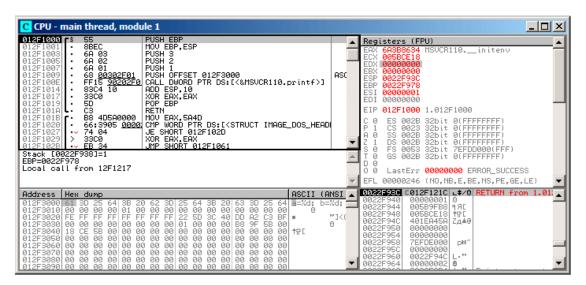
.text:100113FF add esp, 8 ; jednocześnie sprząta dwa argumenty ze stosu

MSVC and OllyDbg

Skorzystajmy z OllyDbg. Jest to jeden z najpopularniejszych debuggerów pod win32, działających w trybie użytkownika. Przykład skompilujemy w MSVC 2012 z opcją /MD, która oznacza dynamiczne linkowanie do MSVCR*.DLL, by łatwo można było rozpoznać zaimportowane funkcje w debuggerze.

Możemy załadować plik wykonywalny do OllyDbg. Pierwszy breakpoint jest w ntdll.dll, naciskamy F9 (run). Drugi breakpoint jest w kodzie CRT. Musimy odnaleźć funkcję main().

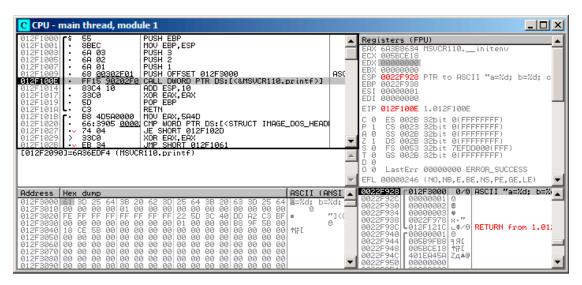
Można to zrobić scrollując na samą górę kodu (MSVC umieszcza funkcję main() na samym początku sekcji kodu):



Rysunek 1.8: OllyDbg: sam początek funkcji main()

Klikamy na instrukcję PUSH EBP, wciskamy F2 (ustaw breakpoint) i wciskamy F9 (run). Dzięki temu przeskoczymy kod z CRT, którym nie jesteśmy na razie zainteresowani.

Naciśnij F8 (step over) 6 razy, by przeskoczyć 6 kolejnych instrukcji:



Rysunek 1.9: OllyDbg: przed wykonaniem printf()

PC pokazuje teraz na instrukcję CALL printf. OllyDbg, jak inne debuggery, podświetla rejestry, które zostały zmienione. Za każdym razem, gdy naciskasz F8, EIP zmienia się i jego wartość jest wyświetlana na czerwono. ESP również się zmienia, gdyż argumenty są przekazywane przez stos.

Gdzie na stosie są nasze wartości? Spójrz na obszar w prawym, dolnym rogu okna:



Rysunek 1.10: OllyDbg: stos po odłożeniu argumentów (czerwona ramka została dodana przez autora w programie graficznym)

Widzimy 3 kolumny: adres na stosie, wartość i dodatkowo komentarz OllyDbg. OllyDbg rozumie wskaźniki na łańcuchy znaków, więc wypisuje wartość tego łańcucha jako komentarz .

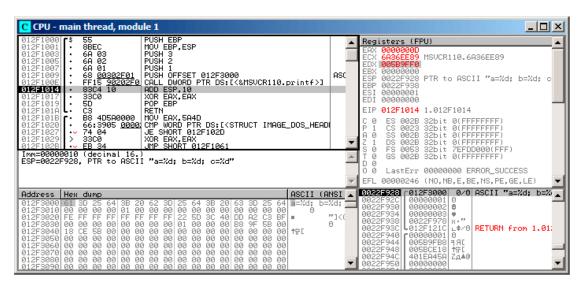
Możesz kliknąć prawym przyciskiem myszy na łańcuch znaków z formatem i wybrać "Follow in dump". Łańcuch znaków pojawi się w lewym, dolnym oknie debuggera, wyświetlającym zawartość pamięci. Możesz ją tam edytować. Mógłbyś zmienić format łańcucha znaków, tak by na wyjście został wypisany inny tekst. W tym przykładzie nie jest to użyteczna funkcjonalność, ale możesz jej użyć w ramach ćwiczeń, by lepiej poznać opisane wcześniej mechanizmy.

Wciśnij F8 (step over).

Zobaczymy następujący rezultat w konsoli:

```
a=1; b=2; c=3
```

Sprawdźmy jak zmieniły się rejestry i stos:



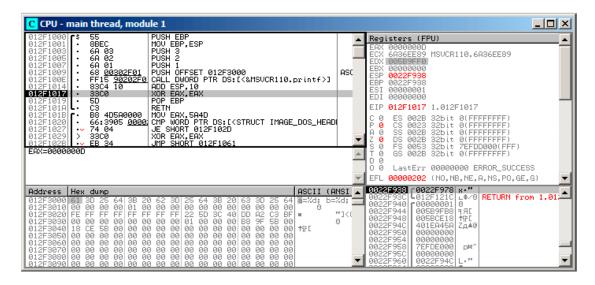
Rysunek 1.11: OllyDbg po wykonaniu funkcji printf()

Rejestr EAX zawiera teraz 0xD (13). Jest to spodziewana wartość, ponieważ printf() zwraca liczbę wypisanych znaków. Zmieniła się wartość EIP: zawiera teraz adres kolejnej instrukcji, występującej bezpośrednio za CALL printf. ECX i EDX również się zmieniły. Najwyraźniej implementacja printf() wykorzystała je do własnych celów.

Ważnym faktem jest to, że ani wartość ESP, ani stan stosu się nie zmieniły!

Łatwo zauważyć, że łańcuch znaków z formatem oraz 3 powiązane z nim argumentu wciąż tam są. Jest to konwencja wywoływania *cdecl*: funkcja wywoływana nie przywraca ESP do pierwotnego stanu. Ta odpowiedzialność spoczywa na wywołującym.

Ponownie wciśnij F8, by wykonać instrukcję ADD ESP, 10:



Rysunek 1.12: OllyDbg: po wykonaniu instrukcji ADD ESP, 10

Zmieniła się wartość ESP, ale wartości na stosie zostały niezmienione! Można się tego spodziewać; nikt nie musi ich nadpisywać. Wszystko powyżej wskaźnika stosu (SP) to szum czy śmieci i nie ma znaczenia. Czyszczenie nieużywanych wpisów na stosie byłoby stratą czasu i nikt tego nie potrzebuje.

GCC

Skompilujmy ten sam program na Linuksie, za pomocą GCC 4.4.1 i sprawdźmy wynik w programie IDA:

```
main
                proc near
var_10
                = dword ptr -10h
                = dword ptr -0Ch
var C
                = dword ptr -8
var 8
                = dword ptr -4
var_4
                push
                        ebp
                mov
                         ebp, esp
                         esp, 0FFFFFF0h
                and
                sub
                         esp, 10h
                         eax, offset aADBDCD ; "a=%d; b=%d; c=%d"
                mov
                         [esp+10h+var_4], 3
                mov
                         [esp+10h+var_8], 2
                mov
                mov
                         [esp+10h+var_C], 1
                mov
                         [esp+10h+var_10], eax
                        _printf
                call
```

	mov leave retn	eax, 0	
main	endp		

Jedyną zauważalną różnicą jest inny sposób odkładania argumentów na stos. W tym przykładzie GCC explicite podaje adres w obrębie stosu i nie używa instrukcji PUSH/POP.

GCC i GDB

Wczytajmy plik wykonywalny do debuggera GDB⁶⁷.

Opcja -g sprawia, że kompilator zapisuje do pliku wykonywalnego informacje użyteczne do debuggowania.

```
$ gcc 1.c -g -o 1
```

```
$ gdb 1
GNU gdb (GDB) 7.6.1-ubuntu
...
Reading symbols from /home/dennis/polygon/1...done.
```

Listing 1.48: Ustawmy breakpoint w funkcji printf()

```
(gdb) b printf
Breakpoint 1 at 0x80482f0
```

Kontynuujmy wykonywanie kodu. Gdybyśmy dysponowali kodem źródłowym funkcji printf(), GDB mógłby go wyświetlić obok instrukcji asemblera.

Wypiszmy 10 wartości ze stosu. Skrajna lewa kolumna oznacza adres, pod którym wartości ze stosu znajdują się w pamięci.

```
      (gdb) x/10w $esp
      0x0804844a
      0x080484f0
      0x00000001
      0x00000002

      0xbffff12c:
      0x00000003
      0x08048460
      0x00000000
      0x00000000

      0xbffff13c:
      0xb7e29905
      0x00000001
      0x00000000
```

Pierwszy element to adres powrotu (RA) (0x0804844a). Możemy to sprawdzić, deasemblując pamięć pod tym adresem (instruujemy GDB, by wypisał 5 elementów ze stosu, interpretując je jako instrukcje asemblera):

⁶⁷GNU Debugger

```
(gdb) x/5i 0x0804844a

0x804844a <main+45>: mov $0x0,%eax

0x804844f <main+50>: leave

0x8048450 <main+51>: ret

0x8048451: xchg %ax,%ax

0x8048453: xchg %ax,%ax
```

Pojawiająca się dwa razy XCHG działa jak pusta instrukcja NOP, gdyż w tym przypadku ustawia wartość rejestr AX na jego bieżącą wartość.

Drugim elementem jest (0x080484f0) — to adres łańcucha znaków z formatem:

```
(gdb) x/s 0x080484f0
0x80484f0: "a=%d; b=%d; c=%d"
```

Kolejne 3 elementy (1, 2, 3) to argumenty funkcji printf(). Pozostałe elementy to prawdopodobnie "śmieci" znajdujące się na stosie, lecz mogłyby to być wartości używane przez inne funkcje, ich zmienne lokalnce, etc. Możemy je na razie zignorować.

Kontynuujmy za pomocą "finish". Polecenie powoduje, że GDB wykona wszystkie instrukcje aż do końca funkcji. W tym przypadku do końca funkcji printf().

GDB pokazuje jaką wartość printf() zwróciła przez rejestr EAX (13). Jest to liczba znaków, które zostały wypisane i jest to dokładnie tyle, ile widzieliśmy w przykładzie z OllyDbg.

Widzimy również "return 0;" wraz z informacją, że to wyrażenie jest w pliku 1.c, w linii 6. Plik 1.c znajduje się w bieżącym katalogu i tam GDB znalazł ten łańcuch znaków. Skąd debugger wiedział, która linia kodu w C jest właśnie wykonywana? Kompilatory, gdy generują informacje dla debuggera, zapisują również tablicę z zależnościami między liniami kodu źródłowego a adresami instrukcji, GDB jest w końcu debuggerem pracującym z kodem źródłowym.

Przyjrzyjmy się rejestrom. W EAX znajduje się wartość 13:

```
(gdb) info registers
                            13
eax
                 0xd
                 0x0
                            0
ecx
                 0x0
                            0
edx
                 0xb7fc0000
                                     -1208221696
ebx
                 0xbffff120
                                     0xbffff120
esp
                 0xbffff138
                                     0xbffff138
ebp
esi
                 0 \times 0
                            0
                            0
edi
                 0 \times 0
                 0x804844a
                                     0x804844a <main+45>
eip
. . .
```

Deasemblujemy kolejne instrukcje. Strzałka pokazuje na instrukcję, która zostanie wykonana jako kolejna.

```
(qdb) disas
Dump of assembler code for function main:
  0x0804841d <+0>:
                       push
                               %ehn
   0x0804841e <+1>:
                       mov
                               %esp,%ebp
                               $0xfffffff0,%esp
  0x08048420 <+3>:
                       and
  0x08048423 <+6>:
                       sub
                               $0x10,%esp
  0x08048426 <+9>:
                       movl
                               $0x3,0xc(%esp)
  0x0804842e <+17>:
                               $0x2,0x8(%esp)
                       movl
  0x08048436 <+25>:
                       movl
                               $0x1,0x4(%esp)
  0x0804843e <+33>:
                       movl
                               $0x80484f0,(%esp)
  0x08048445 <+40>:
                       call
                               0x80482f0 <printf@plt>
=> 0x0804844a <+45>:
                               $0x0,%eax
                       mov
  0x0804844f <+50>:
                       leave
   0x08048450 <+51>:
                        ret
End of assembler dump.
```

GDB używa domyślnie składni AT&T. Możemy jednak przełączyć się na składnię Intela.

```
(gdb) set disassembly-flavor intel
(qdb) disas
Dump of assembler code for function main:
  0x0804841d <+0>:
                        push
                               ebp
  0x0804841e <+1>:
                       mov
                               ebp,esp
  0x08048420 <+3>:
                        and
                               esp,0xffffff0
  0x08048423 <+6>:
                        sub
                               esp,0x10
  0x08048426 <+9>:
                       mov
                               DWORD PTR [esp+0xc],0x3
  0x0804842e <+17>:
                       mov
                               DWORD PTR [esp+0x8],0x2
  0x08048436 <+25>:
                       mov
                               DWORD PTR [esp+0x4],0x1
  0x0804843e <+33>:
                        mov
                               DWORD PTR [esp], 0x80484f0
  0x08048445 <+40>:
                        call
                               0x80482f0 <printf@plt>
=> 0x0804844a <+45>:
                               eax,0x0
                        mov
  0x0804844f <+50>:
                        leave
  0x08048450 <+51>:
                        ret
End of assembler dump.
```

Wykonajmy kolejną linię kodu w C/C++. GDB pokazuje klamrowy nawias zamykający, który oznacza koniec bloku kodu.

```
(gdb) step
7 };
```

Sprawdźmy rejestry po wykonaniu instrukcji MOV EAX, 0. Tak jak się spodziewamy, EAX zawiera teraz wartość 0.

```
(gdb) info registers
eax 0x0 0
ecx 0x0 0
edx 0x0 0
ebx 0xb7fc0000 -1208221696
```

```
0xbffff120
                                       0xbffff120
esp
ebp
                  0xbffff138
                                       0xbffff138
esi
                  0 \times 0
                             0
                  0 \times 0
                             0
edi
                  0x804844f
                                       0x804844f <main+50>
eip
. . .
```

x64: 9 argumentów

Zmieńmy nieco nasz przykład, by zobaczyć jak na x64 argumenty przekazywane są przez stos. Zwiększymy liczbę argumentów do 9 (łańcuch znaków z formatem + 8 zmiennych typu *int*):

```
#include <stdio.h>
int main()
{
         printf("a=%d; b=%d; c=%d; d=%d; e=%d; f=%d; g=%d; h=%d\n", 1, 2, 3, \( \nabla \)
         4, 5, 6, 7, 8);
         return 0;
};
```

MSVC

Jak wspomnieliśmy poprzednio — pierwsze 4 argumenty na Win64 przekazywane są przez rejestry RCX, RDX, R8 i R9 a pozostałe przez stos⁶⁸.

Widać to na wygenerowanym listingu. Stos został przygotowany przy pomocy instrukcji MOV, zamiast PUSH- wartości zostały odłożone ze wskazaniem adresu.

Listing 1.49: MSVC 2012 x64

```
$SG2923 DB
                 a=%d: b=%d: c=%d: d=%d: e=%d: f=%d: a=%d: h=%d'. 0aH. 00H
main
        PR0C
                 rsp, 88
        sub
                DWORD PTR [rsp+64], 8
        mov
                DWORD PTR [rsp+56], 7
        mov
                DWORD PTR [rsp+48], 6
        mov
                DWORD PTR [rsp+40], 5
        mov
                DWORD PTR [rsp+32], 4
        mov
                r9d, 3
        mov
                r8d, 2
        mov
        mov
                edx, 1
                rcx, OFFSET FLAT: $SG2923
        lea
        call
                printf
```

⁶⁸przyp. tłum. - rzecz wygląda inaczej w przypadku przekazywania argumentów zmiennoprzecinkowych, gdy może zostać wykorzystany rejestr wektorowy XMM0-XMM3

```
; zwróć 0
xor eax, eax
add rsp, 88
ret 0
main ENDP
_TEXT ENDS
END
```

Uważny czytelnik może się zastanawiać, dlaczego dla wartości typu *int* zostało zaalokowanych 8 bajtów, skoro wystarczą tylko 4? Dla przypomnienia: 8 bajtów jest alokowanych dla każdego typu danych, krótszego niż 64 bity. Powodem jest wygoda, łatwo w ten sposób wyliczyć adres dowolnego argumentu. Poza tym, wszystkie są przechowywane w pamięci na wyrównanych adresach. W środowisku 32-bitowym jest podobnie - 4 bajty są zarezerwowane dla wszystkich typów nie dłuższych niż 4 bajty⁶⁹.

GCC

Kompilacja na x86-64 systemach *NIX daje podobny wynik jak MSVC, jednak teraz 6 pierwszych argumentów jest przekazywanych przez rejestry RDI, RSI, RDX, RCX, R8 i R9, a cała reszta przez stos.

GCC generuje kod, który przechowuje wskaźnik stosu w EDI zamiast w RDI — co już zdążyliśmy zauważyć: 1.5.2 on page 22.

Widzieliśmy też, że rejestr EAX został wyzerowany przed wywołaniem funkcji printf(): 1.5.2 on page 22.

Listing 1.50: Optymalizujący GCC 4.4.6 x64

```
.LC0:
        .string "a=%d; b=%d; c=%d; d=%d; e=%d; f=%d; g=%d; h=%d\n"
main:
                 rsp, 40
        sub
                 r9d, 5
        mov
                 r8d, 4
        mov
                ecx, 3
        mov
                edx, 2
        mov
                esi, 1
        mov
                edi, OFFSET FLAT:.LC0
        mov
                eax, eax; liczba użytych rejestrów wektorowych
        xor
                DWORD PTR [rsp+16], 8
        mov
        mov
                DWORD PTR [rsp+8], 7
                DWORD PTR [rsp], 6
        mov
        call
                printf
        ; zwróć 0
        xor
                eax, eax
```

⁶⁹przyp. tłum. - np. zmienna typu long long zajmie 8 bajtów.

```
add rsp, 40
ret
```

GCC + GDB

\$ qcc -q 2.c -o 2

Wczytajmy plik wykonywalny do debuggera GDB

```
$ gdb 2
GNU gdb (GDB) 7.6.1-ubuntu
...
Reading symbols from /home/dennis/polygon/2...done.
```

Listing 1.51: Ustawiamy breakpoint na funkcji printf() i zaczynamy wykonanie

Rejestry RSI/RDX/RCX/R8/R9 zostały ustawione na spodziewane wartości. W RIP przechowywany jest adres pierwszej instrukcji z funkcji printf().

```
(gdb) info registers
rax
                0x0
rbx
                0x0
                          0
rcx
                0x3
                          3
rdx
                0x2
                          2
rsi
                0x1
                0x400628 4195880
rdi
                                  0x7fffffffdf60
                0x7fffffffdf60
rbp
                0x7fffffffdf38
                                  0x7fffffffdf38
rsp
                0x4
                          4
r8
r9
                0x5
                0x7fffffffdce0
                                   140737488346336
r10
                0x7fffff7a65f60
                                   140737348263776
r11
                0x400440 4195392
r12
r13
                0x7ffffffffe040
                                   140737488347200
r14
                0 \times 0
                          0
                0x0
                          0
r15
                0x7fffff7a65f60
                                   0x7fffff7a65f60 <__printf>
rip
```

Listing 1.52: Łańcuch znaków z formatem

```
(gdb) x/s $rdi
0x400628: "a=%d; b=%d; c=%d; d=%d; e=%d; f=%d; g=%d; h=%d\n"
```

Wyświetlimy zawartość stosu za pomocą komendy x/g - g oznacza *giant word*, czyli wartość 64-bitowa.

Jak w poprzednim przykładzie, pierwszy elementem na stosie jest adres powrotu RA. 3 wartości przekazywane są przez stos: 6, 7, 8. Widać, że 8 przekazywane jest z wypełnionymi 32 starszymim bitami: 0x00007fff00000008. Nie stanowi to problemu, ponieważ argument jest typu *int*, który jest 32-bitowy. Starsze części rejestrów, albo elementów na stosie, mogą zawierać "losowe śmieci".

Jeśli sprawdzimy gdzie zostanie zwrócone sterowanie po zakończeniu funkcji printf(), GDB pokaże funkcję main:

```
(qdb) set disassembly-flavor intel
(gdb) disas 0x0000000000400576
Dump of assembler code for function main:
   0x000000000040052d <+0>:
                                 push
   0x000000000040052e <+1>:
                                 mov
                                        rbp,rsp
   0x0000000000400531 <+4>:
                                 sub
                                        rsp,0x20
   0x0000000000400535 <+8>:
                                        DWORD PTR [rsp+0x10],0x8
                                 mov
   0x000000000040053d <+16>:
                                        DWORD PTR [rsp+0x8],0x7
                                 mov
   0x0000000000400545 <+24>:
                                        DWORD PTR [rsp],0x6
                                 mov
   0x000000000040054c <+31>:
                                 mov
                                        r9d.0x5
   0x0000000000400552 <+37>:
                                 mov
                                        r8d,0x4
   0x0000000000400558 <+43>:
                                 mov
                                        ecx,0x3
   0x000000000040055d <+48>:
                                 mov
                                        edx,0x2
   0x0000000000400562 <+53>:
                                 mov
                                        esi,0x1
   0x0000000000400567 <+58>:
                                 mov
                                        edi,0x400628
   0x000000000040056c <+63>:
                                 mov
                                        eax,0x0
   0x0000000000400571 <+68>:
                                        0x400410 <printf@plt>
                                 call
   0x0000000000400576 <+73>:
                                 mov
                                        eax,0x0
   0x000000000040057b <+78>:
                                 leave
   0x000000000040057c <+79>:
                                 ret
End of assembler dump.
```

Przeskoczmy na koniec funkcji printf() i wykonajmy jedną linię kodu z funkcji main(). W ramach tej linii rejestr EAX został wyzerowany. Debugger pokazuje teraz na koniec bloku kodu. Możemy się upewnić, że EAX rzeczywiście ma wartość 0, a RIP pokazuje teraz na instrukcję LEAVE, przedostatnią w funkcji main().

```
(gdb) next
        };
(gdb) info registers
                          0
rax
                0x0
                          0
rbx
                0x0
                0x26
                          38
rcx
                0x7ffff7dd59f0
                                   140737351866864
rdx
                0x7fffffd9
                                   2147483609
rsi
                0x0
rdi
                          0
                0x7fffffffdf60
                                   0x7fffffffdf60
rbp
                0x7fffffffdf40
                                   0x7fffffffdf40
rsp
r8
                0x7fffff7dd26a0
                                   140737351853728
r9
                0x7fffff7a60134
                                   140737348239668
r10
                0x7fffffffd5b0
                                   140737488344496
                                   140737348458752
r11
                0x7fffff7a95900
                0x400440 4195392
r12
r13
                0x7fffffffe040
                                   140737488347200
r14
                0x0
                          0
r15
                0 \times 0
                          0
                0x40057b 0x40057b <main+78>
rip
. . .
```

1.11.2 ARM

ARM: 4 argumenty

Tradycyjny sposób w ARM na przekazywanie argumentów (tzw. konwencja wywoływania funkcji) wygląda następująco: pierwsze 4 argumenty są przekazywane przez rejestry R0-R3, a pozostałe przez stos. Przypomina to konwencję fastcall (?? on page ??) czy win64 (?? on page ??).

32-bitowy ARM

Nieoptymalizujący Keil 6/2013 (tryb ARM)

Listing 1.53: Nieoptymalizujący Keil 6/2013 (tryb ARM)

```
.text:00000000 main
.text:00000000 10 40 2D E9
                              STMFD
                                      SP!, {R4,LR}
                                      R3, #3
.text:00000004 03 30 A0 E3
                              MOV
.text:00000008 02 20 A0 E3
                              MOV
                                      R2, #2
.text:0000000C 01 10 A0 E3
                              MOV
                                      R1, #1
.text:00000010 08 00 8F E2
                              ADR
                                      R0, aADBDCD
                                                       ; "a=%d; b=%d; c=%d"
                                        2printf
.text:00000014 06 00 00 EB
                                      R0, #0
.text:00000018 00 00 A0 E3
                              MOV
                                                       ; zwróć 0
.text:0000001C 10 80 BD E8
                              LDMFD
                                      SP!, {R4,PC}
```

Pierwsze 4 argumenty zostały przekazane przez rejestry R0-R3 w następującej kolejności: wskaźnik na łańcuch znaków z formatem w R0, następnie 1 w R1, 2 w R2 i 3 w

R3. Instrukcja z adresu 0x18 zapisuje 0 do rejestru R0—jest to część instrukcji *return* 0 z kodu C. Nic nadzwyczajnego.

Optymalizujący Keil 6/2013 generuje taki sam kod.

Optymalizujący Keil 6/2013 (tryb Thumb)

Listing 1.54: Optymalizujący Keil 6/2013 (tryb Thumb)

```
.text:00000000 main
                             PUSH
.text:00000000 10 B5
                                     {R4,LR}
.text:00000002 03 23
                             MOVS
                                     R3, #3
.text:00000004 02 22
                             MOVS
                                     R2, #2
.text:00000006 01 21
                             MOVS
                                     R1, #1
.text:00000008 02 A0
                             ADR
                                     R0, aADBDCD
                                                      ; "a=%d; b=%d; c=%d"
.text:0000000A 00 F0 0D F8
                            BL
                                       2printf
                             {\sf MOVS}
.text:0000000E 00 20
                                     R0, #0
.text:00000010 10 BD
                             P0P
                                     {R4,PC}
```

Porównując do niezoptymalizowanego kodu w trybie ARM, nie widać wyraźnej różnicy.

Optymalizujący Keil 6/2013 (tryb ARM) + usunięty return

Zmieńmy nieco przykład, usuwając return 0:

```
#include <stdio.h>

void main()
{
         printf("a=%d; b=%d; c=%d", 1, 2, 3);
};
```

Efekt jest dość nieoczekiwany:

Listing 1.55: Optymalizujący Keil 6/2013 (tryb ARM)

```
.text:00000014 main
.text:00000014 03 30 A0 E3
                             MOV
                                     R3, #3
.text:00000018 02 20 A0 E3
                             MOV
                                      R2, #2
.text:0000001C 01 10 A0 E3
                             MOV
                                      R1, #1
.text:00000020 1E 0E 8F E2
                             ADR
                                     R0, aADBDCD
                                                      ; "a=%d; b=%d; c=%d\n"
.text:00000024 CB 18 00 EA
                                       2printf
```

W zoptymalizowanej wersji w trybie ARM widzimy, że ostatnią instrukcją jest B zamiast spodziewanej BL. Inną różnicą jest brak prologu i epilogu (instrukcje zachowujące wartości rejestrów R0 i LR), które wystąpiły w wersji niezoptymalizowanej.

Instrukcja B skacze pod inny adres, bez zmiany rejestru LR, podobnie jak JMP w x86. Dlaczego to działa? Nowy kod w działaniu jest równoważny poprzedniej wersji z dwóch powodów:

- 1) nie jest modyfikowany SP (wskaźnik stosu),
- 2) wywołanie printf() jest ostatnią instrukcją, nic się dalej nie dzieje.

Funkcja printf() po zakończeniu pracy zwraca sterowanie do adresu z LR. LR przechowuje adres miejsca, z którego nasza funkcja została wywołana, a więc tam też zostanie zwrócone sterowanie. Nie musimy zapisywać LR, ponieważ nie ma konieczności jego modyfikacji. W programie nie ma innych wywołań funkcji niż wywołanie printf() i to z tego powodu nie musimy modyfikować LR. Co więcej, po wywołaniu funkcji nie musimy już nic robić! To własnie dzięki tym wszystkim okolicznościom optymalizacja była możliwa.

Podobna optymalizacja pojawia się często w funkcjach, których ostatnią instrukcją jest wywołanie innej funkcji. Podobny przykład widać tutaj: ?? on page ??.

Nieco prostszy przykład opisywaliśmy już wcześniej: 1.10 on page 57.

ARM64

Nieoptymalizujący GCC (Linaro) 4.9

Listing 1.56: Nieoptymalizujący GCC (Linaro) 4.9

```
.LC1:
        .string "a=%d; b=%d; c=%d"
f2:
; zapisz FP i LR w ramce stosu:
        stp
                x29, x30, [sp, -16]!
; ustaw wskaźnik ramki stosu (FP=SP):
                x29, sp, 0
        add
                x0, .LC1
        adrp
                x0, x0, :lo12:.LC1
        add
                w1, 1
        mov
        mov
                w2, 2
        mov
                w3, 3
        h1
                printf
        mov
                w0, 0
; przywróć FP i LR
        ldp
                x29, x30, [sp], 16
        ret
```

Pierwsza instrukcja STP (*Store Pair*) zapisuje na stosie FP (X29) i LR (X30). Kolejna — ADD X29, SP, 0 — tworzy ramkę stosu przez zapisanie wartości SP do X29.

Następnie widać już znaną parę instrukcji ADRP/ADD, która konstruuje wskaźnik na łańcuch znaków. lo12 oznacza młodsze 12 bitów — linker umieści młodsze 12 bitów adresu LC1 w kodzie operacji (opcode) instrukcji ADD. Trzy ostatnie argumenty funkcji printf() — 1, 2 i 3 — to literały typu int, więc są ładowane do 32-bitowych części rejestru. 70

⁷⁰Zmiana 1 na 1L (literał long long) spowoduje, że będzie to wartość 64-bitowa i trafi ona do rejestru 64-bitowego. Więcej o definiowaniu liczb całkowitych i literałach w C/C++: 1, 2.

Optymalizujący GCC (Linaro) 4.9 generuje taki sam kod.

ARM: 9 argumentów

Użyjmy ponownie przykładu z 9 argumentami: 1.11.1 on page 68.

Optymalizujący Keil 6/2013: tryb ARM

```
.text:00000028
                           main
.text:00000028
.text:00000028
                           var 18 = -0x18
.text:00000028
                           var 14 = -0x14
.text:00000028
                           var 4 = -4
.text:00000028
.text:00000028 04 E0 2D E5 STR
                                    LR, [SP, #var_4]!
                                    SP, SP, #0x14
.text:0000002C 14 D0 4D E2
                            SUB
.text:00000030 08 30 A0 E3
                            MOV
                                    R3, #8
.text:00000034 07 20 A0 E3
                            MOV
                                    R2, #7
.text:00000038 06 10 A0 E3
                            MOV
                                    R1, #6
.text:0000003C 05 00 A0 E3
                            MOV
                                    R0, #5
.text:00000040 04 C0 8D E2
                            ADD
                                    R12, SP, #0x18+var_14
                                    R12, {R0-R3}
.text:00000044 0F 00 8C E8
                            STMIA
.text:00000048 04 00 A0 E3
                                    R0, #4
                            MOV
.text:0000004C 00 00 8D E5
                                    R0, [SP,#0x18+var 18]
                            STR
                                    R3, #3
.text:00000050 03 30 A0 E3
                            MOV
.text:00000054 02 20 A0 E3
                            MOV
                                    R2, #2
.text:00000058 01 10 A0 E3
                            MOV
                                    R1, #1
.text:0000005C 6E 0F 8F E2
                            ADR
                                    RO, aADBDCDDDEDFDGD; "a=%d; b=%d; c=%d;
   d=%d; e=%d; f=%d; g=%"
                                     2printf
.text:00000060 BC 18 00 EB
                            BL
.text:00000064 14 D0 8D E2
                            ADD
                                    SP, SP, #0x14
.text:00000068 04 F0 9D E4
                            LDR
                                    PC, [SP+4+var_4],#4
```

Kod można podzielić na kilka części.

• Prolog.

Pierwsza instrukcja — STR LR, [SP,#var_4]! — zapisuje LR na stosie, ponieważ użyjemy tego rejestru przy wywołaniu funkcji printf(). Wykrzyknik na końcu oznacza pre-index.

Pre-index oznacza, że SP zostanie najpierw zmniejszony o 4, a następnie pod tym zmodyfikowanym adresem zostanie zapisana wartość LR. Podobnie działa instrukcja PUSH na x86. Więcej przeczytasz o tym tutaj: ?? on page ??.

Druga instrukcja — SUB SP, SP, #0x14 — zmniejsza SP (wskaźnik stosu) by zaalokować na stosie 0x14 (20) bajtów. Będziemy przekazywać do funkcji printf() 5 32-bitowych wartości, każda z nich zajmuje 4 bajty — razem zajmą więc dokładnie 20 bajtów. Pozostałe 4 32-bitowe wartości zostaną przekazane przez rejestry.

• Przekazania argumentów 5, 6, 7 i 8 przez stos.

Najpierw argumenty zapisywane są do rejestrów, odpowiednio: R0, R1, R2 and R3. Następnie instrukcja ADD R12, SP, #0x18+var_14 zapisuje do rejestru R12 adres stosu, pod którym te wartości zostaną umieszczone. *var_14* to makro równe -0x14, stworzone przez program IDA by poprawić czytelność kodu pracującego ze stosem. Makra *var_?* wygenerowane w programie IDA odpowiadają zmiennym lokalnym umieszczonym na stosie. Zatem ostatecznie do rejestru R12 trafi adres SP+4.

Kolejna instrukcja — STMIA R12, R0-R3 — zapisuje zawartość rejestrów R0-R3 w pamięci, pod adres z R12. STMIA to skrót od *Store Multiple Increment After. Increment After* oznacza, że R12 będzie zwiększany o 4, po każdej zapisanej wartości rejestru.

• Przekazanie argumentu 4 przez stos.

Najpierw wartość 4 jest zapisywana w R0, a następnie za pomocą instrukcji STR R0, [SP, $\#0x18+var_18$] odkładana jest na stos. var_18 to -0x18, a więc ostateczne przesunięcie (offset) wynosi 0, a więc wartość z R0 (4) trafi pod adres z SP.

Przekazanie argumentów 1, 2, 3 przez rejestry.

3 pierwsze argumenty -1, 2, 3 (a, b, c w łańcuchu formatującym) - są przekazywane przez rejestry R1, R2 i R3 tuż przed wywołaniem funkcji printf().

- Wywołanie printf().
- · Epilog.

Instrukcja ADD SP, SP, #0x14 przywraca wskaźnik stosu SP do poprzedniej wartości, porzucając wszystkie tam zapisane dane. Oczywiście odłożone wartości wciąż tam są, ale zostaną nadpisane przy wywołaniach kolejnych funkcji.

Instrukcja LDR PC, [SP+4+var_4],#4 wczytuje do PC wcześniej odłożoną na stos wartość LR, powodując wyjście z funkcji. Tym razem na końcu instrukcji nie ma wykrzyknika — tak, najpierw PC jest ładowany z adresu przechowywanego w SP $(4 + var_4 = 4 + (-4) = 0)$, a następnie SP jest zwiększany o 4.

Dlaczego IDA w taki sposób wyświetla instrukcje? W ten sposób łatwiej pokazać układ danych na stosie, widać tutaj, że zmienna var_4 została stworzona do zapisu wartości LR na stosie lokalnym. Instrukcje jest na swój sposób podobna do POP PC w x86⁷¹.

⁷¹Niemożliwe jest ustawienie wartości w IP/EIP/RIP za pomocą POP w x86, ale poza tym to trafne

Optymalizujący Keil 6/2013: tryb Thumb

```
.text:0000001C
                            printf main2
.text:0000001C
                            var 18 = -0x18
.text:0000001C
.text:0000001C
                            var^{-}14 = -0x14
.text:0000001C
                            var_8 = -8
.text:0000001C
                             PUSH
.text:0000001C 00 B5
                                     {LR}
.text:0000001E 08 23
                             MOVS
                                     R3, #8
.text:00000020 85 B0
                             SUB
                                     SP, SP, #0x14
.text:00000022 04 93
                             STR
                                     R3, [SP,#0x18+var_8]
                             MOVS
.text:00000024 07 22
                                     R2, #7
.text:00000026 06 21
                             MOVS
                                     R1, #6
.text:00000028 05 20
                             MOVS
                                     R0, #5
                                     R3, SP, #0x18+var_14
.text:0000002A 01 AB
                             ADD
.text:0000002C 07 C3
                             STMIA
                                     R3!, {R0-R2}
                                     R0, #4
.text:0000002E 04 20
                             MOVS
                                     R0, [SP,#0x18+var_18]
R3, #3
.text:00000030 00 90
                             STR
.text:00000032 03 23
                             MOVS
                                     R2, #2
.text:00000034 02 22
                             MOVS
                                     R1, #1
.text:00000036 01 21
                             MOVS
                                     R0, aADBDCDDDEDFDGD; "a=%d; b=%d; c=%d;
.text:00000038 A0 A0
                             ADR
   d=%d; e=%d; f=%d;
.text:0000003A 06 F0 D9 F8 BL
                                      2printf
.text:0000003E
.text:0000003E
                            loc 3E
                                     ; CODE XREF: example13 f+16
                             ADD
.text:0000003E 05 B0
                                     SP, SP, #0x14
.text:00000040 00 BD
                             P0P
                                     {PC}
```

Wyjście jest podobne do poprzedniego przykładu. Tym razem jest to kod w trybie Thumb i wartości są umieszczane na stosie w innym porządku: najpierw odkładana jest wartość 8, jako druga odkładana jest grupa wartości 5, 6, 7 a jako trzecia odkładana jest wartość 4.

Optymalizujący Xcode 4.6.3 (LLVM): tryb ARM

```
text:0000290C
                           _printf_main2
text:0000290C
text:0000290C
                           var 1C = -0x1C
text:0000290C
                           var C = -0xC
text:0000290C
text:0000290C 80 40 2D E9
                             STMFD
                                   SP!, {R7,LR}
text:00002910 0D 70 A0 E1
                            MOV
                                    R7, SP
text:00002914 14 D0 4D E2
                                    SP, SP, #0x14
                             SUB
text:00002918 70 05 01 E3
                            MOV
                                    R0, #0x1570
text:0000291C 07 C0 A0 E3
                            MOV
                                    R12, #7
text:00002920 00 00 40 E3
                            MOVT
                                    R0, #0
text:00002924 04 20 A0 E3
                            MOV
                                    R2, #4
```

porównanie.

```
text:00002928 00 00 8F E0
                              ADD
                                      RO, PC, RO
 text:0000292C 06 30 A0 E3
                              MOV
                                      R3, #6
 text:00002930 05 10 A0 E3
                              MOV
                                      R1, #5
                                      R2, [SP,#0x1C+var 1C]
 text:00002934 00 20 8D E5
                              STR
                              STMFA
 text:00002938 0A 10 8D E9
                                     SP, {R1,R3,R12}
 text:0000293C 08 90 A0 E3
                              MOV
                                     R9, #8
 text:00002940 01 10 A0 E3
                              MOV
                                     R1, #1
__text:00002944 02 20 A0 E3
                                      R2, #2
                              MOV
text:00002948 03 30 A0 E3
                                      R3, #3
                              MOV
 text:0000294C 10 90 8D E5
                              STR
                                      R9, [SP,#0x1C+var_C]
 text:00002950 A4 05 00 EB
                              BL
                                      printf
                                      SP, R7
 text:00002954 07 D0 A0 E1
                              MOV
 text:00002958 80 80 BD E8
                              LDMFD
                                     SP!, {R7,PC}
```

Niemal to samo widzieliśmy poprzednio, za wyjątkiem istrukcji STMFA (Store Multiple Full Ascending), która jest synonimem STMIB (Store Multiple Increment Before). Instrukcja najpierw zwiększa wartość rejestru SP, a po tym zapisuje wartości rejestrów (z drugiego operandu) do pamięci. Te dwa kroki odbywają się w odwrotnej kolejności niż w instrukcji STMIA.

Można również zwrócić uwagę, że instrukcje zostały rozrzucone jakby losowo. Na przykład wartość w rejestrze R0 jest ustawiana w trzech różnych miejscach: 0x2918, 0x2920 i 0x2928, a można by to zrobić w jednym.

Musimy pamiętać, że ten porządek jest pozornie losowy, kompilator ma swoje powodu do takiego szeregowania instrukcji, ponieważ kieruje się efektywnością kodu w trakcie wykonania.

Procesor z reguły próbuje równolegle wykonywać instrukcje położone obok siebie. Na przykład, instrukcje jak MOVT R0, #0 oraz ADD R0, PC, R0 nie mogę być wykonywane równocześnie, gdyż obie modyfikują ten sam rejestr R0. Z drugiej strony, MOVT R0, #0 oraz MOV R2, #4 mogą być wykonywane równolegle, gdyż nie ma konfliktu między wynikami ich pracy. Prawdopodobnie kompilator starał się tak uszeregować instrukcje, by mogły być wykonywane równolegle tam, gdzie to możliwe.

Optymalizujący Xcode 4.6.3 (LLVM): tryb Thumb-2

```
text:00002BA0
                              printf main2
 text:00002BA0
_text:00002BA0
                              var 1C = -0x1C
text:00002BA0
                              var_18 = -0x18
text:00002BA0
                              var_C = -0xC
__text:00002BA0
 text:00002BA0 80 B5
                               PUSH
                                         {R7,LR}
 text:00002BA2 6F 46
                               MOV
                                         R7, SP
                                         SP, SP, #0x14
 text:00002BA4 85 B0
                               SUB
 text:00002BA6 41 F2 D8 20
                               MOVW
                                         R0, #0x12D8
 text:00002BAA 4F F0 07 0C
                               MOV.W
                                         R12, #7
 text:00002BAE C0 F2 00 00
                               MOVT.W
                                         R0, #0
 text:00002BB2 04 22
                               MOVS
                                         R2, #4
 text:00002BB4 78 44
                               ADD
                                         R0, PC
                                                 ; char *
 _text:00002BB6 06 23
                               MOVS
                                         R3, #6
```

```
text:00002BB8 05 21
                               MOVS
                                         R1, #5
 text:00002BBA 0D F1 04 0E
                               ADD.W
                                         LR, SP, #0x1C+var 18
 text:00002BBE 00 92
                               STR
                                         R2, [SP,#0x1C+var_1C]
text:00002BC0 4F F0 08 09
                                         R9, #8
                               MOV.W
                                         LR, {R1,R3,R12}
text:00002BC4 8E E8 0A 10
                               STMIA.W
text:00002BC8 01 21
                               MOVS
                                         R1, #1
                                         R2, #2
text:00002BCA 02 22
                               MOVS
text:00002BCC 03 23
                               MOVS
                                         R3, #3
text:00002BCE CD F8 10 90
                               STR.W
                                         R9, [SP,#0x1C+var_C]
_text:00002BD2 01 F0 0A EA
                               BLX
                                         printf
_text:00002BD6 05 B0
                                         SP, SP, #0x14
                               ADD
text:00002BD8 80 BD
                               P<sub>0</sub>P
                                         {R7, PC}
```

Wyjście jest prawie takie samo jak w poprzednim przykładzie, różnicą jest użycie instrukcji z trybu Thumb/Thumb-2.

ARM64

Nieoptymalizujący GCC (Linaro) 4.9

Listing 1.57: Nieoptymalizujący GCC (Linaro) 4.9

```
.LC2:
        .string "a=%d; b=%d; c=%d; d=%d; e=%d; f=%d; g=%d; h=%d\n"
f3:
; przydziel miejsce na stosie:
        sub
                sp, sp, #32
; zapisz FP i LR w ramce stosu:
        stp
                x29, x30, [sp,16]
; ustaw wskaźnik ramki stosu (FP=SP+16):
        add
                x29, sp, 16
                x0, .LC2; "a=%d; b=%d; c=%d; d=%d; e=%d; f=%d; q=%d; h=%d\n"
        adrp
        add
                x0, x0, :lo12:.LC2
                                 ; 9. argument
        mov
                w1, 8
                w1, [sp]
                                 ; zapisz 9. argument na stosie
        str
                w1, 1
        mov
                w2, 2
        mov
                w3, 3
        mov
        mov
                w4, 4
                w5, 5
        mov
        mov
                w6, 6
                w7, 7
        mov
                printf
        bl
                sp, x29, #16
        sub
; przywróć FP i LR
        ldp
                x29, x30, [sp,16]
        add
                sp, sp, 32
        ret
```

Pierwsze 8 argumentów przekazywanych jest w rejestrach X- oraz W-: [Procedure Call Standard for the ARM 64-bit Architecture (AArch64), (2013)]⁷². Wskaźnik na łańcuch znaków wymaga 64-bitowego rejestru, trafia więc do X0. Wszystkie pozostałe wartości są typu *int*, mają szerokość 32 bitów i umieszczane są w młodszych 32-bitowych częściach rejestrów (W-). Dziewiąty argument (8) jest przekazywany przez stos. Nie można przekazać dużej liczby argumentów przez rejestry, gdyż ich liczba jest ograniczona.

Optymalizujący GCC (Linaro) 4.9 generuje taki sam kod.

1.11.3 MIPS

4 argumenty

Optymalizujący GCC 4.4.5

Główną różnicą między przykładem z "Hello, world!" jest to, że tym razem wywoływana jest funkcja printf() zamiast puts() a 3 dodatkowe argumenty przekazywane są przez rejestry \$5...\$7 (\$A1 ...\$A3). Nazwy tych rejestrów są poprzedzone literą "A", gdyż w architekturze MIPS rejestry \$4...\$7 (\$A0 ...\$A3) służą do przekazywania argumentów.

Listing 1.58: Optymalizujący GCC 4.4.5 (wyjście w asemblerze)

```
$LC0:
        .ascii "a=%d; b=%d; c=%d\000"
main:
; prolog:
        lui
                $28,%hi(__gnu_local_gp)
        addiu
                $sp,$sp,-32
        addiu
                $28,$28,%lo(__gnu_local_gp)
                $31,28($sp)
        SW
; załaduj adres funkcji printf():
                $25,%call16(printf)($28)
        lw
; załaduj adres łańcucha znaków i ustaw jako 1. argument funkcji printf():
        lui
                $4,%hi($LC0)
        addiu
                $4,$4,%lo($LC0)
; ustaw 2. argument funkcji printf():
                                         # 0×1
        li
                $5,1
; ustaw 3. argument funkcji printf():
                                         # 0x2
        li
                $6,2
; wywołaj printf():
        jalr
                $25
; ustaw 4. argument funkcji printf() (branch delay slot):
        li
                $7,3
                                         # 0x3
; epilog:
                $31,28($sp)
; ustaw wartość zwracaną na 0:
        move
                $2,$0
```

⁷²Dostep także przez http://infocenter.arm.com/help/topic/com.arm.doc.ihi0055b/IHI0055B_ aapcs64.pdf

```
; zwróć wartość:
j $31
addiu $sp,$sp,32 ; branch delay slot
```

Listing 1.59: Optymalizujący GCC 4.4.5 (IDA)

```
.text:00000000 main:
.text:00000000
.text:00000000 var_10
                                = -0 \times 10
.text:00000000 var_4
                                = -4
.text:00000000
; prolog:
.text:00000000
                                lui
                                        $gp, (__gnu_local_gp >> 16)
                                        sp, -0x^{-2}
.text:00000004
                                addiu
                                        $gp, (__gnu_local_gp & 0xFFFF)
.text:00000008
                                la
.text:0000000C
                                        $ra, 0x20+var_4($sp)
                                SW
.text:00000010
                                SW
                                        $gp, 0x20+var_10($sp)
; załaduj adres funkcji printf():
.text:00000014
                                        $t9, (printf & 0xFFFF)($gp)
; załaduj adres łańcucha znaków i ustaw jako 1. argument funkcji printf():
                                                          # "a=%d; b=%d; c=%d"
.text:00000018
                                        $a0, $LC0
                                la
; ustaw 2. argument funkcji printf():
.text:00000020
                                        $a1, 1
                                li
; ustaw 3. argument funkcji printf():
.text:00000024
                                lί
                                        $a2, 2
; call printf():
.text:00000028
                                jalr
                                        $t9
; ustaw 4. argument funkcji printf() (branch delay slot):
.text:0000002C
                                li
                                        $a3, 3
; epilog:
.text:00000030
                                        $ra, 0x20+var_4($sp)
                                lw
; ustaw wartość zwracaną na 0:
.text:00000034
                                        $v0, $zero
                                move
; zwróć wartość:
.text:00000038
                                jr
                                        $ra
.text:0000003C
                                addiu
                                        $sp, 0x20 ; branch delay slot
```

IDA zgrupowała parę instrukcji LUI i ADDIU w jedną pseudoinstrukcję LA. Z tego powodu pod adresem 0x1C nie ma instrukcji - LA zajmuje 8 bajtów.

Nieoptymalizujący GCC 4.4.5

Nieoptymalizujący GCC generuje nieco rozwlekły kod:

Listing 1.60: Nieoptymalizujący GCC 4.4.5 (wyjście w asemblerze)

```
$LC0:
    .ascii "a=%d; b=%d; c=%d\000"
main:
; prolog:
    addiu $sp,$sp,-32
    sw $31,28($sp)
```

```
$fp,24($sp)
        SW
        move
                $fp,$sp
        lui
                $28,%hi(__gnu_local_gp)
        addiu
                $28,$28,%lo(__gnu_local_gp)
; załaduj adres łańcucha znaków:
                $2,%hi($LC0)
        lui
        addiu
                $2,$2,%lo($LC0)
; ustaw 1. argument funkcji printf():
        move
                $4,$2
; ustaw 2. argument funkcji printf():
                $5,1
                                          # 0x1
        li
; ustaw 3. argument funkcji printf():
        li
                $6,2
                                          # 0x2
; ustaw 4. argument funkcji printf():
                                          # 0x3
        li
                $7,3
; pobierz adres funkcji printf():
                $2,%call16(printf)($28)
        lw
        nop
; wywołaj printf():
                $25,$2
        move
                $25
        jalr
        nop
; epilog:
        lw
                $28,16($fp)
; ustaw wartość zwracaną na 0:
                $2,$0
        move
        move
                $sp,$fp
        lw
                $31,28($sp)
                $fp,24($sp)
        1w
        addiu
                $sp,$sp,32
; zwróć wartość:
                $31
        j
        nop
```

Listing 1.61: Nieoptymalizujący GCC 4.4.5 (IDA)

```
.text:00000000 main:
.text:00000000
.text:00000000 var 10
                                = -0 \times 10
.text:00000000 var_8
                                = -8
                                = -4
.text:00000000 var_4
.text:00000000
; prolog:
.text:00000000
                                addiu
                                         sp, -0x20
.text:00000004
                                         $ra, 0x20+var_4($sp)
                                SW
.text:00000008
                                         fp, 0x20+var_8(sp)
                                SW
.text:0000000C
                                move
                                         $fp, $sp
                                         $gp,
.text:00000010
                                               __gnu_local_gp
                                la
                                         $gp, 0x20+var_10($sp)
.text:00000018
; załaduj adres łańcucha znaków:
                                         $v0, aADBDCD
                                                          # "a=%d; b=%d; c=%d"
.text:0000001C
                                la
; ustaw 1. argument funkcji printf():
.text:00000024
                                move
                                         $a0, $v0
```

```
; ustaw 2. argument funkcji printf():
.text:00000028
                                        $a1, 1
; ustaw 3. argument funkcji printf():
                                        $a2, 2
.text:0000002C
                                li
; ustaw 4. argument funkcji printf():
.text:00000030
                                        $a3, 3
                                li
; pobierz adres funkcji printf():
.text:00000034
                                        $v0, (printf & 0xFFFF)($gp)
                                1w
.text:00000038
                                or
                                        $at, $zero
; wywołaj printf():
.text:0000003C
                                        $t9, $v0
                                move
.text:00000040
                                        $t9
                                jalr
.text:00000044
                                        $at, $zero ; NOP
; epilog:
.text:00000048
                                        $gp, 0x20+var_10($fp)
                                lw
; ustaw wartość zwracaną na 0:
.text:0000004C
                                move
                                        $v0, $zero
.text:00000050
                                move
                                        $sp, $fp
.text:00000054
                                1w
                                        $ra, 0x20+var_4($sp)
.text:00000058
                                lw
                                        $fp, 0x20+var_8($sp)
.text:0000005C
                                addiu
                                        $sp, 0x20
; zwróć wartość:
.text:00000060
                                jr
                                        $ra
.text:00000064
                                or
                                        $at, $zero ; NOP
```

9 argumentów

Ponownie użyjmy przykładu z 9. argumentami z poprzedniego rozdziału: 1.11.1 on page 68.

```
#include <stdio.h>
int main()
{
         printf("a=%d; b=%d; c=%d; d=%d; e=%d; f=%d; g=%d; h=%d\n", 1, 2, 3, \( \nabla \)
         4, 5, 6, 7, 8);
         return 0;
};
```

Optymalizujący GCC 4.4.5

4 pierwsze argumenty są przekazane przez rejestry \$A0 ...\$A3, a pozostałe przez stos.

Jest to tzw. konwencja wywoływania O32 (najpowszechniejsza w świecie MIPS). Inne konwencje (jak np. N32) mogą używać innej liczby rejestrów do przekazywania argumentów.

SW to skrótowiec od "Store Word" (z rejestru do pamięci). W MIPS brakuje instrukcji bezpośrednio zapisującej wartość w pamięci, zawsze do tego celu trzeba użyć pary LI/SW.

Listing 1.62: Optymalizujący GCC 4.4.5 (wyjście w asemblerze)

```
$LC0:
        .ascii "a=%d; b=%d; c=%d; d=%d; e=%d; f=%d; g=%d; h=%d012\000"
main:
; prolog:
        lui
                $28,%hi(__gnu_local_gp)
        addiu
                $sp,$sp,-56
                $28,$28,%lo(__gnu_local_gp)
        addiu
        SW
                $31,52($sp)
; zapisz 5. argument na stosie:
                                         # 0x4
        li
                $2,4
                $2,16($sp)
        SW
; zapisz 6. argument na stosie:
        li
                                         # 0x5
                $2,5
                $2,20($sp)
        SW
; zapisz 7. argument na stosie:
        li
                $2,6
                                         # 0x6
                $2,24($sp)
        SW
; zapisz 8. argument na stosie:
        li
                $2,7
                                         # 0×7
        lw
                $25,%call16(printf)($28)
        SW
                $2,28($sp)
; zapisz 1 argument w $a0:
                $4,%hi($LC0)
        lui
; zapisz 9 argument na stosie:
                $2,8
                                         # 0x8
        li
                $2,32($sp)
        SW
        addiu
                $4,$4,%lo($LC0)
; zapisz 2 argument w $a1:
                                         # 0x1
        li
                $5,1
; zapisz 3 argument w $a2:
        li
                $6,2
                                         # 0x2
; wywołaj printf():
        jalr
                $25
; zapisz 4 argument w $a3 (branch delay slot):
        li
                $7,3
; epilog:
                $31,52($sp)
        lw
; ustaw wartość zwracaną na 0:
        move
                $2,$0
; zwróć wartość
                $31
        j
                $sp,$sp,56 ; branch delay slot
        addiu
```

Listing 1.63: Optymalizujący GCC 4.4.5 (IDA)

```
.text:00000000 main:
.text:00000000
.text:00000000 var_28 = -0x28
.text:00000000 var_24 = -0x24
.text:00000000 var_20 = -0x20
.text:00000000 var_1C = -0x1C
```

```
.text:00000000 var 18
                                = -0 \times 18
.text:00000000 var 10
                                = -0 \times 10
.text:00000000 var 4
                                = -4
.text:00000000
; prolog:
.text:00000000
                                lui
                                         $gp, (__gnu_local_gp >> 16)
.text:00000004
                                addiu
                                         sp, -0x38
.text:00000008
                                         $gp, (__gnu_local_gp & 0xFFFF)
                                la
.text:0000000C
                                         $ra, 0x38+var_4($sp)
                                SW
.text:00000010
                                         $gp, 0x38+var_10($sp)
                                SW
; zapisz 5. argument na stosie:
.text:00000014
                                         $v0, 4
                                lί
.text:00000018
                                         $v0, 0x38+var_28($sp)
; zapisz 6. argument na stosie:
.text:0000001C
                                li
                                         $v0, 5
                                         $v0, 0x38+var_24($sp)
.text:00000020
; zapisz 7. argument na stosie:
.text:00000024
                                lί
                                         $v0, 6
.text:00000028
                                         $v0, 0x38+var_20($sp)
                                SW
; zapisz 8. argument na stosie:
.text:0000002C
                                li
                                         $v0, 7
.text:00000030
                                lw
                                         $t9, (printf & 0xFFFF)($gp)
.text:00000034
                                SW
                                         $v0, 0x38+var_1C($sp)
; przygotuj 1. argument w $a0:
.text:00000038
                                lui
                                         $a0, ($LC0 >> 16) # "a=%d; b=%d;
   c=%d; d=%d; e=%d; f=%d; g=%"...
 zapisz 9. argument na stosie:
.text:0000003C
                                li
                                         $v0, 8
                                         $v0, 0x38+var_18($sp)
.text:00000040
zapisz 1. argument w $a0:
                                         a0, ($LC0 & 0xFFFF) # "a=%d; b=%d;
.text:00000044
                                la
   c=%d; d=%d; e=%d; f=%d; g=%"...
; zapisz 2. argument w $a1:
.text:00000048
                                li
                                         $a1, 1
; zapisz 3. argument w $a2:
.text:0000004C
                                li
                                         $a2, 2
; wywołaj printf():
.text:00000050
                                jalr
                                         $t9
; zapisz 4. argument w $a3 (branch delay slot):
.text:00000054
                                li
                                         $a3, 3
; epilog:
.text:00000058
                                lw
                                         $ra, 0x38+var_4($sp)
; ustaw wartość zwracaną na 0:
.text:0000005C
                                move
                                         $v0, $zero
; zwróć wartość
.text:00000060
                                jr
                                         $ra
.text:00000064
                                addiu
                                         $sp, 0x38; branch delay slot
```

Nieoptymalizujący GCC 4.4.5

Nieoptymalizujący GCC generuje nieco rozwlekły kod:

Listing 1.64: Nieoptymalizujący GCC 4.4.5 (wyjście w asemblerze)

```
$LC0:
        .ascii "a=%d; b=%d; c=%d; d=%d; e=%d; f=%d; g=%d; h=%d012\000"
main:
; prolog:
        addiu
                $sp,$sp,-56
        SW
                $31,52($sp)
        SW
                 $fp,48($sp)
        move
                $fp,$sp
                $28,%hi(__gnu_local_gp)
        lui
                $28,$28,\sqrt{0}[o(\_gnu_local_gp)
        addiu
                $2,%hi($LC0)
        lui
                $2,$2,%lo($LC0)
        addiu
; zapisz 5. argument na stosie:
                                          # 0x4
        li
                $3,4
                $3,16($sp)
        SW
; zapisz 6. argument na stosie:
        li
                $3,5
                                          # 0x5
        SW
                $3,20($sp)
; zapisz 7. argument na stosie:
                                          # 0x6
        li
                $3,6
        SW
                $3,24($sp)
; zapisz 8. argument na stosie:
        li
                $3,7
                                          # 0x7
        SW
                $3,28($sp)
; zapisz 9. argument na stosie:
        li
                $3,8
                                          # 0x8
                $3,32($sp)
        SW
; zapisz 1. argument w $a0:
        move
                $4,$2
; zapisz 2. argument w $a1:
        li
                $5,1
                                          # 0x1
; zapisz 3. argument w $a2:
                $6,2
        li
                                          # 0x2
; zapisz 4. argument w $a3:
                                          # 0x3
        li
                $7,3
; wywołaj printf():
        lw
                $2,%call16(printf)($28)
        nop
        move
                $25,$2
                $25
        jalr
        nop
; epilog:
                $28,40($fp)
        lw
; ustaw wartość zwracaną na 0:
        move
                $2,$0
        move
                $sp,$fp
                $31,52($sp)
        lw
                $fp,48($sp)
        lw
        addiu
                $sp,$sp,56
; zwróć wartość:
        j
                $31
        nop
```

Listing 1.65: Nieoptymalizujący GCC 4.4.5 (IDA)

```
.text:00000000 main:
.text:00000000
.text:00000000 var_28
                                = -0x28
.text:00000000 var_24
                                = -0 \times 24
.text:00000000 var_20
                                = -0x20
.text:00000000 var_1C
                                = -0 \times 10
.text:00000000 var_18
                                = -0x18
.text:00000000 var_10
                                = -0 \times 10
.text:00000000 var_8
                                = -8
.text:00000000 var_4
                                = -4
.text:00000000
; prolog:
.text:00000000
                                         $sp, -0x38
                                addiu
.text:00000004
                                         $ra, 0x38+var 4($sp)
                                SW
.text:00000008
                                         $fp, 0x38+var_8($sp)
                                SW
.text:0000000C
                                move
                                         $fp, $sp
.text:00000010
                                         $gp,
                                                _gnu_local_gp
                                la
.text:00000018
                                         $gp, 0x38+var_10($sp)
                                SW
                                         v0, aADBDCDDDEDFDGD # "a=%d; b=%d;
.text:0000001C
                                la
   c=%d; d=%d; e=%d; f=%d; g=%"...
; zapisz 5. argument na stosie:
                                li
.text:00000024
                                         $v1, 4
.text:00000028
                                         v1, 0x38+var_28(sp)
; zapisz 6. argument na stosie:
.text:0000002C
                                li
                                         $v1, 5
.text:00000030
                                         $v1, 0x38+var_24($sp)
                                SW
; zapisz 7. argument na stosie:
.text:00000034
                                 li
                                         $v1, 6
.text:00000038
                                         $v1, 0x38+var_20($sp)
                                SW
; zapisz 8. argument na stosie:
.text:0000003C
                                li
                                         $v1, 7
.text:00000040
                                         $v1, 0x38+var_1C($sp)
; zapisz 9. argument na stosie:
.text:00000044
                                li
                                         $v1, 8
.text:00000048
                                         $v1, 0x38+var_18($sp)
                                SW
; zapisz 1. argument w $a0:
.text:0000004C
                                         $a0, $v0
                                move
; zapisz 2. argument w $a1:
.text:00000050
                                li
                                         $a1, 1
; zapisz 3. argument w $a2:
.text:00000054
                                li
                                         $a2, 2
; zapisz 4. argument w $a3:
.text:00000058
                                li
                                         $a3, 3
; wywołaj printf():
.text:0000005C
                                lw
                                         $v0, (printf & 0xFFFF)($gp)
                                         $at, $zero
.text:00000060
                                or
.text:00000064
                                         $t9, $v0
                                move
.text:00000068
                                jalr
                                         $t9
.text:0000006C
                                or
                                         $at, $zero ; NOP
; epilog:
.text:00000070
                                lw
                                         $gp, 0x38+var_10($fp)
; ustaw wartość zwracaną na 0:
```

```
.text:00000074
                                        $v0, $zero
                                move
                                        $sp, $fp
.text:00000078
                                move
.text:0000007C
                                lw
                                        $ra, 0x38+var 4($sp)
.text:00000080
                                lw
                                        $fp, 0x38+var_8($sp)
.text:00000084
                                addiu
                                        $sp, 0x38
; zwróć wartość:
.text:00000088
                                jr
                                        $ra
.text:0000008C
                                        $at, $zero; NOP
                                or
```

1.11.4 Wnioski

Tak wygląda szkielet wywołania funkcji:

Listing 1.66: x86

```
PUSH 3. argument
PUSH 2. argument
PUSH 1. argument
CALL funkcja
; zmodyfikuj wskaźnik stosu (jeśli trzeba)
```

Listing 1.67: x64 (MSVC)

```
MOV RCX, 1. argument
MOV RDX, 2. argument
MOV R8, 3. argument
MOV R9, 4. argument
...
PUSH 5., 6., ... argument; (jeśli trzeba)
CALL funkcja
; zmodyfikuj wskaźnik stosu (jeśli trzeba)
```

Listing 1.68: x64 (GCC)

```
MOV RDI, 1. argument
MOV RSI, 2. argument
MOV RDX, 3. argument
MOV RCX, 4. argument
MOV R8, 5. argument
MOV R9, 6. argument
...
PUSH 7., 8., ... argument; (jeśli trzeba)
CALL funkcja
; zmodyfikuj wskaźnik stosu (jeśli trzeba)
```

Listing 1.69: ARM

```
MOV R0, 1. argument
MOV R1, 2. argument
MOV R2, 3. argument
MOV R3, 4. argument
; przekaż 5., 6., ... argument przez stos (jeśli trzeba)
```

```
BL funkcja
; zmodyfikuj wskaźnik stosu (jeśli trzeba)
```

Listing 1.70: ARM64

```
MOV X0, 1. argument
MOV X1, 2. argument
MOV X2, 3. argument
MOV X3, 4. argument
MOV X4, 5. argument
MOV X5, 6. argument
MOV X6, 7. argument
MOV X7, 8. argument
; przekaż 9., 10., ... argument przez stos (jeśli trzeba)
BL funkcja
; zmodyfikuj wskaźnik stosu (jeśli trzeba)
```

Listing 1.71: MIPS (konwencja wywoływania O32)

```
LI $4, 1. argument; AKA $A0
LI $5, 2. argument; AKA $A1
LI $6, 3. argument; AKA $A2
LI $7, 4. argument; AKA $A3
; przekaż 5., 6., ... argument, przez stos (jeśli trzeba)
LW temp_reg, adress funkcji
JALR temp_reg
```

1.11.5 Przy okazji

Różnice między przekazywaniem argumentów funkcji w x86, x64, fastcall, ARM i MIPS pokazują, że procesorowi jest bez różnicy, jak będą przekazywane argumenty do funkcji. Można by stworzyć kompilator, który będzie je przekazywał za pomocą wskaźnika na strukturę z argumentami, nie korzystając ze stosu w ogóle.

Rejestry \$A0...\$A3 w MIPS są nazwane w ten sposób tylko dla wygody (jest tak w konwencji wywoływania O32). Programiści mogą korzystać z jakichkolwiek innych rejestrów (może oprócz \$ZERO) do przekazywania argumentów i dowolnej konwencji wywoływania funkcji.

CPU w żaden sposób nie jest świadomy jakiej metody używamy.

Początkujący programiści asemblera często przekazują argumenty do funkcji przez rejestry, bez wyraźnego porządku lub nawet przez zmienne globalne.

To też będzie działać poprawnie.

1.12 scanf()

Tym razem zajmiemy się funkcją scanf ()

1.12.1 Prosty przykład

```
#include <stdio.h>
int main()
{
    int x;
    printf ("Enter X:\n");
    scanf ("%d", &x);
    printf ("You entered %d...\n", x);
    return 0;
};
```

Używanie scanf () do interakcji z użytkownikiem nie jest dobrym pomysłem w dzisiejszych czasach, jednak mimo wszystko funkcja ta jest dobrym przykładem użycia wskaźnika na zmienną typu *int*.

O wskaźnikach

Wskaźniki są jednym z podstawowych pojęć informatycznych. Często przekazywanie dużej tablicy, struktury lub obiektu do innej funkcji jest pamięciożerne, podczas gdy przekazanie samego adresu jest znacznie tańsze.

Kiedy chcesz wypisać tekst w konsoli, najprościej będzie wskazać jego adres w pamięci.

W dodatku, jeśli wywoływana funkcja potrzebuje zmodyfikować cokolwiek w dużej tablicy lub strukturze danych przekazanej jako parametr a następnie ją zwrócić, kopiowanie tylu danych byłoby prawie absurdalne. Dlatego najprościej będzie przekazać adres tej tablicy/struktury do wywoływanej funkcji i wtedy zmodyfikować to, co wymaga modyfikacji.

Wskaźnik w C/C++—jest adresem pewnego miejsca w pamięci.

W x86 adresy są reprezentowane przy pomocy 32-bitowych liczb (czyli 4 bajtowych), a w x86-64 jako liczby 64-bitowe (czyli 8 bajtowe). Przy okazji jest to powód dlaczego niektórych ludzi oburza przeskok na x86-64—wszystkie wskaźniki w architekturze x64 wymagają dwa razy więcej miejsca, włączając pamięć cache, która jest bardzo "kosztowna".

Można pracować jedynie z nietypowanymi wskaźnikami, wymaga to jednak nieco wysiłku, np. użycia funkcji z biblioteki standardowej C memcpy(), która kopiuje blok z jednego miejsca w pamięci do drugiego. memcpy() jako argumenty przyjmuje 2 wskaźniki typu void*, co umożliwia kopiowanie dowolnych typów danych. Typy danych nie są istotne, znaczenie mają tylko rozmiary bloków pamięci.

Wskaźniki są także często używane kiedy funkcja potrzebuje zwrócić więcej niż jedną wartość (wrócę do tego później (?? on page ??)).

Funkcja scanf() jest takim przypadkiem. Poza tym, że funkcja scanf () zwraca liczbę wczytanych wartości, to musi jeszcze je jakoś przekazać.

W C/C++ typ wskaźnika jest potrzebny tylko do sprawdzania typów podczas kompilacji.

W skompilowanym kodzie nie ma żadnej informacji jakiego typu są wskaźniki.

x86

MSVC

Poniższy kod otrzymamy po kompilacji za pomocą MSVC 2010:

```
CONST
         SEGMENT
$SG3831
           DB
                  'Enter X:', 0aH, 00H
$SG3832
           DB
                  '%d', 00H
$SG3833
           DB
                  'You entered %d...', OaH, OOH
CONST
         ENDS
PUBLIC
          main
         _scanf:PROC
EXTRN
          _printf:PROC
EXTRN
; Ustawione opcje kompilacji funkcji: /Odtp
_TEXT
_x$ = -4
         SEGMENT
                                 : size = 4
         PR0C
_main
    push
           ebp
   mov
           ebp, esp
    push
           ecx
           OFFSET $SG3831 ; 'Enter X:'
    push
    call
           printf
    add
           esp, 4
    lea
           eax, DWORD PTR _x$[ebp]
    push
           OFFSET $SG3832 ; '%d'
    push
    call
           _scanf
    add
           esp, 8
           ecx, DWORD PTR _x$[ebp]
    mov
    push
           ecx
           OFFSET $SG3833 ; 'You entered %d...'
    push
           _printf
    call
    add
           esp, 8
    ; zwróć 0
           eax, eax
    xor
           esp, ebp
    mov
    pop
           ebp
    ret
           0
         ENDP
main
TEXT
         ENDS
```

x jest zmienną lokalną.

Według standardu C/C++ zmienna lokalna może być widoczna tylko w konkretnej funkcji. Tradycyjnie zmienne lokalne są przechowywane na stosie. Prawdopodobnie są inne moliwości przechowywania tych zmiennych, ale tak akurat jest w x86.

Zadaniem instrukcji rozpoczynającej funkcję, PUSH ECX, nie jest zapisanie stanu ECX (można zauważyć brak odpowiadającej instrukcji POP ECX na końcu funkcji).

Tak naprawdę instrukcja ta alokuje 4 bajty na stosie do przechowania zmiennej x.

Dostęp do x odbywa się za pomocą makra _x\$ (-4) i rejestru EBP, który wskazuje na bieżącą ramkę.

W trakcie wykonywania funkcji EBP wskazuje na bieżącą ramkę stosu, umożliwiając dostęp do zmiennych lokalnych i argumentów funkcji poprzez EBP+offset.

Można by użyć w tym celu rejestru ESP, ale nie byłoby to zbyt wygodne, ponieważ wartość tego rejestru często się zmienia. Wartość EBP może być postrzegana jako zachowana wartość ESP z początku wykonania funkcji.

Poniżej pokazano typowy układ ramki stosu w środowisku 32-bitowym:

EBP-8	zmienna lokalna #2, oznaczony w programie IDA jako var_8	
EBP-4	zmienna lokalna #1, oznaczony w programie IDA jako var_4	
EBP	zapisana wartość EBP	
EBP+4	adres powrotu	
EBP+8	argument#1, oznaczony w programie IDA jako arg_0	
EBP+0xC	argument#2, oznaczony w programie IDA jako arg_4	
EBP+0x10	argument#3, oznaczony w programie IDA jako arg_8	
	···	

Funkcja scanf () w naszym przykładzie ma dwa argumenty.

Pierwszy jest wskaźnikiem na łańcuch znaków %d a drugi jest adresem zmiennej x.

Na początku adres zmiennej x jest ładowany do rejestru EAX przy pomocy instrukcji lea eax, DWORD PTR x\$[ebp].

LEA oznacza *load effective address* i jest często używana do formowania adresów (**??** on page ??).

Można powiedzieć, że w tym przypadku LEA po prostu umieszcza sumę rejestru EBP i makra x\$ w rejestrze EAX.

W tym przypadku ($_x$ \$ = -4) jest to samo co lea eax, [ebp-4]. Więc od rejestru EBP jest odejmowane 4 i wynik zostaje umieszczony w rejestrze EAX. Następnie wartość rejestru EAX jest odkładana na stos i funkcja scanf() zostaje wywołana.

Kolejno następuje przygotowanie do wywołania funkcji printf(). Pierwszym argumentem jest wskaźnik na łańcuch znaków: You entered %d...\n.

Drugi argument jest przygotowywany za pomocą: mov ecx, [ebp-4]. Instrukcja kopiuje zmienną x (nie jej adres) do rejestru ECX.

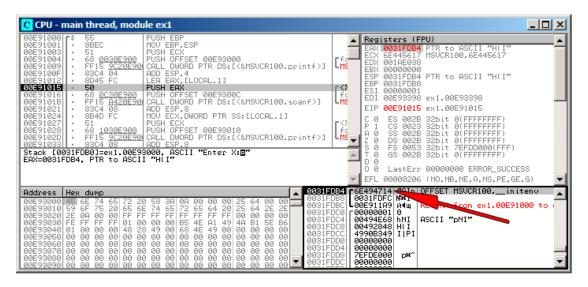
Następnie wartość z ECX jest odkładana na stos, a na koniec zostaje wywołana funkcja printf().

MSVC + OllyDbg

Otwórzmy przykład w OllyDbg. Po załadowaniu wciskamy kilka razy F8, aż dotrzemy do naszego pliku wykonywalnego, zamiast ntdll.dll. Scrollujemy na górę, aż pojawi się funkcja main().

Kliknij na pierwszą instrukcję (PUSH EBP) i naciśnij F2 (*ustaw breakpoint*), a następnie F9 (*Run*). Zatrzymamy się na początku funkcji main.

Przejdźmy do miejsca, w którym wyliczany jest adres zmiennej x:



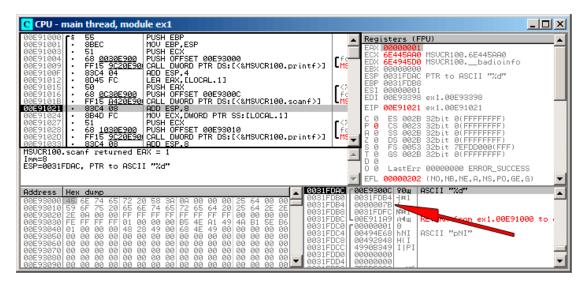
Rysunek 1.13: OllyDbg: wyliczanie adresu zmiennej lokalnej

Kliknij prawym przyciskiem na rejestr EAX w oknie z rejestrami i wybierz "Follow in stack".

Adres z EAX pojawi się w oknie z widokiem stosu. Czerwona strzałka pokazuje na zmienną lokalną na stosie. W tej chwili są tam śmieci — (0x6E494714). Za pomocą instrukcji PUSH adres tego elementu na stosie również trafi na stos, jako kolejny element. Wciskając F8, przejdźmy za wywołanie funkcji scanf(). W trakcie wykonywania funkcji musimy podać jakiś wejściowy ciąg znaków w oknie konsoli, np. "123".

```
Enter X: 123
```

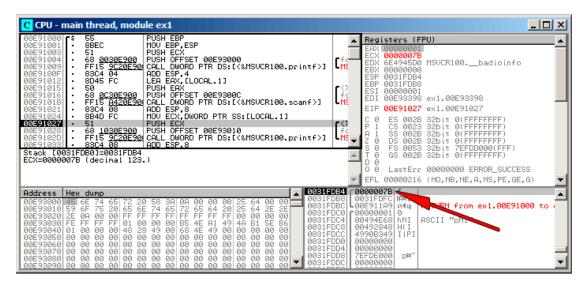
Funkcja scanf() zakończyła swoje wykonanie.



Rysunek 1.14: OllyDbg: stan po zakończeniu funkcji scanf ()

Funkcja scanf() zwróciła 1 w EAX, co oznacza, że wczytała jedną wartość. Jeśli ponownie spojrzymy na element na stosie odpowiadający zmiennej lokalnej, zobaczymy, że ma on teraz wartość 0x7B (123).

Później wartość zostanie skopiowana ze stosu do rejestru ECX i przekazana do funkcji printf():



Rysunek 1.15: OllyDbg: przygotowanie argumentu funkcji printf()

GCC

Tak wygląda skompilowany kod w GCC 4.4.1 w systemie Linux:

```
main
                proc near
var_20
                = dword ptr -20h
var_1C
                = dword ptr -1Ch
var 4
                = dword ptr -4
                push
                        ebp
                mov
                        ebp, esp
                        esp, 0FFFFFF0h
                and
                        esp, 20h
                sub
                        [esp+20h+var_20], offset aEnterX ; "Enter X:"
                mov
                call
                        _puts
                        eax, offset aD ; "%d"
                mov
                        edx, [esp+20h+var 4]
                lea
                        [esp+20h+var_1C], edx
                mov
                        [esp+20h+var 20], eax
                mov
                call
                           isoc99 scanf
                mov
                        edx, [esp+20h+var 4]
                        eax, offset aYouEnteredD ; "You entered %d...\n"
                mov
                         [esp+20h+var_1C], edx
                mov
                        [esp+20h+var_20], eax
                mov
                        _printf
                call
                        eax, 0
                mov
```

	leave
	retn
main	endp

GCC zamienia wywołanie funkcji printf() na wywołanie funkcji puts(). Powód tego został wyjaśniony w (1.5.3 on page 29).

Jak w przykładzie z MSVC—argumenty funkcji są umieszczane na stosie przy użyciu instrukcji MOV.

Nawiasem mówiąc...

Ten prosty przykład pokazuje, że kompilatory rzeczywiście tłumaczą listę instrukcji języka C na serię instrukcji kodu maszynowego. W kodzie C wykonanie odbywa się instrukcja po instrukcji i podobnie jest w kodzie maszynowym - między instrukcjami nie ma nic więcej.

x64

Sposób wykonania programy będzie niemal taki sam, z tą różnicą, że argumenty tym razem będą będą przekazywane przez rejestry, a nie przez stos.

MSVC

Listing 1.72: MSVC 2012 x64

```
DATA
        SEGMENT
$SG1289 DB
                 'Enter X:', 0aH, 00H
$SG1291 DB
                 '%d', 00H
$SG1292 DB
                 'You entered %d...', OaH, OOH
DATA
        ENDS
_TEXT
        SEGMENT
\bar{x}$ = 32
        PR<sub>0</sub>C
main
$LN3:
        sub
                 rsp, 56
        lea
                 rcx, OFFSET FLAT: $SG1289; 'Enter X:'
        call
                 printf
        lea
                 rdx, QWORD PTR x$[rsp]
                 rcx, OFFSET FLAT:$SG1291; '%d'
        lea
                 scanf
        call
        mov
                 edx, DWORD PTR x$[rsp]
                 rcx, OFFSET FLAT:$SG1292; 'You entered %d...'
        lea
        call
                 printf
        : zwróć 0
                 eax, eax
        xor
                 rsp, 56
        add
        ret
                 0
```

```
main ENDP
_TEXT ENDS
```

GCC

Listing 1.73: Optymalizujący GCC 4.4.6 x64

```
.LC0:
        .string "Enter X:"
.LC1:
        .string "%d"
.LC2:
        .string "You entered %d...\n"
main:
        sub
                 rsp, 24
                 edi, OFFSET FLAT:.LC0 ; "Enter X:"
        mov
        call
                 puts
        lea
                 rsi, [rsp+12]
                 edi, OFFSET FLAT:.LC1 ; "%d" \,
        mov
        xor
                 eax, eax
        call
                  _isoc99_scanf
                 esi, DWORD PTR [rsp+12]
        mov
                 edi, OFFSET FLAT: LC2; "You entered %d...\n"
        mov
                 eax, eax
        xor
        call
                 printf
        ; zwróć 0
        xor
                 eax, eax
        add
                 rsp, 24
        ret
```

ARM

Optymalizujący Keil 6/2013 (tryb Thumb)

```
.text:00000042
                            scanf_main
.text:00000042
.text:00000042
                                            = -8
                            var_8
.text:00000042
.text:00000042 08 B5
                             PUSH
                                     {R3,LR}
.text:00000044 A9 A0
                             ADR
                                     R0, aEnterX ; "Enter X:\n"
.text:00000046 06 F0 D3 F8
                             BL
                                       _2printf
.text:0000004A 69 46
                             MOV
                                     R1, SP
                                     R0, aD ; "%d"
.text:0000004C AA A0
                             ADR
.text:0000004E 06 F0 CD F8 BL
                                      0scanf
.text:00000052 00 99
                             LDR
                                     R1, [SP,#8+var_8]
.text:00000054 A9 A0
                                     R0, aYouEnteredD____; "You entered
                             ADR
%d...\n"
.text:00000056 06 F0 CB F8 BL
                                     __2printf
```

.text:0000005A 00 20	MOVS	R0, #0
.text:0000005C 08 BD	P0P	{R3,PC}

Funkcja scanf () potrzebuje argumentu— wskaźnika na *int*, by mogła zapisać wycztaną wartość. *int* jest 32-bitowy i zmieści się idealnie do 32-bitowego rejestru. Miejsce na zmienną lokalną x jest zaalokowane na stosie, IDA oznaczyła przesunięcie względem SP makrem *var_8*. Można by się bez niego obyć, gdyż SP (wskaźnik stosu) już pokazuje na to miejsce i mógły być użyty bezpośrednio.

Wartość z SP jest kopiowany do rejestru R1 i razem z łańcuchem znaków formatu przekazywana jako argumenty do funkcji scanf().

Instrukcja PUSH/POP zachowuje się inaczej niż na x86 (odwrotnie). Są synonimami instrukcji

STM/STMDB/LDM/LDMIA. PUSH najpierw zapisuje wartość na stosie, a następnie zmniejsza SP o 4. POP najpierw dodaje 4 do SP, a następnie wczytuje wartość ze stosu. Stąd po wykonaniu PUSH, SP pokazuje na nieużywane miejsce na stosie. Zostanie ono wykorzystane przez scanf(), a następnie printf() do zapisania i wczytania zmiennej lokalnej.

LDMIA oznacza Load Multiple Registers Increment address After each transfer. STMDB oznacza Store Multiple Registers Decrement address Before each transfer.

Później, za pomocą instrukcji LDR, wartość zmiennej lokalnej jest wczytywana ze stosu do rejestru R1, by następnie zostać przekazana do funkcji printf().

ARM64

Listing 1.74: Nieoptymalizujący GCC 4.9.1 ARM64

```
.LC0:
 2
            .string "Enter X:"
 3
    .LC1:
 4
            .string "%d"
 5
    .LC2:
 6
            .string "You entered %d...\n"
 7
    scanf_main:
    ; odejmij 32 od SP, a następnie zapisz FP i LR w ramce stosu
 8
 9
                    x29, x30, [sp, -32]!
            stp
10
    ; ustaw wskaźnik ramki stosu (FP=SP)
11
            add
                    x29, sp, 0
12
    ; wczytaj wskaźnik na łańcuch znaków "Enter X:":
13
            adrp
                    x0, .LC0
                    x0, x0, :lo12:.LC0
14
15
    ; X0=wskaźnik na łańcuch znaków "Enter X:"
16
    ; wypisz go:
17
            bl
                    puts
    ; wczytaj wskaźnik na łańcuch znaków "%d":
18
19
                    x0, .LC1
            adrp
20
            add
                    x0, x0, :lo12:.LC1
   ; znajdź miejsce w ramce stosu na zmienną "x" (X1=FP+28):
21
22
            add
                    x1, x29, 28
```

```
23
   ; X1=adres zmiennej "x"
24
   ; przekaż adres do funkcji scanf() i ją wywołaj:
25
            bl
                      isoc99 scanf
26
   ; załaduj 32-bitową wartość zmiennej z ramki stosu:
27
            ldr
                    w1, [x29,28]
28
    ; W1=x
    ; wczytaj wskaźnik na łańcuch znaków "You entered %d...\n"
29
   ; argumenty printf() - łańcuch znaków z X0 i zmienna "x" z X1 (W1 to młodsze
30
       32 bity)
31
                    x0, .LC2
            adrp
32
            add
                    x0, x0, :lo12:.LC2
33
            bl
                    printf
34
    ; zwróć 0
35
                    w0, 0
            mov
36
    ; przywróć FP i LR, a następnie dodaj 32 do SP:
37
            ldp
                    x29, x30, [sp], 32
38
            ret
```

Na ramkę stosu zaalokowano 32 bajty, a więc więcej niż to konieczne. Być może jest to efekty wyrównywania pamięci? Najciekawszym fragmetem jest szukanie położenia zmiennej x w obrębie ramki stosu (linia 22). Dlaczego 28? Z jakiegoś powodu kompilator zdecydował umieścić zmienną na końcu ramki stosu, a nie na początku. Adres jest przekazywany do funkcji scanf (), która umieszcza pod tym adresem wartość wpisaną przez użytkownika. Jest to 32-bitowa wartość typu int. Wartość jest pobierana w linii 27 a następnie przekazywana do funkcji printf ().

MIPS

Na stosie lokalnym zaalokowano miejsce dla zmiennej x, odwoływać będziemy się do niej przez \$sp + 24.

Adres zmiennej przekazywany jest do funkcji scanf(). Wartość wpisana przez użytkownika i odczytana za pomocą scanf() jest następnie wczytywana za pomocą instrukcji LW ("Load Word") i przekazywana do printf().

Listing 1.75: Optymalizujący GCC 4.4.5 (wyjście w asemblerze)

```
$LC0:
        .ascii
                "Enter X:\000"
$LC1:
        .ascii
                 "%d\000"
$1 C2:
        .ascii
                 "You entered %d...\012\000"
main:
; prolog:
        lui
                 $28,%hi(__gnu_local_gp)
        addiu
                 $sp,$sp,-40
        addiu
                 $28,$28,%lo( gnu local gp)
        SW
                 $31,36($sp)
; wywołaj puts():
                 $25,%call16(puts)($28)
        lw
        lui
                 $4,%hi($LC0)
        jalr
                 $25
```

```
addiu
                $4,$4,%lo($LCO); branch delay slot
; wywołaj scanf():
        lw
                $28,16($sp)
        lui
                $4,%hi($LC1)
                $25,%call16(__isoc99_scanf)($28)
        lw
; ustaw 2.argument funkcji scanf(), $a1=$sp+24:
        addiu
                $5,$sp,24
                $25
        jalr
        addiu
                $4,$4,%lo($LC1); branch delay slot
; wywołaj printf():
                $28,16($sp)
        lw
; ustaw 2. argument funkcji printf(),
; załaduj słowo word z adresu $sp+24:
        lw
                $5,24($sp)
                $25,%call16(printf)($28)
        lw
                $4,%hi($LC2)
        lui
        jalr
                $25
        addiu
                $4,$4,%lo($LC2); branch delay slot
; epilog:
                $31,36($sp)
        lw
; ustaw wartość zwracana na 0:
        move
                $2,$0
; zwróć wartość:
                $31
        j
                                 ; branch delay slot
        addiu
                $sp,$sp,40
```

IDA wyświetla układ stosu następująco:

Listing 1.76: Optymalizujący GCC 4.4.5 (IDA)

```
.text:00000000 main:
.text:00000000
.text:00000000 var 18
                         = -0x18
.text:00000000 var 10
                         = -0 \times 10
.text:00000000 var 4
                         = -4
.text:00000000
; prolog:
.text:00000000
                                 $gp, (__gnu_local_gp >> 16)
                         lui
.text:00000004
                                 $sp, -0x28
                         addiu
.text:00000008
                         la
                                 $gp, (__gnu_local_gp & 0xFFFF)
.text:0000000C
                                 $ra, 0x28+var_4($sp)
                         SW
.text:00000010
                         SW
                                 $gp, 0x28+var_18($sp)
; wywołaj puts():
.text:00000014
                         lw
                                 $t9, (puts & 0xFFFF)($gp)
.text:00000018
                         lui
                                 $a0, ($LC0 >> 16) # "Enter X:"
.text:0000001C
                         jalr
                                 $t9
                                 $a0, ($LCO & 0xFFFF) # "Enter X:"; branch
.text:00000020
                         la
   delay slot
; wywołaj scanf():
.text:00000024
                                 $gp, 0x28+var_18($sp)
                         lw
.text:00000028
                         lui
                                 $a0, ($LC1 >> 16) # "%d"
                                 $t9, (__isoc99_scanf & 0xFFFF)($gp)
.text:0000002C
                         lw
```

```
ustaw 2. argument funkcji scanf(), $a1=$sp+24:
.text:00000030
                        addiu
                                 $a1, $sp, 0x28+var 10
.text:00000034
                        jalr
                                 $t9 ; branch delay slot
                                 $a0, ($LC1 & 0xFFFF) # "%d"
.text:00000038
                        la
; call printf():
.text:0000003C
                                 p, 0x28+var_18(sp)
                        lw
; ustaw 2. argument funkcji printf(),
; załaduj słowo z adresu $sp+24:
.text:00000040
                        lw
                                 $a1, 0x28+var_10($sp)
.text:00000044
                                 $t9, (printf & 0xFFFF)($gp)
                        ٦w
.text:00000048
                        lui
                                 $a0, ($LC2 >> 16) # "You entered %d...\n"
.text:0000004C
                        jalr
                                 $t9
                                 $a0, ($LC2 & 0xFFFF) # "You entered %d...\n"
.text:00000050
                        la
     branch delay slot
; epilog:
.text:00000054
                        lw
                                 $ra, 0x28+var 4($sp)
; ustaw wartość zwracaną na 0:
.text:00000058
                                 $v0, $zero
                        move
; zwróć wartość:
.text:0000005C
                        jr
                                 $ra
.text:00000060
                        addiu
                                 $sp, 0x28 ; branch delay slot
```

1.12.2 Popularny błąd

Bardzo popularnym błędem jest podanie jako argumentu zmiennej x zamiast wskaźnika na zmienną x:

```
#include <stdio.h>
int main()
{
    int x;
    printf ("Enter X:\n");
    scanf ("%d", x); // BUG
    printf ("You entered %d...\n", x);
    return 0;
};
```

Co się wtedy stanie? Zmienna x jest niezainicjalizowana i zawiera losowe śmieci z lokalnego stosu. Kiedy funkcja scanf() jest wywoływana, pobiera ciąg znaków od użytkownika, parsuje jako liczbę i próbuje ją zapisać w x, traktując wartość x jak adres w pamięci. Jednak skoro tam są losowe śmieci ze stosu, scanf() będzie próbować uzyskać dostęp do losowego adresu. Najprawdopodobniej proces natychmiast zakończy się błędem.

Co ciekawe, niektóre biblioteki CRT w wersji do debugowania, umieszczają w pamięci, która jest alokowana, widoczne wzorce takie jak 0xCCCCCCC albo 0x0BADF00D itp. W tym przypadku x może zawierać 0xCCCCCCC, więc scanf() będzie próbowała zapisać pod adres 0xCCCCCCCC. Jeśli zauważysz, że coś w procesie próbuje

zapisać pod 0xCCCCCCC, to znaczy, że została użyta niezainicjalizowana zmienna (lub wskaźnik). Jest to lepsze rozwiązanie niż gdyby nowo alokowana pamięć była po prostu wyzerowana.

1.12.3 Zmienne globalne

A jeśli zmienna x z poprzedniego przykładu nie będzie zmienną lokalną, a globalną? Wtedy będzie dostępna z każdego miejsca w programie, nie tylko wewnątrz funkcji. Zmienne globalne są uważane za antywzorzec, ale w celu eksperymentu możemy tak zrobić:

```
#include <stdio.h>

// x jest teraz zmienną globalną
int x;

int main()
{
    printf ("Enter X:\n");
    scanf ("%d", &x);
    printf ("You entered %d...\n", x);
    return 0;
};
```

MSVC: x86

```
DATA
         SEGMENT
        _x:DWORD
COMM
$SG2456
           DB
                 'Enter X:', 0aH, 00H
           DB
                 '%d', 00H
$SG2457
$SG2458
                 'You entered %d...', OaH, OOH
           DB
         ENDS
DATA
PUBLIC
          _main
         _scanf:PROC
EXTRN
         _printf:PROC
EXTRN
; Function compile flags: /Odtp
_TEXT
         SEGMENT
_main
         PR0C
    push
           ebp
    mov
           ebp, esp
           OFFSET $SG2456
    push
           _printf
    call
    add
           esp, 4
           0FFSET
    push
           OFFSET $SG2457
    push
           _scanf
    call
    add
           esp, 8
    mov
           eax, DWORD PTR _x
```

```
push
           eax
   push
           OFFSET $SG2458
   call
           printf
   add
           esp, 8
   xor
           eax, eax
   pop
           ebp
   ret
           0
_main
         ENDP
TEXT
         ENDS
```

W tym przypadku zmienna x jest zdefiniowana w segmencie _DATA i nie następuje alokacja pamięci na stosie lokalnym. Dostęp do zmiennej jest bezpośredni, z pominięciem stosu. Niezainicjalizowane zmienne globalne nie zajmują miejsca w pliku wykonywalnym (po co alokować wyzerowaną pamięć?), dopiero w momencie odwołania pod adres zmiennej, OS alokuje blok pamieci, wypełniony zerami.

Przypiszmy teraz wprost wartość do zmiennej:

```
int x=10; // wartość domyślna
```

Otrzymamy:

```
_DATA SEGMENT
_x DD 0aH
```

Widać przypisaną wartość 0xA typu DWORD (DD oznacza DWORD, czyli 32 bity).

Jeśli otworzysz skompilowany plik .exe w programie IDA, zobaczysz zmienną x na początku segmentu DATA, a zaraz za nią ciąg znaków.

Gdybyś otworzył w programie IDA skompilowany plik .exe z poprzedniego przykładu (gdy x była niezainicjalizowana), zobaczyłbyś podobny wynik:

Listing 1.77: IDA

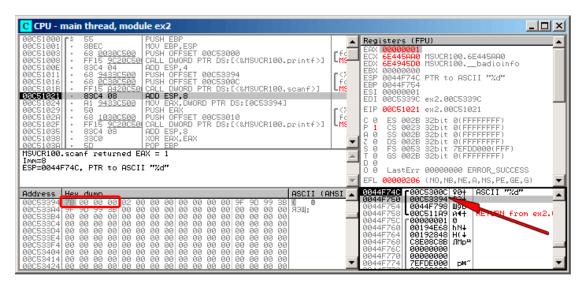
```
; DATA XREF: main+10
.data:0040FA80 _x
                              dd?
.data:0040FA80
                                         main+22
.data:0040FA84 dword 40FA84
                              dd?
                                      ; DATA XREF: memset+1E
                                      ; unknown libname 1+28
.data:0040FA84
                              dd?
                                      ; DATA XREF: sbh find block+5
.data:0040FA88 dword 40FA88
.data:0040FA88
                                      ; ___sbh_free_block+2BC
.data:0040FA8C ; LPV0ID lpMem
.data:0040FA8C lpMem
                              dd?
                                      ; DATA XREF:
                                                     sbh find block+B
.data:0040FA8C
                                           sbh free block+2CA
.data:0040FA90 dword_40FA90
                              dd?
                                      ; DATA XREF: _V6_HeapAlloc+13
.data:0040FA90
                                          calloc impl+72
.data:0040FA94 dword 40FA94
                              dd?
                                      ; DATA XREF: sbh free block+2FE
```

Zmienna _x razem z innymi zmiennymi, które nie muszą być zainicjalizowane, jest oznaczona za pomocą?. To powoduje, że po załadowaniu pliku wykonalnego do pamięci, miejsce na te zmienne jest zaalokowane i wypełnione zerami [ISO/IEC 9899:TC3]

(C C99 standard), (2007)6.7.8p10]. W samym pliku wykonywalnym niezainicjalizowane zmienne nie zajmują żadnego miejsca. Ma to swoje zalety, np. przy dużych tablicach.

MSVC: x86 + OllyDbg

Teraz jest nawet prościej:



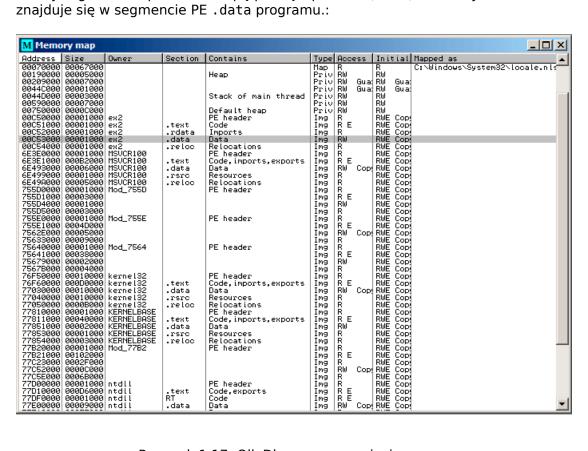
Rysunek 1.16: OllyDbg: po wykonaniu scanf()

Zmienna jest umieszczona w segmencie danych. Po wykonaniu instrukcji PUSH (odłożenie adresu x), adres pojawia się w oknie stosu. Kliknij prawym przyciskiem na ten wiersz i wybierz "Follow in dump". Zmienna pojawi się w oknie pamięci, po lewej stroniej. Po wprowadzeniu 123 w konsoli, 0x7B pojawi się w oknie pamięci (patrz miejsca zaznaczane na zrzucie ekranu).

Ale dlaczego pierwszy bajt to 7B? Przecież logicznie rzecz biorąc, powinno być 00 00 00 7B! Przyczyną jest tzw. kolejność bajtów (ang. endianess), a x86 używa kolejności od najmniej znaczącego bajtu (tzw. cienkokońcowość, ang. little-endian). Więcej o tym przeczytasz tutaj:: ?? on page ??. Wracając do przykładu, wartość 32-bitowa jest ładowana z adresu w pamięci do EAX a następnie przekazywana do funkcji printf().

x znajduje się pod adresem 0x00C53394.

W OllyDbg można sprawdzić mapę pamięci procesu (Alt-M). Widzimy, że ten adres znajduje się w segmencie PE .data programu.:



Rysunek 1.17: OllyDbg: mapa pamięci procesu

GCC: x86

Wynik kompilacji na Linuksie jest prawi taki sam, różnicą jest to, że niezainicjalizowana zmienna jest umieszczona w segmencie bss. W plikach ELF⁷³ ten segment ma następujące atrybuty:

```
Segment type: Uninitialized
Segment permissions: Read/Write
```

Jeśli jednak nadasz zmiennej jakość wartość, np. 10, zostanie umieszczona w segmencie data, który z kolei ma atrybuty:

```
Segment type: Pure data
Segment permissions: Read/Write
```

⁷³ Executable and Linkable Format: Format plików wykonywalnych używany w systemach z rodziny *NIX, w szczególności na Linuksie

MSVC: x64

Listing 1.78: MSVC 2012 x64

```
DATA
        SEGMENT
COMM
        x:DWORD
                 'Enter X:', 0aH, 00H
$SG2924 DB
$SG2925 DB
                 '%d', 00H
$SG2926 DB
                 'You entered %d...', OaH, OOH
DATA
        ENDS
TEXT
        SEGMENT
main
        PR0C
$LN3:
        sub
                rsp, 40
        lea
                rcx, OFFSET FLAT: $SG2924; 'Enter X:'
        call
                printf
                rdx, OFFSET FLAT:x
        lea
        lea
                rcx, OFFSET FLAT:$SG2925; '%d'
        call
                scanf
                edx, DWORD PTR x
        mov
        lea
                rcx, OFFSET FLAT: $SG2926; 'You entered %d...'
        call
                printf
        ; zwróć 0
        xor
                eax, eax
        add
                rsp, 40
        ret
                0
        ENDP
main
        ENDS
TEXT
```

Kod jest niemal taki sam jak na x86. Zauważ, że adres zmiennej x jest przekazany do funkcji scanf () za pomocą instrukcji LEA, ale wartość zmiennej jest przekazywana do drugiego wywołania printf () za pomocą instrukcji MOV. DWORD PTR—to część kodu w asemblerze (bez związku z kodem maszynowym), pokazująca, że zmienna jest 32-bitowa i instrukcja MOV musi być odpowiednio zakodowana (opcode stosowny do rozmiaru).

ARM: Optymalizujący Keil 6/2013 (tryb Thumb)

Listing 1.79: IDA

```
.text:00000000 ; Segment type: Pure code
.text:00000000
                       AREA .text, CODE
.text:00000000 main
.text:00000000
                       PUSH
                                {R4,LR}
                                R0, aEnterX ; "Enter X:\n"
.text:00000002
                       ADR
                                 _2printf
.text:00000004
                       BL
.text:00000008
                       LDR
                                R1, =x
.text:0000000A
                       ADR
                                R0, aD
                                            ; "%d"
```

```
.text:0000000C
                       BL
                                 0scanf
.text:00000010
                       LDR
                               R0, =x
                               R1, [R0]
.text:00000012
                       LDR
                               R0, aYouEnteredD___ ; "You entered %d...\n"
.text:00000014
                       ADR
                       BL
.text:00000016
                                 2printf
.text:0000001A
                       MOVS
                               R0, #0
                               {R4,PC}
.text:0000001C
                       P0P
.text:00000020 aEnterX DCB "Enter X:",0xA,0 ; DATA XREF: main+2
.text:0000002A
                       DCB
.text:0000002B
                       DCB
                              0
.text:0000002C off 2C
                       DCD x
                                             ; DATA XREF: main+8
.text:0000002C
                                             ; main+10
                       DCB "%d",0
.text:00000030 aD
                                             ; DATA XREF: main+A
                       DCB
.text:00000033
                             0
.text:00000034 aYouEnteredD DCB "You entered %d...",0xA,0 ; DATA XREF:
.text:00000047
.text:00000047 ; .text ends
.text:00000047
.data:00000048 ; Segment type: Pure data
.data:00000048
                       AREA .data, DATA
.data:00000048
                       : ORG 0x48
.data:00000048
                       FXPORT x
.data:00000048 x
                       DCD 0xA
                                             ; DATA XREF: main+8
.data:00000048
                                             : main+10
.data:00000048 ; .data ends
```

Zmienna x jest teraz globalna i z tego powodu znajduje się w innym segmencie - w segmencie danych .data. Można by zapytać - dlaczego w takim razie łańcuch znaków jest w segmencie kodu (.text)? Ponieważ x jest zmienną i z definicji jej wartość może się zmienić, co może dziać się dość często. Łańcuch znaków jest stały, nie zostanie zmieniony, więc znajduje się w segmencie .text.

Segment kodu czasami może znajdować się w układzie ROM⁷⁴ (pamiętaj, że mamy teraz do czynienia z systemami wbudowanymi, gdzie często występuje deficyt pamięci), a *zmienialne* zmienne w RAM⁷⁵.

Nie byłoby to racjonalne, gdybyśmy trzymali stałe zmienne w pamięci RAM, gdy dostępny jest ROM.

Co więcej, stałe zmienne w pamięci RAM powinny być zainicjalizowane przed rozpoczęciem pracy, ponieważ po włączeniu zasilania w pamięci RAM znajduję się przypadkowe dane.

Przechodząc dalej, widzimy wskaźnik z segmentu kodu (off_2C) do zmiennej x, i że wszystkie operacje na zmiennej zachodzą z użyciem tego wskaźnika.

Dzieje się tak, gdyż x może być w pamięci dość daleko od danej instrukcji, a więc jej adres musi być zapisany gdzieś blisko samego kodu.

⁷⁴Pamięć tylko do odczytu (Read-Only Memory)

⁷⁵Random-Access Memory

Instrukcja LDR w trybie Thumb może adresować zmienne w przedziale 1020 bajtów od swojej lokalizacji, a w trybie ARM —w przedziale ± 4095 bajtów.

Więc adres x musi być dość blisko, ponieważ nie ma gwarancji, że linker będzie mógł umieścić samą zmienną w pobliżu kodu. Może ona trafić nawet do zewnętrznego układu!

Jeszcze jedna rzecz: jeśli zmienna jest zadeklarowana jako *const*, kompilator Keil zaalokuje ją w segmencie . constdata.

Być może linker później umieści ten segment w pamięci ROM, razem z segmentem kodu.

ARM64

Listing 1.80: Nieoptymalizujący GCC 4.9.1 ARM64

```
x,4,4
 1
            .comm
    .LC0:
 2
 3
            .string "Enter X:"
 4
    .LC1:
 5
            .string "%d"
 6
    .LC2:
 7
            .string "You entered %d...\n"
 8
 9
    ; zapisz FP i LR w ramce stosu
10
                    x29, x30, [sp, -16]!
            stp
11
    ; ustaw wskaźnik ramki stosu (FP=SP)
12
            add
                    x29, sp, 0
    ; wczytaj wskaźnik na łańcuch znaków "Enter X:":
13
14
            adrp
                    x0, .LC0
15
                    x0, x0, :lo12:.LC0
            add
16
            bl
                    puts
17
    ; wczytaj wskaźnik na łańcuch znaków "%d":
                    x0, .LC1
18
            adrp
19
                    x0, x0, :lo12:.LC1
            add
20
    ; ustaw adres zmiennej globalnej x:
21
            adrp
                    x1, x
22
            add
                    x1, x1, :lo12:x
23
                     _isoc99_scanf
            bl
24
    ; ponownie ustaw adres zmiennej globalnej x:
25
                    x0, x
            adrp
26
            add
                    x0, x0, :lo12:x
    ; wczytaj wartość z tego adresu:
27
                    w1, [x0]
28
            ldr
29
    ; wczytaj wskaźnik na łańcuch znaków "You entered %d...\n"
30
            adrp
                    x0, .LC2
31
            add
                    x0, x0, :lo12:.LC2
32
            bl
                    printf
    ; zwróć 0
33
34
                    w0, 0
            mov
    ; przywróć FP i LR:
35
36
            ldp
                    x29, x30, [sp], 16
37
            ret
```

W tym przypadku zmienna x jest zadeklarowana jako globalna a jej adres jest wyliczany za pomocą pary instrukcji ADRP/ADD (linia 21. i 25.).

MIPS

Niezainicjalizowane zmienne globalne

x jest teraz zmienną globalną. Skompilujmy program do pliku wykonywalnego, zamiast obiektowego, i otwórzmy w programie IDA. IDA wyświetla zmienną x w sekcji .sbss pliku ELF (pamiętasz "Global Pointer"? 1.5.4 on page 34), gdyż zmienna nie jest zainicializowana na starcie.

Listing 1.81: Optymalizujący GCC 4.4.5 (IDA)

```
.text:004006C0 main:
.text:004006C0
.text:004006C0 var 10 = -0x10
.text:004006C0 var 4
.text:004006C0
; prolog:
                                $gp, 0x42
.text:004006C0
                        lui
.text:004006C4
                        addiu
                                sp, -0x20
.text:004006C8
                        li
                                $gp, 0x418940
.text:004006CC
                                $ra, 0x20+var_4($sp)
                        SW
.text:004006D0
                                $gp, 0x20+var_10($sp)
                        SW
; wywołaj puts():
                                $t9, puts
$a0, 0x40
.text:004006D4
                        la
.text:004006D8
                        lui
                                $t9 ; puts
.text:004006DC
                        jalr
                                $a0, aEnterX
                                                 # "Enter X:" ; branch delay
.text:004006E0
slot
; wywołaj scanf():
                                $qp, 0x20+var 10($sp)
.text:004006E4
                        lw
                        $a0. 0x40
.text:004006E8 lui
.text:004006EC
                                $t9, __isoc99_scanf
                        la
; przygotuj adres x:
.text:004006F0
                        la
                                $a1, x
                                $t9 ; __isoc99_scanf
$a0, aD # "%d" ; branch delay slot
.text:004006F4
                        jalr
.text:004006F8
                        la
; wywołaj printf():
.text:004006FC
                        lw
                                $gp, 0x20+var_10($sp)
                                $a0, 0x40
.text:00400700
                        lui
; pobierz adres x:
.text:00400704
                        la
                                $v0, x
.text:00400708
                        la
                                $t9, printf
; załaduj wartość ze zmiennej "x" i przekaż ją do funkcji printf() przez $al:
.text:0040070C
                        lw
                                $a1, (x - 0x41099C)($v0)
.text:00400710
                        jalr
                                $t9 ; printf
                                $a0, aYouEnteredD # "You entered %d...\n"
.text:00400714
                       la
    ; branch delay slot
: epilog:
.text:00400718
                       lw
                                $ra, 0x20+var_4($sp)
.text:0040071C
                                $v0, $zero
                       move
```

```
.text:00400720 jr $ra
.text:00400724 addiu $sp, 0x20 ; branch delay slot
...
.sbss:0041099C # Segment type: Uninitialized
.sbss:0041099C .sbss
.sbss:0041099C .globl x
.sbss:0041099C x: .space 4
.sbss:0041099C
```

IDA nie wyświetliła wszystkich informacji, więc spójrzmy na listing wygenerowany za pomocą objdump oraz komentarze:

Listing 1.82: Optymalizujący GCC 4.4.5 (objdump)

```
1
    004006c0 <main>:
 2
    ; prolog:
 3
      4006c0:
                3c1c0042
                           lui
                                    gp,0x42
 4
               27bdffe0
                           addiu
      4006c4:
                                    sp, sp, -32
 5
               279c8940
                                    gp,gp,-30400
      4006c8:
                           addiu
 6
               afbf001c
      4006cc:
                                    ra,28(sp)
                           SW
 7
      4006d0:
                afbc0010
                                    gp,16(sp)
                           SW
 8
    ; wywołaj puts():
 9
      4006d4:
                8f998034
                                    t9,-32716(qp)
                           ۱w
10
      4006d8:
                3c040040
                           lui
                                    a0,0x40
11
      4006dc:
                0320f809
                           ialr
                                    t9
12
      4006e0:
                248408f0
                           addiu
                                    a0,a0,2288; branch delay slot
13
      wywołaj scanf():
14
      4006e4:
                8fbc0010
                           lw
                                    gp,16(sp)
15
                3c040040
                           lui
                                    a0,0x40
      4006e8:
16
      4006ec:
                8f998038
                           lw
                                    t9,-32712(gp)
17
      przygotuj adres x:
18
      4006f0:
                8f858044
                           lw
                                    a1,-32700(gp)
19
      4006f4:
                0320f809
                           ialr
20
      4006f8:
                248408fc
                           addiu
                                    a0,a0,2300 ; branch delay slot
21
    ; wywołaj printf():
22
      4006fc:
                8fbc0010
                                    qp,16(sp)
                           lw
23
      400700:
                3c040040
                           lui
                                    a0,0x40
24
    ; pobierz adres x:
25
      400704:
                8f828044
                           lw
                                    v0,-32700(gp)
26
      400708:
                8f99803c
                           lw
                                    t9,-32708(gp)
27
    ; załaduj wartość ze zmiennej
                                    "x" i przekaż ją do funkcji printf() przez $a1:
      40070c:
28
                           lw
                8c450000
                                    a1,0(v0)
29
      400710:
                0320f809
                            jalr
30
                24840900
      400714:
                            addiu
                                    a0,a0,2304; branch delay slot
31
    : epilog:
32
                8fbf001c
      400718:
                           lw
                                    ra,28(sp)
33
      40071c:
                00001021
                           move
                                    v0,zero
34
      400720:
                03e00008
                           jr
                                    ra
35
                           addiu
      400724:
                27bd0020
                                    sp,sp,32
                                               ; branch delay slot
      kilka instrukcji NOP do wyrównania początku kolejnej funkcji do granicy 16
36
        bajtów
37
      400728:
                00200825
                           move
                                    at,at
```

40072c: 00200825 move at,at

38

Teraz widać, że adres zmiennej x jest wczytywany z 64KiB bufora danych za pomocą GP i ujemnego przesunięcia (linia 18). Co więcej, adresy trzech kolejnych zewnętrznych funkcji (puts (), scanf (), printf ()) również wczytywane są z tego globalnego bufora, za pomocą GP (linia 9, 16 i 26). GP wskazuje na środek bufora, a takie przesunięcie świadczy o tym, że adresy trzech funkcji oraz zmiennej x są przechowywane gdzieś na jego początku. Ma to sens, ponieważ nasz przykład jest bardzo prosty.

Warto zauważyć, że funkcja kończy się dwiema instrukcjami NOP (MOVE \$AT,\$AT — puste instrukcje), by wyrównać początek kolejnej funkcji do granicy 16 bajtów.

Zainicjalizowane zmienne globalne

Zmieńmy nasz przykład, nadając zmiennej x wartość:

```
int x=10; // wartość domyślna
```

Teraz IDA pokazuje, że zmienna x jest wczytywana z sekcji .data:

Listing 1.83: Optymalizujący GCC 4.4.5 (IDA)

```
.text:004006A0 main:
.text:004006A0
.text:004006A0 var 10
                      = -0 \times 10
                       = -8
.text:004006A0 var_8
                       = -4
.text:004006A0 var 4
.text:004006A0
                                $gp, 0x42
.text:004006A0
                        lui
.text:004006A4
                        addiu
                                sp, -0x20
                                $gp, 0x418930
.text:004006A8
                        li
                                $ra, 0x20+var_4($sp)
.text:004006AC
                        SW
.text:004006B0
                                $s0, 0x20+var_8($sp)
                        SW
.text:004006B4
                        SW
                                $gp, 0x20+var_10($sp)
.text:004006B8
                        la
                                $t9, puts
                                $a0, 0x40
.text:004006BC
                       lui
.text:004006C0
                                $t9 ; puts
                        jalr
                                                  # "Enter X:"
.text:004006C4
                       la
                                $a0, aEnterX
                                $gp, 0x20+var_10($sp)
.text:004006C8
                       lw
; przygotuj starsze bity adresu x:
.text:004006CC
                        lui
                                $s0, 0x41
                                $t9, __isoc99_scanf
.text:004006D0
                        la
.text:004006D4
                                $a0, 0x40
                        lui
; dodaj młodsze bity adresu x:
.text:004006D8
                       addiu
                                $a1, $s0, (x - 0x410000)
; adres x jest teraz w $a1.
.text:004006DC
                       jalr
                                $t9 ; _
                                        _isoc99_scanf
                                                  # "%d"
.text:004006E0
                                $a0, aD
                       la
.text:004006E4
                                $gp, 0x20+var_10($sp)
                       lw
; pobierz słowo z pamięci:
.text:004006E8
                       lw
                                $a1, x
; wartość x jest teraz w $a1.
```

```
.text:004006EC
                                 $t9, printf
                        la
.text:004006F0
                        lui
                                $a0, 0x40
.text:004006F4
                        jalr
                                $t9 ; printf
                                                        # "You entered %d...\n"
.text:004006F8
                        la
                                $a0, aYouEnteredD_
.text:004006FC
                        lw
                                $ra, 0x20+var_4($sp)
.text:00400700
                        move
                                $v0, $zero
.text:00400704
                        ٦w
                                $s0, 0x20+var_8($sp)
.text:00400708
                        jr
                                $ra
.text:0040070C
                        addiu
                                $sp, 0x20
. . .
.data:00410920
                        .globl x
.data:00410920 x:
                        .word 0xA
```

Dlaczego nie z .sdata? Być może wpływają na to pewne opcje GCC?

W każdym razie, x jest w .data, a jest to pamięć współdzielona. Możemy zobaczyć jak taka pamięć jest wykorzystywana.

Adres zmiennej jest konstruowany za pomocą pary instrukcji.

W naszym przykładzie są to LUI ("Load Upper Immediate") i ADDIU ("Add Immediate Unsigned Word").

Poniżej listing wygenerowany za pomocą objdump, do bardziej szczegółowej analizy:

Listing 1.84: Optymalizujący GCC 4.4.5 (objdump)

```
004006a0 <main>:
  4006a0:
           3c1c0042
                      lui
                              gp,0x42
  4006a4:
                              sp,sp,-32
           27bdffe0
                      addiu
  4006a8:
           279c8930
                      addiu
                              gp,gp,-30416
  4006ac:
           afbf001c
                               ra,28(sp)
                      SW
                              s0,24(sp)
  4006b0:
           afb00018
                      SW
  4006b4:
           afbc0010
                      SW
                              qp, 16(sp)
  4006b8:
           8f998034
                      lw
                              t9,-32716(gp)
  4006bc:
           3c040040
                      lui
                              a0,0x40
  4006c0:
           0320f809
                              t9
                      jalr
  4006c4:
           248408d0
                      addiu
                              a0,a0,2256
  4006c8:
          8fbc0010
                      lw
                              gp, 16(sp)
; przygotuj starsze bity adresu x:
          3c100041
  4006cc:
                      lui
                              s0,0x41
  4006d0:
           8f998038
                      lw
                              t9,-32712(qp)
  4006d4:
           3c040040
                      lui
                              a0,0x40
; dodaj młodsze bity adresu x:
  4006d8: 26050920
                      addiu
                              a1,s0,2336
; adres x jest teraz w $a1.
                              t9
  4006dc: 0320f809
                      jalr
  4006e0: 248408dc
                      addiu
                              a0,a0,2268
  4006e4: 8fbc0010
                              gp, 16(sp)
                      lw
; starsza część adresu wciąż jest w $s0.
; dodaj młodsze bity i pobierz słowo z pamięci:
  4006e8: 8e050920
                     lw
                              a1,2336(s0)
; wartość x jest teraz w $a1.
```

```
4006ec:
         8f99803c
                             t9,-32708(qp)
                     lw
4006f0:
         3c040040
                     lui
                             a0,0x40
         0320f809
4006f4:
                     jalr
                             t9
         248408e0
                             a0,a0,2272
4006f8:
                     addiu
         8fbf001c
4006fc:
                     lw
                             ra,28(sp)
400700:
         00001021
                             v0,zero
                     move
         8fb00018
400704:
                     ۱w
                             s0,24(sp)
400708:
         03e00008
                     jr
                             ra
40070c:
         27bd0020
                     addiu
                             sp,sp,32
```

Widać, że po zbudowaniu adresu za pomocą LUI i ADDIU starsze bity wciąż znajdują się w rejestrze \$50. Można teraz zakodować przesunięcie w instrukcji LW ("Load Word"), by za pomocą tylko tej jednej instukcji załadować zmienną z pamięci i przekazać do funkcji printf().

Wiemy już, że rejestry przechowujące tymczasowe dane mają prefiks T-. W przykładzie widzimy również takie, które rozpoczynają się od S- — są to rejestry, których zawartość musi zostać zachowana, jeśli funkcja planuje ich użyć (np. muszą być gdzieś zapisana, a później przywrócone). Dzięki temu, gdy wywołujemy daną funkcję, to po jej zakończeniu i powrocie sterowania dane w tych rejestrach będą takie same, jak przed jej wywołaniem.

Dlatego wartość \$50 została ustawiona w adresie 0x4006cc, a następnie ponownie użyta pod adresem 0x4006e8, po wywołaniu funkcji scanf(). Funkcja scanf() nie zmieniła tej wartości.

1.12.4 scanf()

Jak wspomniano wcześniej, używanie scanf() w dzisiejszych czasach jest nieco staroświeckie. Jeśli jednak musisz to zrobić, należy się upewnić czy wykonanie scanf() zakończyło się poprawnie, bez żadnego błędu.

Zgodnie ze standardem scanf () 76 zwraca liczbę pól, które zostały z sukcesem wczytane i zapisane.

⁷⁶scanf, wscanf: MSDN

W naszym przypadku, jeśli wszystko pójdzie dobrze i użytkownik wprowadził liczbę, scanf() zwróci 1. W przypadku wystąpienia błędu (lub EOF⁷⁷), zwróci 0.

Dodaliśmy więcej kodu by sprawdzić co zwraca scanf () i wypiszmy ewentualne komunikaty o błędach.

Poniżej pokazano program w działaniu:

```
C:\...>ex3.exe
Enter X:
123
You entered 123...

C:\...>ex3.exe
Enter X:
ouch
What you entered? Huh?
```

MSVC: x86

Poniżej wynik kompilacji pod MSVC 2010:

```
lea
                eax, DWORD PTR _x$[ebp]
        push
                OFFSET $SG3833 ; '%d', 00H
        push
                _scanf
        call
        add
                esp, 8
        cmp
                eax, 1
        jne
                SHORT $LN2@main
                ecx, DWORD PTR _x$[ebp]
        mov
        push
                OFFSET $SG3834; 'You entered %d...', OaH, OOH
        push
                _printf
        call
        add
                esp, 8
        jmp
                SHORT $LN1@main
$LN2@main:
        push
                OFFSET $SG3836 ; 'What you entered? Huh?', OaH, OOH
                _printf
        call
        add
                esp, 4
$LN1@main:
        xor
                eax, eax
```

Funkcja wywołująca (main()) potrzebuje rezultatu zwróconego przez funkcję wywoływaną (scanf()), więc funkcja wywoływana zwraca go za pomocą rejestru EAX.

Rezultat sprawdzamy za pomocą instrukcji CMP EAX, 1 (*CoMPare*) — porównujemy wartość w rejestrze EAX z liczbą 1.

Instrukcja JNE to skok warunkowy, następujący po CMP. JNE oznacza *Jump if Not Equal*.

⁷⁷End of File

Jeśli wartość w EAX jest różna od 1, CPU przekaże sterowanie pod adres z operandu instrukcji JNE, w naszym przypadku jest to \$LN2@main. Przekazanie sterowania pod ten adres oznacza wykonanie funkcji printf() z argumentem What you entered? Huh?. Jeśli natomiast scanf() zakończyła się sukcesem i wartość w EAX jest równa 1, skok warunkowy nie zostanie wykonany i kolejno zostanie wywołana funkcja printf(), z dwoma argumentami:

'You entered %d...' i wartością x.

W tym drugin przypadku - gdy scanf() zakończyła się poprawnie - nie ma potrzeby wykonywać drugiego wywołania funkcji printf(), stąd przed wywołaniem znajduje się instrukcja JMP (skok bezwarunkowy). Instrukcja przekazuje sterowanie w miejsce za drugim wywołaniem printf(), ale przed instrukcją XOR EAX, EAX, która realizuje return 0.

Można powiedzieć, że porówywanie dwóch wartości jest zwykle realizowane przez parę instrukcji CMP/Jcc, gdzie *cc* oznacza *condition code* (*kod warunku*). CMP porównuje dwie wartości i ustawia flagę procesora ⁷⁸. Jcc sprawdza te flagi i decyduje czy przekazać sterowanie pod podany adres.

Zabrzmi to paradoksalnie, ale instrukcja CMP to tak na prawdę SUB (subtract - odejmij). Nie tylko CMP, ale wszystkie instrukcje arytmetyczne modyfikują flagi procesora. Jeśli porównamy 1 z 1, 1 – 1 daje 0, więc flaga ZF zostanie ustawiona. W żadnym innym przypadku flaga ZF nie zostanie ustawiona, poza tym gdy operandy są sobie równe. JNE sprawdza tylko flagę ZF i wykonuje skok, jeśli nie jest ustawiona. JNE jest synonimem JNZ (Jump if Not Zero). Asembler tłumaczy zarówno JNE jak i JNZ na ten sam kod operacji (opcode). Instrukcja CMP może być zastąpiona przez SUB i prawie wszystko powinno działać poprawnie, poza tym, że SUB zmieni wartość pierwszego operandu na wynik operacji odejmowania. CMP to SUB bez zapisywania wyniku operacji, ale ze zmianą flag.

MSVC: x86: IDA

Nadszedł czas na uruchomienie programu IDA i pokazanie jego możliwości. Przy okazji, początkującym pomoże ustawienie opcji /MD w MSVC, co spowoduje, że wszystkie funkcji biblioteki standardowej nie będą statycznie zlinkowane do pliku wykonywalnego, ale zostaną zaimportowane z MSVCR*.DLL podczas wykonania. Dzięki temu łatwiej będzie zobaczyć, które funkcje z biblioteki standardowej zostały użyte i gdzie.

Podczas analizy kodu w programie IDA warto dla siebie (i innych) robić notatki. W tym przypadku widzimy, że skok JNZ wykona się w przypadku błędu. Można przesunąć kursor do etykiety, nacisnąć "n" i zmienić nazwę na "error". Zmienimy również nazwę kolejnej etykiety na "exit".

Poniżej listing po zmianiach nazw:

```
.text:00401000 _main proc near
.text:00401000
.text:00401000 var_4 = dword ptr -4
.text:00401000 argc = dword ptr 8
.text:00401000 argv = dword ptr 0Ch
.text:00401000 envp = dword ptr 10h
```

⁷⁸rejestr FLAGS, więcej o tym przeczytasz pod adresem: wikipedia.

```
.text:00401000
.text:00401000
                     push
                              ebp
.text:00401001
                     mov
                              ebp, esp
.text:00401003
                     push
                              ecx
                              offset Format ; "Enter X:\n"
.text:00401004
                     push
.text:00401009
                     call
                              ds:printf
.text:0040100F
                     add
                              esp, 4
.text:00401012
                              eax, [ebp+var_4]
                     lea
.text:00401015
                     push
                              eax
                              offset aD ; "%d"
.text:00401016
                     push
.text:0040101B
                     call
                              ds:scanf
.text:00401021
                     add
                              esp, 8
.text:00401024
                     cmp
                              eax, 1
.text:00401027
                     jnz
                              short error
.text:00401029
                     mov
                              ecx, [ebp+var_4]
.text:0040102C
                     push
                              offset aYou; "You entered %d...\n"
.text:0040102D
                     push
.text:00401032
                     call
                              ds:printf
.text:00401038
                     bha
                              esp, 8
.text:0040103B
                     jmp
                              short exit
.text:0040103D
.text:0040103D error: ; CODE XREF: main+27
.text:0040103D
                     push
                              offset aWhat; "What you entered? Huh?\n"
.text:00401042
                     call
                              ds:printf
.text:00401048
                     add
                              esp, 4
.text:0040104B
.text:0040104B exit: ; CODE XREF: _main+3B
.text:0040104B
                     xor
                              eax, eax
.text:0040104D
                              esp, ebp
                     mov
.text:0040104F
                     pop
                              ebp
.text:00401050
                     retn
.text:00401050 main endp
```

Te drobne modyfikacje ułatwiły zrozumienie kodu, jednak nie warto przesadzać i komentować każdej instrukcji.

W IDA nożesz również ukryć (zwinąć) kod wybranej funkcji. Zaznacz blok kodu, wciśnij Ctrl-"–" na klawiaturze numerycznej i wpisz tekst, który ma zostać wyświetlony zamiast kodu.

Ukryjmy dwa bloki kodu i nadajmy im nazwy:

```
.text:00401000 _text segment para public 'CODE' use32
                     assume cs: text
.text:00401000
.text:00401000
                     ;org 401000h
.text:00401000 ; ask for X
.text:00401012 ; get X
.text:00401024
                     cmp eax, 1
.text:00401027
                     inz short error
.text:00401029 ; print result
.text:0040103B
                     jmp short exit
.text:0040103D
.text:0040103D error: ; CODE XREF: main+27
.text:0040103D
                     push offset aWhat ; "What you entered? Huh?\n"
```

```
      .text:00401042
      call ds:printf

      .text:00401048
      add esp, 4

      .text:0040104B
      code XREF: _main+3B

      .text:0040104B
      xor eax, eax

      .text:0040104D
      mov esp, ebp

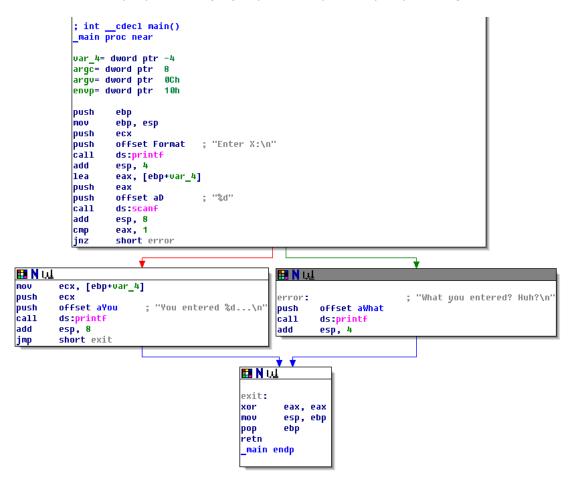
      .text:0040104F
      pop ebp

      .text:00401050
      retn

      .text:00401050
      _main endp
```

By rozwinąć poprzednio zwinięte fragmenty, użyj Ctrl-"+" na klawiaturze numerycznej.

Po naciśnięciu "spacji" zobaczymy reprezentację funkcji w postaci grafu.



Rysunek 1.18: Tryb grafu w IDA

Z każdego skoku warunkowego wychodzą dwie strzałki: zielona i czerwona. Zielona wskazuje blok, który się wykona w przypadku wykonania skoku, a czerwona - blok, który się wykona, gdy do skoku nie dojdzie.

W tym trybie można zwinąć węzły i nadać nazwę tak stworzonej "grupie węzłów". Zróbmy to dla 3 bloków:

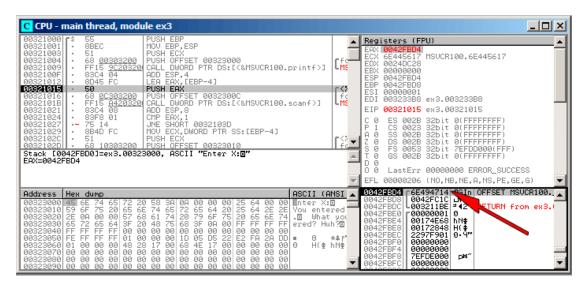
```
; int __cdecl main()
_main proc near
var_4= dword ptr -4
argc= dword ptr 8
argv= dword ptr
envp= dword ptr 10h
push
        ebp
mov
        ebp, esp
push
        ecx
        offset Format
                         ; "Enter X:\n"
push
call
        ds:printf
add
        esp, 4
1ea
        eax, [ebp+var_4]
push
        eax
                         ; ''%d''
push
        offset aD
.
call
        ds:scanf
add
        esp, 8
cmp
        eax, 1
jnz
        short error
                                         III N 👊
                                         print X
                    print error message
                               🚻 N Ա
                               return 0
```

Rysunek 1.19: Tryb grafu w IDA przy 3 zwiniętych węzłach

Jest to dość użyteczne. Można powiedzieć, że istotną częścią pracy osoby zajmującej się inżynierią wsteczną (a także każdego innego badacza) jest ograniczenie ilości informacji.

MSVC: x86 + OllyDbg

Spróbujmy zhackować nasz program w OllyDbg, zmuszając go, by uznał, że funkcja scanf() wykonała się bez błędów. Kiedy adres zmiennej lokalnej jest przekazywany do scanf(), zmienna początkowo zawiera przypadkową wartość, w tym wypadku 0x6E494714:



Rysunek 1.20: OllyDbg: przekazywanie adresu zmiennej do scanf()

Kiedy wykonywana jest funkcja scanf(), w konsoli wpiszmy coś, co z pewnością nie jest liczbą, na przykład "asdasd". scanf() kończy działanie z 0 w EAX, co wskazuje na wystąpienie błędu.

Możemy sprawdzić wartość zmiennej lokalnej na stosie i zauważyć, że się ona nie zmieniła. W rzeczy samej, dlaczego funkcja scanf () miałaby cokolwiek tam zapisać? Jej wykonanie nie spowodowało nic, poza zwróceniem zera.

Spróbujmy "zhackować" nasz program. Kliknij prawym przyciskiem na EAX, wśród opcji znajduje się "Set to 1" (*ustaw na 1*). To jest to, czego szukamy.

Mamy teraz 1 w EAX, a więc kolejne sprawdzenie powinno się wykonać zgodnie z oczekiwaniami i printf() powinna wyświetlić wartość zmiennej ze stosu.

Po wznowieniu wykonania programu (F9) widzimy następujący efekt w oknie konsoli:

Listing 1.85: console window

Enter X:
asdasd
You entered 1850296084...

1850296084 to postać dziesiętna liczby, którą widzieliśmy na stosie (0x6E494714)!

MSVC: x86 + Hiew

Na tym przykładzie pokażemy proste *poprawianie* plików wykonalnych. Tak zmodyfikujmy program, by zawsze wypisał wejście wprowadzony przez użytkownika, niezależnie od jego treści.

Zakładając, że plik wykonywalny jest linkowany dynamicznie z MSVCR*.DLL (kompilacja z opcją /MD), zobaczymy funkcję main() na początku sekcji .text. Otwórzmy plik w Hiew i znajdźmy początek sekcji .text (Enter, F8, F6, Enter, Enter).

Widzimy:

```
Hiew: ex3.exe
                                                                   a32 PE .00401000 Hie
   C:\Polygon\ollydbg\ex3.exe

□FRO -----
00401000: 55
                                            push
.00401001: 8BEC
                                            mov
                                                        ebp,esp
.00401003: 51
                                            push
                                                        000403000 ;'Enter X:' -- 1
.00401004: 6800304000
                                           push
.00401009: FF1594204000
                                           call
                                                        printf
.0040100F: 83C404
                                           add
                                                        esp,4
.00401012: 8D45FC
                                                        eax,[ebp][-4]
                                           lea
.00401015: 50
                                           push
                                                        eax
.00401016: 680C304000
                                           push
.0040101B: FF158C204000
                                           call
                                                        scanf
.00401021: 83C408
                                           add
                                                        esp,8
.00401024: 83F801
                                           cmp
                                                        eax,1
.00401027: 7514
                                           jnz
.00401029: 8B4DFC
                                                        ecx,[ebp][-4]
                                           mov
.0040102C: 51
                                                        ecx
                                           push
                                                        000403010 ; 'You entered %d...
.0040102D: 6810304000
.00401032: FF1594204000
                                           call
                                                        printf
.00401038: 83C408
                                           add
                                                        esp,8
                                                        .00040104B --E5
.0040103B: EB0E
                                           jmps
                                                        000403024 ; 'What you entered?
.0040103D: 6824304000
                                           3push
.00401042: FF1594204000
                                           call
                                                        printf
.00401048: 83C404
                                           add
                                                        esp,4
.0040104B: 33C0
                                           5xor
                                                        eax,eax
.0040104D: 8BE5
                                                        esp,ebp
                                           mov
.0040104F: 5D
                                                        ebp
                                           pop
.00401050: C3
00401051: B84D5A0000
                                                        eax,000005A4D;' ZM'
                                           mov
                                                       ect <mark>8</mark>Table 91byte 10Leave
Global 2FilBlk 3CryBlk 4ReLoad 5OrdLdr
```

Rysunek 1.21: Hiew: funkcja main()

Hiew znajduje łańuchy znaków ASCIIZ⁷⁹ i je wyświetla, tak samo dzieje się również z nazwami zaimportowanych funkcji.

⁷⁹ASCII Zero ()

Przesuń kursor do adresu .00401027 (znajduje się tam instrukcja JNZ, którą musimy ominąć), naciśnij F3 i wpisz "9090" (co oznacza dwie instrukcje NOP):

Hiew: ex3.exe		
<pre>C:\Polygon\ollydbg\ex3.exe</pre>	⊡FWO EDITM	ODE a32 PE 0000
00000400: 55	push	ebp
00000401: 8BEC	mov	ebp,esp
00000403: 51	push	ecx
00000404: 68 00304000	push	000403000 ;' @0 '
00000409: FF1594204000	call	d,[000402094]
0000040F: 83C404	add	esp,4
00000412: 8D45FC	lea	eax,[ebp][-4]
00000415: 50	push	eax
00000416: 68 0C304000	push	00040300C ;'@0₽'
0000041B: FF158C204000	call	d,[00040208C]
00000421: 83C408	add	esp,8
00000424: 83F801	cmp	eax,1
00000427: 90	nop	
00000428: 90	nop	
00000429: <u>8</u> B4DFC	mov	ecx,[ebp][-4]
0000042C: 51	push	ecx
0000042D: 68 10304000	push	000403010 ;'@0D'
00000432: FF1 5 94204000	call	d,[000402094]
00000438: 83C408	add	esp <mark>,8</mark>
0000043B: EB0E	jmps	00000044B
0000043D: 68 24304000	push	000403024 ;'@0\$'
00000442: FF1594204000	call	d,[000402094]
00000448: 83C404	add	esp,4
0000044B: 33C0	xor	eax,eax
0000044D: 8BE5	mov	esp,ebp
0000044F: 5D	рор	ebp
00000450: C3	retn ; -^	<u>-^-^</u> - <u>^</u> -^- <u>^</u> -^-
1 2NOPs 3 4 5	6 7	8Table 9 10

Rysunek 1.22: Hiew: zastąpienie JNZ przez dwie instrukcje NOP

Następnie naciśnij F9 (update). Plik wykonywalny został zapisany na dysk i będzie się zachowywał zgodnie z naszymi oczekiwaniami.

Dwie instrukcje NOP nie są najbardziej eleganckim rozwiązaniem. Innym sposobem byłoby poprawienie instrukcji przez zapisanie 0 do drugiego bajtu kodu operacji (przesunięcie skoku), by JNZ zawsze skakała do kolejnej instrukcji.

Można też program zmodyfikować w drugą stronę: zastąpić pierwszy bajt przez EB, nie zmieniając drugiego bajtu (przesunięcie skoku). Otrzymamy wtedy skok bezwarunkowy, który zawsze będzie zachodził, przez co za każdym razem dostaniemy wiadomość o błędzie.

MSVC: x64

Pracujemy ze zmiennymi typu *int*, które na x86-64 wciaż będą 32-bitowe, stąd w kodzie zobaczymy wykorzystanie 32-bitowych części rejestrów (z prefiksem E-). Jednak przy pracy ze wskaźnikami będą używane 64-bitowe rejestry, z prefiksem R-.

Listing 1.86: MSVC 2012 x64

```
SEGMENT
DATA
$SG2924 DB
                 'Enter X:', 0aH, 00H
$SG2926 DB
                 '%d', 00H
$SG2927 DB
                 'You entered %d...', OaH, OOH
$SG2929 DB
                 'What you entered? Huh?', 0aH, 00H
        ENDS
DATA
_TEXT
        SEGMENT
x$ = 32
        PR<sub>0</sub>C
main
$LN5:
        sub
                 rsp, 56
                 rcx, OFFSET FLAT: $SG2924 ; 'Enter X:'
        lea
        call
                 printf
        lea
                 rdx, QWORD PTR x$[rsp]
        lea
                 rcx, OFFSET FLAT:$SG2926; '%d'
        call
                 scanf
                 eax, 1
        cmp
                 SHORT $LN2@main
        jne
        mov
                 edx, DWORD PTR x$[rsp]
        lea
                 rcx, OFFSET FLAT:$SG2927 ; 'You entered %d...'
        call
                 printf
                 SHORT $LN1@main
        jmp
$LN2@main:
        lea
                 rcx, OFFSET FLAT:$SG2929 ; 'What you entered? Huh?'
        call
                 printf
$LN1@main:
        ; zwróć 0
        xor
                 eax, eax
        add
                 rsp, 56
        ret
main
        ENDP
TEXT
        ENDS
END
```

ARM

ARM: Optymalizujący Keil 6/2013 (tryb Thumb)

Listing 1.87: Optymalizujący Keil 6/2013 (tryb Thumb)

```
BL
                    2printf
                  R1, SP
         MOV
                                    ; "%d"
         ADR
                  R0, aD
                    0scanf
         BL
                  R0, #1
         CMP
                  loc_1E
         BEQ.
         ADR
                  RO, aWhatYouEntered; "What you entered? Huh?\n"
         BL
                  2printf
                                    ; CODE XREF: main+26
loc_1A
         MOVS
                  R0, #0
         P<sub>0</sub>P
                  {R3, PC}
loc 1E
                                    ; CODE XREF: main+12
         LDR
                  R1, [SP,#8+var_8]
                  R0, aYouEnteredD____; "You entered %d...\n"
         ADR
         BL
                    2printf
         В
                  loc_1A
```

Nowymi instrukcjami są CMP i BEQ⁸⁰.

CMP jest równoważna instrukcji o takiej samej nazwie z x86. Odejmuje ona jeden argument od drugiego (bez zapisywania wyniku) i ustawia odpowiednie flagi procesora.

BEQ skacze pod inny adres, jeśli wartość flagi Z jest równa 1. Taka sytuacja w naszym przykładzie zajdzie, jeśli wartość rejestru i liczby z operandów instrukcji CMP będą sobie równe (tym samym ich różnica będzie równa 0). Tak samo zachowuje się instrukcja JZ na x86.

Cała reszta kodu jest bardzo prosta: przepływ sterowania dzieli się na dwa rozgałęzienia, które spotykają się w punkcie, gdzie 0 jest zapisywane do rejestru R0 jako wartość zwracana. Następnie funkcja się kończy.

ARM64

Listing 1.88: Nieoptymalizujący GCC 4.9.1 ARM64

```
1
    .LC0:
 2
             .string "Enter X:"
 3
    .LC1:
            .string "%d"
 4
 5
    .LC2:
 6
            .string "You entered %d...\n"
 7
    .LC3:
 8
            .string "What you entered? Huh?"
 9
    f6:
10
    ; zapisz FP i LR w ramce stosu:
11
            stp
                     x29, x30, [sp, -32]!
    ; ustaw wskaźnik ramki stosu (FP=SP)
12
13
            add
                     x29, sp, 0
```

^{80 (}PowerPC, ARM) Branch if Equal

```
; załaduj wskaźnik na łańcuch znaków "Enter X:":
14
15
            adrp
                    x0, .LC0
16
            add
                    x0, x0, :lo12:.LC0
17
            bl
                    puts
18
   ; załaduj wskaźnik na łańcuch znaków "%d":
19
            adrp
                    x0, .LC1
20
            add
                    x0, x0, :lo12:.LC1
21
    ; oblicz adres zmiennej x na stosie lokalnym:
22
                    x1, x29, 28
            add
23
                     __isoc99_scanf
            bl
24
    ; scanf() zwraca wynik przez rejestr W0
    ; sprawdź go:
25
26
                    w0, 1
            cmp
    ; BNE oznacza Branch if Not Equal
27
28
    ; jeśli WO<>1, skocz do L2
29
                     .L2
            bne
30
    ; w tym miejscu W0=1, co oznacza brak błędu
31
    ; załaduj wartość x ze stosu lokalnego
32
            ldr
                    w1, [x29,28]
    ; załaduj wskaźnik na łańcuch znaków "You entered %d...\n":
33
                    x0, .LC2
34
            adrp
35
            add
                    x0, x0, :lo12:.LC2
36
            bl
                    printf
    ; przeskocz przez kod wyświetlający "What you entered? Huh?":
37
38
            h
                     .L3
39
    .L2:
40
    ; załaduj wskaźnik na łańcuch znaków "What you entered? Huh?":
41
                    x0, .LC3
            adrp
42
                    x0, x0, :lo12:.LC3
            add
43
            bl
                    puts
44
    .L3:
    ; zwróc 0
45
46
            mov
                    w0, 0
47
    ; przywróć FP i LR:
48
            ldp
                    x29, x30, [sp], 32
49
            ret
```

Przepływ sterowania w tym przypadku rozgałęzia się dzięki parze instrukcji CMP/BNE (Branch if Not Equal).

MIPS

Listing 1.89: Optymalizujący GCC 4.4.5 (IDA)

```
.text:004006A0 main:
.text:004006A0
                          = -0x18
.text:004006A0 var_18
.text:004006A0 var 10
                          = -0 \times 10
                          = -4
.text:004006A0 var_4
.text:004006A0
.text:004006A0
                           lui
                                   $gp, 0x42
.text:004006A4
                           addiu
                                   $sp, -0x28
.text:004006A8
                           li
                                   $gp, 0x418960
```

```
$ra, 0x28+var 4($sp)
.text:004006AC
                          SW
.text:004006B0
                                   $gp, 0x28+var_18($sp)
                          SW
.text:004006B4
                                   $t9, puts
                          la
.text:004006B8
                          lui
                                   $a0, 0x40
.text:004006BC
                          jalr
                                  $t9 ; puts
                                                    # "Enter X:"
.text:004006C0
                                   $a0, aEnterX
                          la
                                   $gp, 0x28+var_18($sp)
.text:004006C4
                          lw
.text:004006C8
                          lui
                                   $a0, 0x40
.text:004006CC
                                  $t9, __isoc99_scanf
$a0, aD #
                          la.
.text:004006D0
                          la
                                                    # "%d"
                                          _isoc99_scanf
                          jalr
                                   $t9 ; _
.text:004006D4
                                   $a1, $sp, 0x28+var_10 # branch delay slot
.text:004006D8
                          addiu
.text:004006DC
                          li
                                   $v1, 1
.text:004006E0
                                   $gp, 0x28+var_18($sp)
                          lw
                                   $v0, $v1, loc_40070C
.text:004006E4
                          beq
                                                  # branch delay slot, NOP
.text:004006E8
                          or
                                   $at, $zero
.text:004006EC
                                  $t9, puts
                          la
                                  $a0, 0x40
.text:004006F0
                          lui
.text:004006F4
                          jalr
                                  $t9 ; puts
.text:004006F8
                          la
                                  $a0, aWhatYouEntered # "What you entered?
.text:004006FC
                          lw
                                  $ra, 0x28+var_4($sp)
.text:00400700
                                  $v0, $zero
                          move
.text:00400704
                          jr
                                  $ra
                                  $sp, 0x28
.text:00400708
                          addiu
.text:0040070C loc_40070C:
.text:0040070C
                                  $t9, printf
                                  $a1, 0x28+var 10($sp)
.text:00400710
                          lw
.text:00400714
                          lui
                                  $a0, 0x40
.text:00400718
                          jalr
                                  $t9 ; printf
                                                        # "You entered
.text:0040071C
                          la
                                  $a0, aYouEnteredD____
   %d..
.text:00400720
                          1w
                                   $ra, 0x28+var_4($sp)
.text:00400724
                          move
                                  $v0, $zero
.text:00400728
                          jr
                                   $ra
.text:0040072C
                          addiu
                                  $sp, 0x28
```

scanf() zwraca wynik wykonania przez rejestr \$V0. Jest on sprawdzany pod adresem 0x004006E4, przez porównanie jego wartości z \$V1 (wartość 1 została zapisana do \$V1 wcześniej, pod adresem 0x004006DC). BEQ oznacza "Branch Equal". Jeśli dwie wartości są sobie równe (w naszym przykładzie tak będzie w przypadku sukcesu), sterowanie skacze pod adres 0x0040070C.

Ćwiczenie

Jak widać, instrukcja JNE/JNZ może być łatwo zastąpiona przez JE/JZ i vice versa (a BNE przez BEQ i vice versa). Jednak należy pamiętać o zamianie miejscami bloków kodu do wykonania. Spróbuj to zrobić w ramach ćwiczeń.

1.12.5 Ćwiczenie

• http://challenges.re/53

1.13 Warto zauważyć: zmienne globalne vs zmienne lokalne

Teraz już wiesz, że zmienne globalne są wypełniane zerami przez OS przy starcie programu (1.12.3 on page 103, [ISO/IEC 9899:TC3 (C C99 standard), (2007)6.7.8p10]), a zmienne lokalne nie (1.9.4 on page 52).

Czasami możesz zapomnieć zainicjalizować zmienną globalną, a program polega na tym, że jej wartość na starcie wynosi 0. Następnie zmieniasz program i przenosisz zmienną do funkcji, zmieniając ją na lokalną. Jednak tym razem jej wartość nie będzie wynosiła 0, co może prowadzić do nieprzyjemnych błędów.

1.14 Dostęp do przekazanych argumentów

Poznaliśmy już jak funkcja wywołująca przekazuje argumenty przez stos do funkcji wywoływanej. Ale w jaki sposób funkcja wywoływana może się do nich dostać?

Listing 1.90: Prosty przykład

```
#include <stdio.h>
int f (int a, int b, int c)
{
    return a*b+c;
};
int main()
{
    printf ("%d\n", f(1, 2, 3));
    return 0;
};
```

1.14.1 x86

MSVC

Poniżej wynik kompilacji (MSVC 2010 Express):

Listing 1.91: MSVC 2010 Express

```
ebp, esp
        mov
                 eax, DWORD PTR _a$[ebp]
        mov
        imul
                 eax, DWORD PTR _b$[ebp]
        add
                 eax, DWORD PTR _c$[ebp]
        pop
                 ebp
                 0
        ret
f
        ENDP
_main
        PR<sub>0</sub>C
                 ebp
        nush
        mov
                 ebp, esp
                 3 ; 3rd argument
        push
                 2 ; 2nd argument
        push
                 1 ; 1st argument
        push
        call
                  f
        add
                 esp, 12
        push
                 eax
                 OFFSET $SG2463 ; '%d', 0aH, 00H
        push
                 _printf
        call
        add
                 esp, 8
        ; return 0
        xor
                 eax, eax
        pop
                 ebp
        ret
        ENDP
main
```

Na listingu widać, jak funkcja main() odkłada na stos 3 liczby i wywołuje f(int,int,int).

Dostęp do argumentów f() uzyskuje za pomocą makr, jak np.:

_a\$ = 8, podobnie jak do zmiennych lokalnych, ale z dodatnim przesunięciem. Niejako adresujemy pamięć *poza stosem*, gdyż stos rośnie w dół, a my dodajemy wartość dodatnią _a\$ do rejestru EBP (wskaźnik ramki stosu).

Następnie wartość a jest zapisywana do EAX. Po wykonaniu instrukcji IMUL, wartość w EAX jest iloczynem wartości z EAX i wartości wskazywanej przez przesunięcie b.

Kolejno wykonywana jest instrukcja ADD, która dodaje wartość pokazywaną przez przesunięcie _c do EAX.

Wartość w EAX już nie musi być nigdzie zapisywana, gdyż jest to wynik funkcji, a w tej konwencji wywoływania jest on zwracany przez rejestr EAX. Po powrocie funkcja wywołująca pobiera wartość z EAX i używa jako argumentu do printf().

MSVC + OllyDbg

Prześledźmy działanie programu w OllyDbg. Gdy zatrzymamy się na pierwszej instrukcji w f(), używającej jednego z argumentów (pierwszego), widać, że EBP pokazuje na ramkę stosu (oznaczona czerwonym prostokątem).

Pierwszym elementem w ramce stosu jest zapisana wartość EBP, drugim jest RA (adres powrotu), trzecim jest pierwszy argument funkcji, następnie drugi i trzeci.

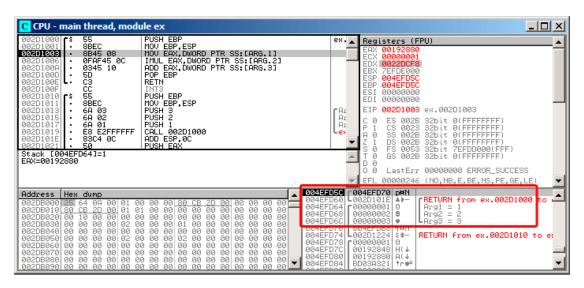
Do odwołania się do pierwszego arugmentu należy dodać dokładnie 8 (dwa 32-bitowe słowa) do EBP.

OllyDbg potrafi to rozpoznać i dodał odpowiednie komentarze do elementów na stosie:

```
"RETURN from" czy "Arg1 = ...", etc.
```

Tak naprawdę - argumenty funkcji nie należą do ramki stosu funkcji, są elementami ramki stosu funkcji wywołującej.

Z tego powodu OllyDbg oznaczył argumenty "Arg" jako elementy innej ramki stosu.



Rysunek 1.23: OllyDbg: inside of f() function

GCC

Skompilujmy ten sam przykład w GCC 4.4.1 i podejrzyjmy rezultat w programie IDA:

Listing 1.92: GCC 4.4.1

```
public f
f
        proc near
arg_0
        = dword ptr
arg_4
        = dword ptr
                     0Ch
arg_8
        = dword ptr
                     10h
                ebp
        push
        mov
                ebp, esp
        mov
                eax, [ebp+arg_0] ; 1 argument
                eax, [ebp+arg_4] ; 2 argument
        imul
                eax, [ebp+arg_8] ; 3 argument
        add
                ebp
        pop
        retn
f
        endp
```

```
public main
main
         proc near
var_10
         = dword ptr -10h
         = dword ptr -0Ch
\mathsf{var}_{\mathsf{C}}\mathsf{C}
var_8
         = dword ptr -8
         push
                   ebp
                   ebp, esp
         mov
                   esp, 0FFFFFF0h
         and
         sub
                   esp, 10h
                   [esp+10h+var_8], 3 ; 3 argument
[esp+10h+var_C], 2 ; 2 argument
         mov
         mov
                   [esp+10h+var_10], 1 ; 1 argument
         mov
         call
                   edx, offset aD ; "%d\n"
         mov
                   [esp+10h+var_C], eax
         mov
                   [esp+10h+var_10], edx
         mov
                   _printf
         call
         mov
                   eax, 0
         leave
          retn
main
         endp
```

Efekt jest taki sam, z małymi różnicami, które już omówiliśmy wcześniej.

Wskaźnik stosu nie jest przywracany po dwóch wywołaniach funkcji (f oraz printf()), ponieważ przedostatnia instrukcja LEAVE (?? on page ??) zajmie się tym na końcu.

1.14.2 x64

Rzecz wygląda nieco inaczej na x86-64. Argumenty funkcji (pierwsze 4 lub 6) są przekazywane przez rejestry, a więc funkcja wywoływana odczytuje je z rejestrów zamiast ze stosu.

MSVC

Optymalizujący MSVC:

Listing 1.93: Optymalizujący MSVC 2012 x64

```
$SG2997 DB
                  '%d', 0aH, 00H
main
        PR<sub>0</sub>C
         sub
                 rsp, 40
        mov
                 edx, 2
                 r8d, QWORD PTR [rdx+1]; R8D=3
         lea
         lea
                 ecx, QWORD PTR [rdx-1]; ECX=1
         call
                 rcx, OFFSET FLAT: $SG2997; '%d'
         lea
        mov
                 edx, eax
        call
                 printf
        xor
                 eax, eax
```

```
add
                  rsp, 40
         ret
main
         ENDP
f
         PR<sub>0</sub>C
         ; ECX - 1 argument
         ; EDX - 2 argument
         ; R8D - 3 argument
         imul
                  ecx, edx
                  eax, DWORD PTR [r8+rcx]
         lea
         ret
         ENDP
```

Jak widać, funkcja f () odczytuje wartości wszystkich argumentów z rejestrów.

Instrukcja LEA została użyta do zrealizowania dodawania, najwyraźniej kompilator uznał, że będzie szybsza niż ADD.

LEA jest również używana w funkcji main() do przygotowania pierwszego i trzeciego argumentu funkcji f(). Kompilator zdecydował, że będzie to szybsze niż klasyczne załadowanie wartości do rejestru za pośrednictwem instrukcji MOV.

Rzućmy okiem na wynik nieoptymalizującego MSVC:

Listing 1.94: MSVC 2012 x64

```
f
                proc near
; shadow space:
arg 0
                = dword ptr
arg 8
                = dword ptr
                              10h
arg_10
                              18h
                = dword ptr
                 ; ECX - 1 argument
                 ; EDX - 2 argument
                 ; R8D - 3 argument
                         [rsp+arg_10], r8d
                mov
                         [rsp+arg_8], edx
                mov
                         [rsp+arg_0], ecx
                mov
                         eax, [rsp+arg_0]
                mov
                imul
                         eax, [rsp+arg 8]
                add
                         eax, [rsp+arg_10]
                retn
f
                endp
main
                proc near
                sub
                         rsp, 28h
                mov
                         r8d, 3 ; 3 argument
                         edx, 2 ; 2 argument
                mov
                mov
                         ecx, 1 ; 1 argument
                call
                         f
                moν
                         edx, eax
                         rcx, $SG2931
                                          ; "%d\n"
                lea
                call
                         printf
```

```
; return 0
xor eax, eax
add rsp, 28h
retn
main endp
```

Wynik kompilacji wygląda dość dziwnie, ponieważ wszystkie 3 argumenty z rejestrów zostały z jakiegoś powodu odłożone na stos.

Nazywamy to "shadow space" 81:

Każda funkcja w Win64 może (ale nie musi) zapisać tam wartości 4 argumentów, przekazywanych przez rejestry. Dzieje się to z dwóch powodów: 1) przeznaczanie całego rejestru (lub nawet 4 rejestrów) na argumenty jest rozrzutne, więc dostęp do nich będzie zachodził przez stos 2) ułatwia to debuggowanie, gdyż debugger zawsze wie, gdzie znaleźć argumenty funkcji 82.

Czasami duże funkcje mogą zapisywać swoje argumenty do "shadow space", jeśli będą one wykorzystywane podczas wykonania, ale małe funkcje nie muszą tego robić.

Odpowiedzialnością funkcji wywołującej jest zaalokowanie na stosie miejsca na "shadow space".

GCC

Optymalizujący GCC generuje dość zrozumiały kod:

Listing 1.95: Optymalizujący GCC 4.4.6 x64

```
f:
        ; EDI - 1 argument
        ; ESI - 2 argument
        ; EDX - 3 argument
        imul
                esi, edi
                eax, [rdx+rsi]
        lea
        ret
main:
        sub
                 rsp, 8
                edx, 3
        mov
                esi, 2
        mov
                edi, 1
        mov
        call
                edi, OFFSET FLAT:.LC0 ; "%d\n"
        mov
        mov
                esi, eax
                          ; liczba rejestrów wektorowych z argumentami
        xor
                eax, eax
        call
                printf
        xor
                eax, eax
        add
                 rsp, 8
        ret
```

⁸¹ MSDN

⁸² MSDN

Nieoptymalizujący GCC:

Listing 1.96: GCC 4.4.6 x64

```
f:
        ; EDI - 1 argument
        ; ESI - 2 argument
        ; EDX - 3 argument
        push
                rbp
        mov
                rbp, rsp
                DWORD PTR [rbp-4], edi
        mov
                DWORD PTR [rbp-8], esi
        mov
        mov
                DWORD PTR [rbp-12], edx
        mov
                eax, DWORD PTR [rbp-4]
                eax, DWORD PTR [rbp-8]
        imul
        add
                eax, DWORD PTR [rbp-12]
        leave
        ret
main:
        push
                rbp
        mov
                rbp, rsp
                edx, 3
        mov
        mov
                esi, 2
        mov
                edi, 1
        call
                edx, eax
        mov
        mov
                eax, OFFSET FLAT:.LC0; "%d\n"
                esi, edx
        mov
                rdi, rax
        mov
                eax, 0 ; liczba rejestrów wektorowych z argumentami
        mov
        call
                printf
        mov
                eax, 0
        leave
        ret
```

W System V *NIX ([Michael Matz, Jan Hubicka, Andreas Jaeger, Mark Mitchell, *System V Application Binary Interface. AMD64 Architecture Processor Supplement*, (2013)] ⁸³) nie ma wymagania o "shadow space", ale funkcje wywoływane mogą zapisywać swoje argumenty przy niedoborze rejestrów.

GCC: uint64_t zamiast int

Nasz przykład wykorzystuje 32-bitowy typ *int*, dlatego używane są 32-bitowe części rejestrów (z prefiksem E-).

Zmodyfikujmy nieco przykład, by użyć wartości 64-bitowych:

```
#include <stdio.h>
#include <stdint.h>
uint64_t f (uint64_t a, uint64_t b, uint64_t c)
```

⁸³ Dostep także przez https://software.intel.com/sites/default/files/article/402129/ mpx-linux64-abi.pdf

Listing 1.97: Optymalizujący GCC 4.4.6 x64

```
f
        proc near
        imul
                rsi, rdi
        lea
                rax, [rdx+rsi]
        retn
f
        endp
main
        proc near
        sub
        mov
                rdx, 33333334444444h ; 3 argument
                rsi, 1111111122222222h ; 2 argument
        mov
                rdi, 1122334455667788h ; 1 argument
        mov
        call
                edi, offset format ; "%lld\n"
        mov
                rsi, rax
        mov
                eax, eax ; liczba rejestrów wektorowych z argumentami
        xor
                _printf
        call
        xor
                eax, eax
        add
                rsp, 8
        retn
main
        endp
```

Kod jest taki sam, ale tym razem użyto całych rejestrów (z prefiksem R-).

1.14.3 ARM

Nieoptymalizujący Keil 6/2013 (tryb ARM)

```
.text:000000A4 00 30 A0 E1
                                          R3, R0
                                 MOV
.text:000000A8 93 21 20 E0
                                 MLA
                                          R0, R3, R1, R2
.text:000000AC 1E FF 2F E1
                                 BX
                                          LR
.text:000000B0
                            main
.text:000000B0 10 40 2D E9
                                 STMFD
                                          SP!, {R4,LR}
                                          R2, #3
R1, #2
.text:000000B4 03 20 A0 E3
                                 MOV
.text:000000B8 02 10 A0 E3
                                 MOV
.text:000000BC 01 00 A0 E3
                                 MOV
                                          R0, #1
.text:000000C0 F7 FF FF EB
                                 BL
.text:000000C4 00 40 A0 E1
                                 MOV
                                          R4, R0
                                          R1, R4
.text:000000C8 04 10 A0 E1
                                 MOV
```

Funkcja main() po prostu wywołuje dwie inne funkcje, przekazując trzy wartości do pierwszej z nich -(f()).

Jak zauważyliśmy poprzednio, w ARM 4 pierwsze wartości są zwykle przekazywane przez 4 pierwsze rejestry (R0-R3).

Funkcja f() używa trzech pierwszych (R0-R2) do przechowywania argumentów.

Instrukcja MLA (*Multiply Accumulate*) mnoży dwa pierwsze operandy (R3 i R1), dodaje do ich iloczynu trzeci (R2) a wynik zapisuje do rejestru zerowego (R0), który, zgodnie ze standardem, służy do zwracania wartości z funkcji.

Jednoczesne mnożenie i dodawanie (*Fused multiply-add*) ⁸⁴. jest bardzo użyteczną operacją. Na x86 nie było takich instrukcji przed wprowadzaniem rozszerzenia FMA (zestaw nowych instrukcji typu SIMD) ⁸⁵.

Pierwsza instrukcja MOV R3, R0, jest nadmiarowa (operację można by zrealizować za pomocą tylko jednej instrukcji MLA). Kompilator pominął optymalizację, gdyż pracował w trybie z wyłączoną optymalizacją.

Instrukcja BX zwraca sterowanie do adresu przechowywanego w rejestrze LR i, jeśli trzeba, zmienia tryb pracy procesora z Thumb na ARM bądź odwrotnie. Może się to okazać niezbędne, gdyż funkcja f() nie wie z jakiego kodu jest wywoływana, może to być zarówno ARM jak i Thumb. Zatem jeśli jest wywoływana z kodu Thumb, BX zwróci sterowanie do funkcji wywołującej i zmieni tryb procesora na Thumb. Jeśli funkcja została wywołana z kodu ARM, wtedy nie zmieni trybu [ARM(R) Architecture Reference Manual, ARMv7-A and ARMv7-R edition, (2012)A2.3.2].

Optymalizujący Keil 6/2013 (tryb ARM)

.text:00000098		f			
.text:00000098	91 20 20	E0 ML	Α R0,	R1, R0,	, R2
.text:0000009C	1E FF 2F	E1 BX	LR		

Widać funkcję f() skompilowaną za pomocą kompilatora Keil w trybie z pełną optymalizacja (-03).

Instrukcja MOV została usunięta. Teraz MLA używa wszystkich rejestrów z argumentami i zapisuje wynik do R0, dokładnie tam, skąd funkcja wywołująca tę wartość odczyta.

Optymalizujący Keil 6/2013 (tryb Thumb)

⁸⁴ przyp. tłum. - prawdziwe Fused multiply-add stosuje jedno zaokrąglanie podczas tej operacji - Wikipedia. Instrukcja MLA nie jest opisana jako Fused na stronie Keil
85 wikipedia

```
.text:0000005E 48 43 MULS R0, R1
.text:00000060 80 18 ADDS R0, R0, R2
.text:00000062 70 47 BX LR
```

Instrukcja MLA nie jest dostępna w trybie Thumb, więc kompilator generuje dwie osobne instrukcje (mnożenie i dodawanie).

Pierwsza instrukcja, MULS, mnoży R0 przez R1 i zapisuje wynik do R0. Druga instrukcja (ADDS) dodaje iloczyn i R2 a wynik zapisuje do R0.

ARM64

Optymalizujący GCC (Linaro) 4.9

Wynik kompilacji jest bardzo prosty. Instrukcja MADD przeprowadza jednoczesne mnożenie i dodawanie (podobnie jak MLA, którą widzieliśmy wcześniej). Wszystkie 3 argumenty są w 32-bitowych częściach rejestrów X, ponieważ są one 32-bitowymi liczbami typu *int*. Wynik jest zwracana przez W0.

Listing 1.98: Optymalizujący GCC (Linaro) 4.9

```
f:
        madd
                 w0, w0, w1, w2
        ret
main:
; zapisz FP i LR w ramce stosu:
                x29, x30, [sp, -16]!
        stp
                 w2, 3
        mov
        mov
                 w1, 2
                 x29, sp, 0
        add
                 w0, 1
        mov
        bl
        mov
                 w1, w0
        adrp
                 x0, .LC7
        add
                 x0, x0, :lo12:.LC7
        bl
                 printf
; zwróc 0
                w0, 0
        mov
; przywróć FP i LR
                 x29, x30, [sp], 16
        ldp
        ret
.LC7:
        .string "%d\n"
```

Rozszerzmy typ danych do 64-bitowych liczb typu uint64_t:

```
#include <stdio.h>
#include <stdint.h>
uint64_t f (uint64_t a, uint64_t b, uint64_t c)
```

```
f:
                x0, x0, x1, x2
        madd
        ret
main:
                x1, 13396
        mov
        adrp
                x0, .LC8
                x29, x30, [sp, -16]!
        stp
                x1, 0x27d0, lsl 16
        movk
        add
                x0, x0, :lo12:.LC8
        movk
                x1, 0x122, lsl 32
        add
                x29, sp, 0
        movk
                x1, 0x58be, lsl 48
        bl
                printf
        mov
                w0, 0
                x29, x30, [sp], 16
        ldp
        ret
.LC8:
        .string "%lld\n"
```

Funkcja f() jest niemal taka sama, używa jednak pełnych 64-bitowych rejestrów X. Duże 64-bit wartości są zapisywane do rejestrów w cześciach, patrz: ?? on page ??.

Nieoptymalizujący GCC (Linaro) 4.9

Kompilator z wyłączoną optymalizacją generuje dłuższy kod:

```
f:
        sub
                 sp, sp, #16
                w0, [sp,12]
        str
                w1, [sp,8]
        str
        str
                w2, [sp,4]
                w1, [sp,12]
        ldr
                w0, [sp,8]
        ldr
        mul
                w1, w1, w0
        ldr
                w0, [sp,4]
        add
                w0, w1, w0
        add
                 sp, sp, 16
        ret
```

Kod zapisuje swoje argumenty wejściowe na stosie lokalnym, na wypadek gdyby coś w funkcji musiało użyć rejestrów W0...W2. Dzięki temu unikniemy nadpisywania oryginalnych wartości argumentów funkcji, które mogą być potrzebne w przyszłości.

Jest to nazywane Register Save Area. [Procedure Call Standard for the ARM 64-bit Architecture (AArch64), (2013)]⁸⁶. Funkcja wywoływana nie ma obowiązku tego robić. Przypomina to "Shadow Space": 1.14.2 on page 134.

Dlaczego optymalizujący GCC 4.9 pominął kod zapisujący argumenty? Ponieważ przeprowadził analizę i wywnioskował, że argumenty funkcji nie będą potrzebne w przyszłości i rejestry W0...W2 nie będą używane.

Widać również parę instrukcji MUL/ADD zamiast pojedynczej MADD.

1.15 switch()/case/default

1.15.1

```
#include <stdio.h>

void f (int a)
{
    switch (a)
    {
       case 0: printf ("zero\n"); break;
       case 1: printf ("one\n"); break;
       case 2: printf ("two\n"); break;
       default: printf ("something unknown\n"); break;
    };
};

int main()
{
    f (2); // test
};
```

Wnioski

listing.??.

1.15.2 Ćwiczenia

Ćwiczenie#1

Polish text placeholder

⁸⁶Dostep także przez http://infocenter.arm.com/help/topic/com.arm.doc.ihi0055b/IHI0055B_
aapcs64.pdf

1.16 Loops

1.16.1 Ćwiczenia

```
http://challenges.re/54http://challenges.re/55http://challenges.re/56http://challenges.re/57
```

1.17 More about strings

1.17.1 strlen()

```
int my_strlen (const char * str)
{
         const char *eos = str;
         while( *eos++ ) ;
         return( eos - str - 1 );
}
int main()
{
         // test
         return my_strlen("hello!");
};
```

ARM

1.18 Replacing arithmetic instructions to other ones

1.18.1 Ćwiczenie

• http://challenges.re/59

1.19 Arrays

yy ⁸⁷

1.19.1

⁸⁷AKA "homogener Container".

```
#include <stdio.h>
int main()
{
    int a[20];
    int i;

    for (i=0; i<20; i++)
        a[i]=i*2;

    for (i=0; i<20; i++)
        printf ("a[%d]=%d\n", i, a[i]);

    return 0;
};</pre>
```

1.19.2

1.19.3 Wnioski

Tablica jest zbiorem wartości połozonych obok siebie w pamięci.

Dotyczy to każdego typu elementów, włączając w to struktury.

Aby uzyskać dostęp do konkretnego elementu tablicy, wystarczy obliczyć jego adres.

1.19.4 Ćwiczenia

```
http://challenges.re/62
http://challenges.re/63
http://challenges.re/64
http://challenges.re/65
http://challenges.re/66
```

1.20 Structures

1.20.1 UNIX: struct tm

1.20.2

1.20.3 Ćwiczenia

```
http://challenges.re/71http://challenges.re/72
```

1.21

1.21.1

Polish text placeholder

Java

- 4.1 Java
- 4.1.1
- 4.1.2
- 4.1.3

- 5.1 Linux
- 5.2 Windows NT
- 5.2.1 Windows SEH

SEH

[Matt Pietrek, A Crash Course on the Depths of Win32 $^{\text{m}}$ Structured Exception Handling, (1997)]¹, [Igor Skochinsky, Compiler Internals: Exceptions and RTTI, (2012)]

5.3

5.4

Pierre Capillon – Black-box cryptanalysis of home-made encryption algorithms: a practical case study.

How to Hack an Expensive Camera and Not Get Killed by Your Wife.

¹Dostęp także przez http://www.microsoft.com/msj/0197/Exception/Exception.aspx

²Dostęp także przez http://yurichev.com/mirrors/RE/Recon-2012-Skochinsky-Compiler-Internals.pdf

Książki/blogi warte przeczytania

7.1 Książki i inne materiały

7.1.1 Inżynieria wsteczna

- Eldad Eilam, Reversing: Secrets of Reverse Engineering, (2005)
- Bruce Dang, Alexandre Gazet, Elias Bachaalany, Sebastien Josse, Practical Reverse Engineering: x86, x64, ARM, Windows Kernel, Reversing Tools, and Obfuscation, (2014)
- Michael Sikorski, Andrew Honig, Practical Malware Analysis: The Hands-On Guide to Dissecting Malicious Software, (2012)
- Chris Eagle, IDA Pro Book, (2011)
- Reginald Wong, Mastering Reverse Engineering: Re-engineer your ethical hacking skills, (2018)

(Stara, ale wciąż interesująca) Pavol Cerven, *Crackproof Your Software: Protect Your Software Against Crackers*, (2002).

Oraz książki Krisa Kaspersky'ego.

7.1.2 Windows

- Mark Russinovich, Microsoft Windows Internals
- Peter Ferrie The "Ultimate" Anti-Debugging Reference¹

Blogi:

• Microsoft: Raymond Chen

¹http://pferrie.host22.com/papers/antidebug.pdf

nynaeve.net

7.1.3 C/C++

- Brian W. Kernighan, Dennis M. Ritchie, *The C Programming Language*, 2ed, (1988)
- ISO/IEC 9899:TC3 (C C99 standard), (2007)²
- Bjarne Stroustrup, The C++ Programming Language, 4th Edition, (2013)
- C++11 standard³
- Agner Fog, Optimizing software in C++ (2015)⁴
- Marshall Cline, C++ FAQ⁵
- Dennis Yurichev, C/C++ programming language notes⁶
- JPL Institutional Coding Standard for the C Programming Language⁷

7.1.4 x86 / x86-64

- manuale Intela⁸
- manuale AMD ⁹
- Agner Fog, The microarchitecture of Intel, AMD and VIA CPUs, (2016)¹⁰
- Agner Fog, Calling conventions (2015)¹¹
- Intel® 64 and IA-32 Architectures Optimization Reference Manual, (2014)
- Software Optimization Guide for AMD Family 16h Processors, (2013)

Trochę stare, ale wciąż interesujące:

Michael Abrash, *Graphics Programming Black Book*, 1997¹² (znany z pracy nad niskopoziomową optymalizacją w takich projektach jak Windows NT 3.1 i id Quake).

7.1.5 ARM

• manuale ARM¹³

```
<sup>2</sup>Dostęp także przez http://www.open-std.org/jtc1/sc22/WG14/www/docs/n1256.pdf
  Dostep także przez http://www.open-std.org/jtc1/sc22/wg21/docs/papers/2013/n3690.pdf.
  <sup>4</sup>Dostęp także przez http://agner.org/optimize/optimizing_cpp.pdf.
  <sup>5</sup>Dostęp także przez http://www.parashift.com/c++-faq-lite/index.html
  <sup>6</sup>Dostęp także przez http://yurichev.com/C-book.html
  <sup>7</sup>Dostep także przez https://yurichev.com/mirrors/C/JPL Coding Standard C.pdf
                             przez
                                          http://www.intel.com/content/www/us/en/processors/
  <sup>8</sup>Dostęp
                 także
architectures-software-developer-manuals.html
  <sup>9</sup>Dostęp także przez http://developer.amd.com/resources/developer-guides-manuals/
 <sup>10</sup>Dostęp także przez http://agner.org/optimize/microarchitecture.pdf
 11Dostep także przez http://www.agner.org/optimize/calling_conventions.pdf
 12 Dostęp także przez https://github.com/jagregory/abrash-black-book
 <sup>13</sup>Dostęp także przez http://infocenter.arm.com/help/index.jsp?topic=/com.arm.doc.subset.
architecture.reference/index.html
```

- ARM(R) Architecture Reference Manual, ARMv7-A and ARMv7-R edition, (2012)
- [ARM Architecture Reference Manual, ARMv8, for ARMv8-A architecture profile, (2013)]¹⁴
- Advanced RISC Machines Ltd, The ARM Cookbook, (1994)¹⁵

7.1.6 Język maszynowy

Richard Blum — Professional Assembly Language.

7.1.7 Java

[Tim Lindholm, Frank Yellin, Gilad Bracha, Alex Buckley, *The Java(R) Virtual Machine Specification / Java SE 7 Edition*] ¹⁶.

7.1.8 UNIX

Eric S. Raymond, The Art of UNIX Programming, (2003)

7.1.9 Programowanie

- Brian W. Kernighan, Rob Pike, Practice of Programming, (1999)
- Henry S. Warren, Hacker's Delight, (2002). Niektórzy twierdzą, że sztuczki z tej książki nie mają dzisiaj znaczenia, ponieważ miały zastosowanie wyłącznie w procesorach RISC, gdzie instrukcje typu branch są kosztowne. Niemniej jednak, wszystko to znacząco ułatwia zrozumienie algebry Boole'a i całej matematyki wokół tego.

7.1.10

- Bruce Schneier, Applied Cryptography, (John Wiley & Sons, 1994)
- (Free) lvh, *Crypto* 101¹⁷
- (Free) Dan Boneh, Victor Shoup, A Graduate Course in Applied Cryptography¹⁸.

7.1.11 Coś jeszcze prostszego

Osobom, dla których ta książka jest zbyt trudna i techniczna, polecam łagodne wprowadzenie do niskopoziomowych zagadnień związanych z maszynami liczącymi: "Code: The Hidden Language of Computer Hardware and Software" Charlesa Petzolda.

¹⁴Dostep także przez http://yurichev.com/mirrors/ARMv8-A_Architecture_Reference_Manual_
(Issue_A.a).pdf

¹⁵ Dostep także przez https://yurichev.com/ref/ARM%20Cookbook%20(1994)/

¹⁶ Dostep także przez https://docs.oracle.com/javase/specs/jvms/se7/jvms7.pdf; http://docs.oracle.com/javase/specs/jvms/se7/html/

¹⁷Dostep także przez https://www.crypto101.io/

¹⁸ Dostęp także przez https://crypto.stanford.edu/~dabo/cryptobook/

Inną prostą książką jest komiks dla dzieci¹⁹ z 1983 roku, poświęcony mikroprocesorom 6502 i Z80.

¹⁹https://yurichev.com/mirrors/machine-code-for-beginners.pdf

Użyte akronimy

	154
OS System operacyjny (Operating System)	ix
PL Język programowania (Programming Language)	vi
ROM Pamięć tylko do odczytu (Read-Only Memory)	108
ALU Jednostka arytmetyczno-logiczna (Arithmetic Logic Unit)	36
LIFO Ostatni na wejściu, pierwszy na wyjściu (Last In First Out)	42
ABI Interfejs binarny aplikacji (Application Binary Interface)	22
PC Program Counter. IP/EIP/RIP w x86/64. PC w ARM	26
SP wskaźnik stosu. SP/ESP/RSP w x86/x64. SP w ARM	26
RA adres powrotu	8
PE Portable Executable (format plików wykonywalnych w systemach Windows)	7
LR Link Register	8
IDA Interaktywny deasembler i debugger rozwijany przez Hex-Rays	7
MSVC Microsoft Visual C++	
AKA Also Known As — znany również jako	42
CRT C Runtime library	14
CPU Central Processing Unit	ix
CISC Complex Instruction Set Computing	27
RISC Reduced Instruction Set Computing	3
BSS Block Started by Symbol	34

J	155
DBMS Database Management Systems	vi
ISA Instruction Set Architecture (architektura listy rozkazów)	2
SEH Structured Exception Handling	51
ELF Executable and Linkable Format: Format plików wykonywalnych używany w stemach z rodziny *NIX, w szczególności na Linuksie	
NOP No Operation	9
BEQ (PowerPC, ARM) Branch if Equal	126
RAM Random-Access Memory	108
GCC GNU Compiler Collection	5
ASCIIZ ASCII Zero ()	123
GPR General Purpose Registers (rejestry ogólnego przeznaczania)	2
GDB GNU Debugger	65
FP Frame Pointer	33
STMFD Store Multiple Full Descending ()	
LDMFD Load Multiple Full Descending ()	
STMED Store Multiple Empty Descending ()	42
LDMED Load Multiple Empty Descending ()	42
STMFA Store Multiple Full Ascending ()	42
LDMFA Load Multiple Full Ascending ()	42
STMFA Store Multiple Empty Ascending ()	42

		156
LDM	EA Load Multiple Empty Ascending ()	42
EOF	End of File	115
URL	Uniform Resource Locator	5

Słownik terminów

```
anti-pattern coś powszechnie uznanego jako zła praktyka. 45, 102
callee funkcja wywoływana. 63, 115, 129, 132, 135
caller funkcja wywołująca. 8-11, 41, 63, 115, 129-131, 134
endianess kolejność bajtów. 30, 105
funkcja liść Funkcja, która nie wywołuje żadnej innej. 39, 45
GiB gibibajt: 2^{10} (1024) mebibajtów, 2^{20} (1048576) kibibajtów lub 2^{30} (1073741824)
    bajtów. 22
heap (kopiec, sterta) - przeważnie duży kawałek pamięci, zapewniony aplikacji przez
    OS na jej własne potrzeby. malloc()/free() pracują ze stertą. 43
inkrementować zwiększać o 1. 23
inżynieria wsteczna proces odkrywania jak dana rzecz działa, czasami w celu jej
    sklonowania. iii
przesuniecie skoku część kodu operacji instrukcji JMP i Jcc, która jest dodawana
    do adresu kolejnej instrukcji by wyliczyć nową wartość PC. Może mieć wartość
    ujemną. 124
ramka stosu Część stosu, która zawiera informacje specyficzne dla bieżącej funkcji:
    zmienne lokalne, argumenty funkcji, RA, etc.. 92, 130
rejestr powrotu (RISC) Rejestr, w który zwykle przechowywany jest adres powro-
    tu. Dzięki temu można wywoływać funkcje-liście (leaf functions) bez używania
    stosu - a więc szybciej. 44
stdout standardowe wyjście. 29, 49
thunk function prosta funkcja, której jedynym zadaniem jest wywołanie innej funk-
```

cji. 31, 58

wskaźnik stosu rejestr pokazujący na miejsce na stosie. 13, 15, 27, 42, 48, 59, 74, 76, 98, 132

Indeks

```
0x0BADF00D, 101
                                               STMIA, 76
0xCCCCCCC, 101
                                               STMIB. 78
                                               STP, 33, 74
Alpha AXP, 3
                                               STR, 75
ARM
                                               SUB, 76
    DCB, 27
                                             Leaf function, 45
    Instructions
                                             Mode switching, 137
     ADD, 29, 140
                                             przełączanie trybów, 30
     ADDS, 138
                                             Rejestry
     ADR, 26
                                               Link Register, 26, 27, 44, 73
     ADRP/ADD pair, 33, 74, 109
                                               Z, 126
     B, 73
                                             tryb ARM, 3
     Bcc, 127, 128
                                             tryb Thumb-2, 3
      BEQ, 126
                                             tryb Thumb, 3
      BL, 26, 28, 30, 31, 33
                                         ARM64
     BLX, 30
                                             lo12, 74
     BX, 137
     CMP, 126, 127
                                         Biblioteki łączone dynamicznie (DLL, z ang.
     LDMEA, 42
                                                 Dynamic-Link Library ), 30
     LDMED, 42
                                         Boolector, 57
     LDMFA, 42
                                         Borland Delphi, 20
     LDMFD, 27, 42
                                         Buffer Overflow, 142
     LDP, 34
     LDR, 76, 98, 108
                                         C language elements
                                             const, 13, 109
     MADD, 138
                                             Pointers, 90, 98
     MLA, 137
     MOV, 11, 27, 29
                                             return, 14, 115
                                             switch, 140
      MOVT, 29
                                             while, 141
      MOVT.W, 30
      MOVW, 30
                                         C standard library
     MUL, 140
                                             alloca(), 48
     MULS, 138
                                             memcpy(), 17, 90
      POP, 26-28, 42, 44
                                             puts(), 29
     PUSH, 28, 42, 44
                                             scanf(), 89
     RET, 34
                                             strcpy(), 17
                                             strlen(), 141
      STMEA, 42
                                         cdecl, 59
      STMED, 42
      STMFA, 42, 78
                                         Compiler intrinsic, 50
     STMFD, 26, 42
```

	100
ELF, 106	PowerPC, 3, 35
fastcall, 20, 47, 89	puts() instead of printf(), 96
FORTRAN, 32	puts() zamiast printf(), 29
Function epilogue, 40, 73, 76	Qt, 19
Function prologue, 15, 40, 44, 75	
Fused multiply-add, 137, 138	rada.re, 18
GDB, 39, 65, 70	RAM, 108
GDB, 39, 03, 70	Raspberry Pi, 25 Rekurencja, 41, 43
Hex-Rays, 142	Relocation, 30
Hiew, 123	ROM, 108, 109
IDA 116 146	RSA, 7
IDA, 116, 146 var_?, 76, 98	Chaday chaca 124 125
Intel C++, 13	Shadow space, 134, 135 składnia AT&T, 16, 51
iPod/iPhone/iPad, 25	składnia Intela, 16, 25
	Software cracking, 19
JAD, 7	Stos, 42, 129
Java, 146	Stack frame, 92
Keil, 25	Stack overflow, 43
	thunk-functions, 31
LAPACK, 32	tryb Thumb-2, 30
Linker, 108	,
LLVM, 25	UNIX
MIPS, 3	chmod, 6
Branch delay slot, 11	Windows
Global Pointer, 34	Structured Exception Handling, 51, 147
Instructions	•
ADDIU, 35, 113, 114	x86
BEQ, 128 J, 9, 11, 36	Flags CF, 47
JALR, 35	Instructions
LUI, 35, 113, 114	ADD, 13, 59, 130
LW, 35, 99, 114	AND, 15
OR, 39	CALL, 13, 43
SW, 83	CMP, 115, 116
O32, 83, 89 Pseudoinstructions	IMUL, 130
LA, 39	INT, 47 Jcc, 128
LI, 11	JMP, 43, 57, 73
MOVE, 36, 112	JNE, 115, 116
NOP, 39, 112	JZ, 126
MS-DOS, 20, 47	LEA, 92, 133
OllyDbg, 61, 93, 105, 130	LEAVE, 15
Oracle RDBMS, 13	MOV, 11, 14, 17
	POP, 13, 42, 43 PUSH, 13, 15, 42, 43, 91
position-independent code, 26	1 0311, 13, 13, 42, 43, 31

```
RET, 8, 10, 14, 43
SUB, 14, 15, 116
XOR, 14, 115
Rejestry
EAX, 115
EBP, 92, 130
ESP, 59, 92
Flags, 116
ZF, 116
x86-64, 20, 21, 68, 90, 96, 125, 132
Xcode, 25
```

Zmienne globalne, 102